



Συνθετικά Δεδομένα για Ισορροπία Κλάσεων σε Περιβάλλοντα Ομοσπονδιακής Μάθησης

Διπλωματική Εργασία του Ραφαήλ-Ανέστη Κωνσταντίνου

Επιβλέποντες: Παύλος Εφραιμίδης, Καθηγητής Δ.Π.Θ.
Νικόλαος Παυλίδης, Διδάκτωρ

Μάϊος 2026 | Ξάνθη

Σύνοψη & Στόχος



Κύριο Πρόβλημα

- Η Στατιστική Ετερογένεια και η Ανισορροπία Κλάσεων υποβαθμίζουν τα Ομοσπονδιακά Μοντέλα
- Η Μειοψηφική Κλάση αποτελεί την Κλάση Ενδιαφέροντος
- Οι κλασικές Τεχνικές Υπερδειγματοληψίας δεν μπορούν να μεταφερθούν αυτούσιες σε Ομοσπονδιακό Περιβάλλον




Κύριος Στόχος και Προτεινόμενη Λύση


- Βελτίωση της Απόδοσης χωρίς παραβίαση της Ιδιωτικότητας των Πρωτογενών Δεδομένων.
- Πλαίσιο FedSMOTE

Ομοσπονδιακή Μάθηση (FL)

- > **Αποκεντρωμένη Εκπαίδευση:** Τα δεδομένα παραμένουν στις συσκευές.
- > **Ανταλλαγή Μοντέλων:** Μόνο ενημερώσεις του μοντέλου διακινούνται στο δίκτυο.
- > **FedAvg:** Ο βασικός αλγόριθμος συνάθροισης.
- > **Πλεονέκτημα:** Privacy-by-design & Συμμόρφωση με GDPR.




Ανισορροπία Κλάσεων (Class Imbalance)




- > **Αριθμός Δειγμάτων:** Η πλειοψηφική κλάση κυριαρχεί αριθμητικά.
- > **Παράδοξο της Ακρίβειας :** Υψηλή ακρίβεια αλλά πλήρης αποτυχία στη μειονοτική κλάση.
- > **Ομοσπονδιακό Περιβάλλον:** Εμφανίζεται ως ενδο-κομβική και δια-κομβική ανισορροπία.
- > Οδηγεί στο φαινόμενο της **Απόκλισης των Πελατών**.

Αλγόριθμος SMOTE

- > Παραγωγή συνθετικών δειγμάτων μέσω γραμμικής παρεμβολής.
- > $x_{\text{new}} = x_i + \lambda \cdot (x_j - x_i)$
- > Επεκτείνει τα όρια απόφασης της μειονοτικής κλάσης.



Πλήρως Ομομορφική Κρυπτογράφηση (FHE)



- > **Ιδιότητα:** Εκτέλεση πράξεων απευθείας σε κρυπτογραφημένα δεδομένα.
- > **Σχήμα CKKS:** Υποστηρίζει προσεγγιστική αριθμητική κινητής υποδιαστολής.
- > Απαραίτητο για τον πολλαπλασιασμό με το συντελεστή παρεμβολής λ.
- > Μηδενική διαρροή πληροφορίας στον διακομιστή.

Το Πλαίσιο FedSMOTE



Client-Side SMOTE

Τοπική υπερδειγματοληψία
σε κάθε κόμβο πριν την
εκπαίδευση



Trans-Client SMOTE

Δια-κομβική παραγωγή
δειγμάτων στον
Κρυπτογραφικό Χώρο




Privacy Shield

Χρήση σχήματος CKKS για
παρεμβολή στον
Κρυπτογραφικό Χώρο

Client-Side SMOTE (1/2)

- > **Λειτουργία:** Κάθε πελάτης εξισορροπεί το τοπικό του σύνολο αυτόνομα.
- > **Πλεονέκτημα:** Μηδενικό επικοινωνιακό κόστος, απλή υλοποίηση.
- > **Περιορισμός:** Αποτυγχάνει σε **ακραία ετερογένεια**.
- > **Κίνδυνος** τοπικής υπερπροσαρμογής.

Client-Side SMOTE (2/2)




Trans-Client SMOTE (1/3)


Συνεργατική Υπερδειγματοληψία με Ασφάλεια

- > Οι κόμβοι μοιράζονται την "κρυπτογραφημένη γνώση" της μειονοτικής κλάσης.
- > Ο διακομιστής δημιουργεί συνθετικά δείγματα παρεμβάλλοντας σημεία από **διαφορετικούς** πελάτες.
- > Διασφαλίζεται η **παγκόσμια ποικιλομορφία**.

Trans-Client SMOTE (2/3)



Trans-Client SMOTE (3/3)



Σύνολα Δεδομένων



Credit Card Fraud Detection

284,807 Νόμιμες Συναλλαγές

492 Απάτες

Ποσοστό Μειοψηφικής Κλάσης : 0.17%

IR $\approx$ 578:1



NSL-KDD (U2R)

67,343 Δείγματα Κανονικής Κίνησης

52 Δείγματα Επιθέσεων

Ποσοστό Μειοψηφικής Κλάσης : 0.08%

IR $\approx$ 1295:1

Πειραματική Διαδικασία (1/2)

Πειράματα σε Κεντριοποιημένο Περιβάλλον

Logistic Regression, XGBoost, MLP και
συνδυασμοί με SMOTE, ADASYN, Borderline-
SMOTE και GAN

Ισχυρά Σημεία Αναφοράς

Πειράματα σε Ομοσπονδιακό Περιβάλλον

Εκπαίδευση MLP σε Ομοσπονδιακό
Περιβάλλον υπο Συνθήκες IID Κατανομής και
Κλιμακούμενων Σενάριων Non-IID Κατανομής

Εφαρμογή Πλαισίου FedSMOTE

Ανάλυση Κόστους

Πειραματική Διαδικασία (2/2)

Μετρικές Αξιολόγησης

- ROC-AUC
- Average Precision
- F1-Score

Στατιστική Ετερογένεια

Κατανομή Dirichlet (Συντελεστής α):

- Ήπια ($\alpha = 1.0$)
- Υψηλή ($\alpha = 0.5$)
- Ακραία ($\alpha = 0.1$)


Ομοσπονδιακό Περιβάλλον

- Cross-Silo Σενάριο
- 5 Κόμβοι-Πελάτες
- 20 Γύροι Επικοινωνίας
- FedAvg

Αρχιτεκτονική Νευρωνικού Δικτύου

- ReLU, Batch Normalization, Dropout
- BCEWithLogitsLoss, Adam
- Αποθήκευση Βέλτιστου Μοντέλου


Αποτελέσματα: Credit Card Fraud Detection (1/2)



- Ποικίλλει η συνεισφορά των Συνθετικών Δεδομένων
- Την καλύτερη επίδοση σημειώνει ο συνδυασμός XGBoost με Συνθετικά Δεδομένα παραγόμενα από GAN
- Μέση Τιμή F1-Score 0,8662

Αποτελέσματα: Credit Card Fraud Detection (2/2)


Συγκριτική Αξιολόγηση Πλαισίου FedSMOTE
(Credit Card Fraud Detection Dataset)



- Η Στατιστική Ετερογένεια ρίχνει την επίδοση του μοντέλου και παρουσιάζει υψηλά επίπεδα αστάθειας.
- Client-Side SMOTE βοηθά, χωρίς να εξαλείφθει την αστάθεια σε υψηλή ετερογένεια.
- Trans-Client SMOTE βέλτιστη μέθοδος, ακόμα και σε δύσκολα σενάρια.

Αποτελέσματα: NSL-KDD (1/2)


Σύγκριση F1-Score της Μειοψηφικής Κλάσης Κεντριοποιημένων Μοντέλων



- Μεγαλύτερη σπανιότητα
- Μεγαλύτερη αστάθεια
- Συνθετικά Δεδομένα δεν συνεισφέρουν στην επίδοση

Αποτελέσματα: NSL-KDD (2/2)

Συγκριτική Αξιολόγηση Πλαισίου FedSMOTE
(NSL-KDD)



**Υπεροχή της Αρχιτεκτονικής
Trans-Client SMOTE**

Υπολογιστικό & Επικοινωνιακό Κόστος



Μέγεθος Μοντέλου

0.02 - 0.03 MB



Δικτυακή Κίνηση

3.81 - 5.96 MB (20 γύροι)



Χρονικό Κόστος

~2.2 δευτερόλεπτα (Μέγιστο)
0.24 δευτερόλεπτα (Ελάχιστο)

Η επιβάρυνση κρίνεται **αμελητέα** για Cross-Silo εφαρμογές.

Συμπεράσματα

- > Ανισορροπία Κλάσεων + Στατιστική Ετερογένεια = Κατάρρευση Ομοσπονδιακών Συστημάτων
- > FedSMOTE = Ενσωμάτωση Συνθετικών Δεδομένων σε Ομοσπονδιακά Περιβάλλοντα με ουσιαστικό τρόπο
- > Trans-Client SMOTE εγγυάται τα Καλύτερα Αποτελέσματα, ακόμα και σε δύσκολα σενάρια
- > FHE + CKKS επιτρέπουν συνεργατική παραγωγή Συνθετικών Δεδομένων, χωρίς διαρροή πληροφορίας

Ανοιχτά Ζητήματα

- > Τηλεπικοινωνιακή επιβάρυνση σε μεγαλύτερα μοντέλα.
- > Περιορισμοί του CKKS στη συνεχή τυχαία παρεμβολή.
- > Προκλήσεις σε συσκευές με περιορισμένους πόρους.

Μελλοντικές Επεκτάσεις

- > Ενσωμάτωση Borderline-SMOTE και ADASYN εξολοκλήρου σε κρυπτογραφημένο χώρο.
- > Υβριδικά μοντέλα ασφαλείας (FHE + Differential Privacy).
- > Ασύγχρονη Ομοσπονδιακή Μάθηση.
- > Επιτάχυνση υλικού.

Βιβλιογραφία

- > [18] McMahan et al., "Communication-Efficient Learning of Deep Networks from Decentralized Data", PMLR, 2017.
- > [22] Chawla et al., "SMOTE: Synthetic Minority Over-sampling Technique", JAIR, 2002.
- > [54] Gentry, "Fully Homomorphic Encryption using Ideal Lattices", STOC, 2009.
- > [56] Cheon et al., "Homomorphic Encryption for Arithmetic of Approximate Numbers", ASIACRYPT, 2017.
- > [21] Wang et al., "Addressing class imbalance in federated learning", AAAI, 2021.
- > [46] Japkowicz, Stephen, "The class imbalance problem: A systematic study", IDA, 2002.

Ευχαριστώ πολύ για την προσοχή σας!

Ερωτήσεις;

Ραφαήλ-Ανέστης Κωνσταντίνου

Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών Δ.Π.Θ.