



Δημοκρίτειο Πανεπιστήμιο Θράκης

Πολυτεχνική Σχολή

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Τομέας Λογισμικού και Ανάπτυξης Εφαρμογών

Εργαστήριο Προγραμματισμού και Επεξεργασίας Πληροφοριών

Συνθετικά Δεδομένα για Ισορροπία
Κλάσεων σε Περιβάλλοντα
Ομοσπονδιακής Μάθησης

Διπλωματική Εργασία

του

Ραφαήλ-Ανέστη Κωνσταντίνου

Επιβλέπων: Παύλος Εφραιμίδης

Καθηγητής Δ.Π.Θ.

Ιούλιος 2026



Democritus University of Thrace
School of Engineering
Department of Electrical and Computer Engineering
Sector of Software and Application Development
Laboratory of Programming and Information Processing

Synthetic Data for Class Imbalance Mitigation in Federated Learning Enviroments

Diploma Thesis
of
Rafail-Anestis Konstantinou

Supervisor: Pavlos Efraimidis

Professor at D.U.Th.

July 2026

Ευχαριστίες

Ολοκληρώνοντας την παρούσα διπλωματική εργασία θα ήθελα να ευχαριστήσω όλους όσους βοήθησαν και ενδιαφέρθηκαν προσωπικά για την επιτυχή ολοκλήρωση της.

Αρχικά, θα ήθελα να ευχαριστήσω ιδιαίτερα τον επιβλέποντα της εργασίας αυτής, τον καθηγητή κ. Παύλο Εφραιμίδη, για την εμπιστοσύνη του στο πρόσωπο μου να αναλάβω την ευθύνη εκπόνησης της παρούσας εργασίας. Πρόθυμος να ακούσει και να συζητήσουμε τον κάθε προβληματισμό που προέκυπτε και διατεθειμένος να παρέχει τις σκέψεις του και την αστείρευτη γνώση του ως αρωγή σε κάθε στάδιο εκπόνησης της εργασίας.

Ταυτόχρονα, θα ήθελα να ευχαριστήσω θερμά τον τότε υποψήφιο και νυν διδάκτορα Νικόλαο Παυλίδη για την καθοριστική του συνεισφορά σε όλη τη διάρκεια εκπόνησης της εργασίας. Πάντοτε πρόθυμος να συζητήσουμε κάθε λεπτομέρεια της εργασίας και ενδιασμό μου, ήταν εκεί με τις εξαιρετικές ιδέες του και τις εύστοχες παρατηρήσεις του για να ενθαρύνει και να κάνει πιο εύκολη τη διαδικασία εκπόνησης της εργασίας. Φροντίζοντας να με ανυψώσει ως μηχανικό και να μου παρέχει πολύτιμες γνώσεις, αποτέλεσε εξαιρετικό παράδειγμα προς μίμηση και υπήρξε σε κάθε περίπτωση ανώτερος των περιστάσεων και των προσδοκιών μου.

Τέλος, θα ήθελα να ευχαριστήσω από καρδιάς την οικογένεια και την κοπέλα μου που στάθηκαν στο πλευρό μου και ήταν εκεί να προσφέρουν την βοήθεια τους όταν την χρειαζόμουν. Θα ήθελα να ευχαριστήσω και κάθε άνθρωπο που εξέφρασε προσωπικό ενδιαφέρον για εμένα και το περιεχόμενο της εργασίας κατά την εκπόνηση της. Η εργασία αυτή αφιερώνεται σε αυτούς ως ελάχιστο δείγμα ευγνωμοσύνης.

Περίληψη

Η παρούσα Διπλωματική Εργασία επικεντρώνεται στη χρήση Συνθετικών Δεδομένων για την αντιμετώπιση του προβλήματος της μη ισορροπημένης κατανομής κλάσεων σε περιβάλλοντα Ομοσπονδιακής Μάθησης. Ενώ η Ομοσπονδιακή Μάθηση επιτρέπει την αποκεντρωμένη εκπαίδευση μοντέλων Μηχανικής Μάθησης, διασφαλίζοντας την ιδιωτικότητα ευαίσθητων δεδομένων, η ανομοιογένεια και η ανισορροπία των τοπικών δεδομένων κάθε συσκευής ή κόμβου, συχνά υποβαθμίζουν τη γενίκευση του συνολικού μοντέλου. Απώτερος σκοπός της παρούσας εργασίας αποτελεί η βελτίωση της απόδοσης των αποκεντρωμένων μοντέλων μέσω της τεχνητής ενίσχυσης υποεκπροσωπούμενων κατηγοριών δεδομένων.

Προς αυτήν την κατεύθυνση, προτείνεται η ενσωμάτωση της μεθόδου παραγωγής συνθετικών δεδομένων SMOTE (Synthetic Minority Over-sampling Technique). Συγκεκριμένα, εξετάζονται δύο βασικές προσεγγίσεις: η εφαρμογή του αλγορίθμου SMOTE τοπικά στα δεδομένα κάθε κόμβου, καθώς και η συνεργατική εφαρμογή του μεταξύ των κόμβων. Με σκοπό την απόλυτη διασφάλιση της ιδιωτικότητας κατά την παραγωγή και την μεταφορά των δεδομένων στο δίκτυο, υιοθετήθηκαν τεχνικές Πλήρους Ομομορφικής Κρυπτογράφησης, καθιστώντας δυνατή την εκτέλεση αριθμητικών υπολογισμών απευθείας σε κρυπτογραφημένα δεδομένα.

Το σύνολο των αρχιτεκτονικών υλοποίησης του αλγορίθμου SMOTE σε περιβάλλοντα Ομοσπονδιακής Μάθησης ορίζεται στην παρούσα εργασία με τον όρο FedSMOTE. Ο αλγόριθμος FedSMOTE αξιολογήθηκε ως προς την ακρίβεια των προβλέψεών του και το αντίστοιχο υπολογιστικό και επικοινωνιακό κόστος, μέσα από την προσομοίωση της χρήσης του σε διάφορα σενάρια κατανομής δεδομένων. Παράλληλα, έγινε χρήση συνδυασμών κεντριοποιημένων αλγορίθμων με διάφορες τεχνικές υπερδειγματοληψίας, για την αποσαφήνιση της επίδρασης των Συνθετικών Δεδομένων σε συνθήκες Ανισορροπίας Κλάσεων σε κεντριοποιημένο επίπεδο.

Λέξεις κλειδιά: Τεχνητή Νοημοσύνη, Μηχανική Μάθηση, Ομοσπονδιακή Μάθηση, Μη Ισορροπημένα Δεδομένα, Ανισορροπία Κλάσεων, Συνθετικά Δεδομένα, SMOTE, Πλήρως Ομομορφική Κρυπτογράφηση

Abstract

The present Diploma Thesis focuses on the use of Synthetic Data to address the problem of imbalanced class distribution in Federated Learning environments. While Federated Learning enables the decentralized training of Machine Learning models, ensuring the privacy of sensitive data, the heterogeneity and imbalance of local data across devices or nodes often degrade the generalization of the global model. The primary objective of this thesis is to improve the performance of decentralized models through the artificial enhancement of under-represented data categories.

Towards this end, the integration of the SMOTE (Synthetic Minority Over-sampling Technique) synthetic data generation method is proposed. Specifically, two main approaches are examined: the local application of the SMOTE algorithm on each node's data, and its collaborative application among nodes. In order to ensure absolute privacy during the generation and transmission of data within the network, Fully Homomorphic Encryption techniques were adopted, enabling numerical computations directly on encrypted data.

In this thesis, the set of implementation architectures for the SMOTE algorithm in Federated Learning environments is defined by the term FedSMOTE. The FedSMOTE algorithm was evaluated based on its prediction accuracy and the corresponding computational and communication costs through simulations across various data distribution scenarios. Furthermore, combinations of centralized algorithms and various oversampling techniques were utilized to clarify the impact of Synthetic Data under Class Imbalance conditions in centralized environments.

Keywords: Artificial Intelligence, Machine Learning, Federated Learning, Imbalanced Data, Class Imbalance, Synthetic Data, SMOTE, Fully Homomorphic Encryption

Συνθετικά Δεδομένα για Ισορροπία Κλάσεων σε
Περιβάλλοντα Ομοσπονδιακής Μάθησης
(Federated Learning)

Ραφαήλ-Ανέστης Κωνσταντίνου

Ιούλιος 2026

Περιεχόμενα

1	Εισαγωγή	7
1.1	Γενικά	7
1.2	Στόχος της διπλωματικής	9
1.3	Related work	10
1.4	Μεθοδολογία - Εργαλεία	10
1.5	Συνοπτικά Αποτελέσματα και Συμπεράσματα	11
1.6	Διάρθρωση της διπλωματικής	13
2	Θεωρητικό Υπόβαθρο	14
2.1	Μηχανική Μάθηση	14
2.1.1	Ορισμός	14
2.1.2	Κατηγορίες Μηχανικής Μάθησης	14
2.1.3	Ροή Εργασιών Μηχανικής Μάθησης	17
2.2	Αλγόριθμοι Ταξινόμησης	19
2.2.1	Λογιστική Παλινδρόμηση (Logistic Regression)	19
2.2.2	Extreme Gradient Boosting (XGBoost)	19
2.2.3	Τεχνητά Νευρωνικά Δίκτυα	20
2.3	Ανισορροπία Κλάσεων	23
2.3.1	Φύση του Προβλήματος	23
2.3.2	Τεχνικές Υπερδειγματοληψίας	25
2.4	Ομοσπονδιακή Μάθηση	28
2.4.1	Ορισμός και Βασική Λειτουργία	28
2.4.2	Ταξινόμηση Συστημάτων Ομοσπονδιακής Μάθησης	28
2.4.3	Ο Αλγόριθμος Federated Averaging (FedAvg)	30
2.4.4	Οφέλη και Πλεονεκτήματα της Ομοσπονδιακής Μάθησης	31
2.4.5	Προκλήσεις και Περιορισμοί της Ομοσπονδιακής Μάθησης	32
2.5	Πλήρως Ομομορφική Κρυπτογράφηση	33
2.5.1	Μαθηματικός Ορισμός και Ιδιότητες	33
2.5.2	Το Σχήμα CKKS	34

3 Μεθοδολογία και Υλοποίηση	36
3.1 Παρουσίαση Συνόλων Δεδομένων	36
3.1.1 Σύνολο Δεδομένων Ανίχνευσης Χρηματοοικονομικής Απάτης (Credit Card Fraud Detection Dataset)	36
3.1.2 Σύνολο Δεδομένων NSL-KDD (User-to-Root Attacks)	37
3.2 Μετρικές Αξιολόγησης	38
3.2.1 Πίνακας Σύγχυσης (Confusion Matrix)	40
3.2.2 Precision, Recall, F1-Score	40
3.2.3 Καμπύλες Επίδοσης (ROC-AUC & Average Precision)	42
3.3 Αρχιτεκτονική Νευρωνικών Δικτύων	46
3.3.1 MLP	46
3.3.2 GAN	49
3.4 Ομοσπονδιακό Περιβάλλον	50
3.4.1 Ομοσπονδιακή Αρχιτεκτονική και Πρωτόκολλο Εκπαίδευσης & Αξιολόγησης	50
3.4.2 Στρατηγικές Κατανομής Δεδομένων	53
3.5 FedSMOTE	55
3.5.1 Client-Side SMOTE	55
3.5.2 Trans-Client SMOTE	56
3.6 Πειραματικό Περιβάλλον και Διαδικασία	58
4 Πειραματική Αξιολόγηση	62
4.1 Πειραματικά Αποτελέσματα από το Σύνολο Δεδομένων Credit Card Fraud Detection	63
4.1.1 Αξιολόγηση Μοντέλων σε Κεντριοποιημένο Περιβάλλον	63
4.1.2 Αξιολόγηση Ομοσπονδιακής Μάθησης	67
4.1.3 Αξιολόγηση του Πλαισίου FedSMOTE	70
4.1.4 Υπολογιστική Επιβάρυνση και Κόστος Επικοινωνίας	71
4.2 Πειραματικά Αποτελέσματα από το Σύνολο Δεδομένων NSL-KDD (U2R Attacks)	74
4.2.1 Αξιολόγηση Μοντέλων σε Κεντριοποιημένο Περιβάλλον	74
4.2.2 Αξιολόγηση Ομοσπονδιακής Μάθησης	78
4.2.3 Αξιολόγηση του Πλαισίου FedSMOTE	79
4.2.4 Υπολογιστική Επιβάρυνση και Κόστος Επικοινωνίας	83
5 Συμπεράσματα, Ανοιχτά Ζητήματα και Μελλοντικές Επεκτάσεις	85
5.1 Σύνοψη και Βασικά Συμπεράσματα	85
5.2 Ανοιχτά Ζητήματα	86
5.3 Μελλοντικές Επεκτάσεις	87

Κατάλογος Πινάκων

4.1	Κεντρικοποιημένα Πειράματα στο Σύνολο Δεδομένων Credit Card Fraud Detection	63
4.2	Πειράματα Απλής Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων Credit Card Fraud Detection	67
4.3	Πειράματα Πλαισίου Fed-SMOTE στο Σύνολο Δεδομένων Credit Card Fraud Detection	70
4.4	Κεντρικοποιημένα Πειράματα στο Σύνολο Δεδομένων NSL-KDD (U2R Attacks)	74
4.5	Πειράματα Απλής Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων NSL-KDD (U2R Attacks)	78
4.6	Πειράματα Πλαισίου Fed-SMOTE στο Σύνολο Δεδομένων NSL-KDD (U2R Attacks)	80

Κατάλογος Σχημάτων

2.1	Είδη Μηχανικής Μάθησης [1]	15
2.2	Διάγραμμα Ροής Δεδομένων Επιβλεπόμενης Μάθησης [2]	16
2.3	Διάγραμμα Ροής Δεδομένων Μη Επιβλεπόμενης Μάθησης [3]	16
2.4	Διάγραμμα Ροής Δεδομένων Ενισχυτικής Μάθησης [4]	17
2.5	Ροή Εργασιών Μηχανικής Μάθησης [5]	18
2.6	Λογιστική Παλινδρόμηση [5]	20
2.7	XGBoost [6]	21
2.8	Σύγκριση Βιολογικού και Τεχνητού Νευρώνα [6]	21
2.9	Αρχιτεκτονική και Επίπεδα ενός MLP [7]	22
2.10	Γεννητικό Ανταγωνιστικό Δίκτυο (GAN) [8]	23
2.11	Ανισορροπία Κλάσεων [9]	24
2.12	Υπερδειγματοληψία [10]	25
2.13	Αλγόριθμος SMOTE [11]	26
2.14	Παράδειγμα Ομοσπονδιακής Μάθησης [12]	29
2.15	Σύγκριση Cross-device και Cross-silo Ομοσπονδιακής Μάθησης [13]	30
2.16	Διάγραμμα Πλήρως Ομομορφικής Κρυπτογράφησης [14]	34
3.1	Ανισορροπία Κλάσεων στο Σύνολο Credit Card Fraud Detection	37
3.2	Ανισορροπία Κλάσεων στο Σύνολο NSL-KDD	39
3.3	Παράδειγμα Πίνακα Σύγκρισης στο Σύνολο Credit Card Fraud Detection	41
3.4	Παράδειγμα Καμπύλης ROC στο Σύνολο Credit Card Fraud Detection	44
3.5	Παράδειγμα Καμπύλης Precision-Recall στο Σύνολο Credit Card Fraud Detection	45
3.6	Αναπαράσταση Προσέγγισης Client-Side SMOTE	56
3.7	Αναπαράσταση Προσέγγισης Trans-Client SMOTE - Μέρος 1ο	59
3.8	Αναπαράσταση Προσέγγισης Trans-Client SMOTE - Μέρος 2ο	59
4.1	Ραβδόγραμμα Μετρικής F1-Score της Μειοψηφικής Κλάσης για τα Κεντρικοποιημένα Πειράματα	63
4.2	Πίνακες Σύγκρισης για Καλύτερες Εκτελέσεις Logistic Regression και XGBoost	64

4.3 Σύγκριση Καμπύλης Precision-Recall για Καλύτερες Εκτελέσεις XGBoost και XGBoost + GAN	66
4.4 Σύγκριση Πινάκων Σύγχησης για Καλύτερες Εκτελέσεις Κεντριοποιημένου MLP και MLP + SMOTE	68
4.5 Διάγραμμα Γραμμής Πορείας F1-Score σε Πειράματα Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων Credit Card Fraud Detection	69
4.6 Ραβδόγραμμα Συγκριτικής Αξιολόγησης Πλαισίου FedSMOTE στο Σύνολο Δεδομένων Credit Card Fraud Detection	72
4.7 Πορεία Εξέλιξης Τιμής F1-Score Μειοψηφικής Κλάσης ανά Γύρο Επικοινωνίας. Στιγμιότυπο από Καλύτερη Εκτέλεση Αρχιτεκτονικής Trans-Client SMOTE για Υψηλή Στατιστική Ετερογένεια ($\alpha = 0.5$) στο Σύνολο Δεδομένων Credit Card Fraud Detection	72
4.8 Ραβδόγραμμα Μετρικής F1-Score της Μειοψηφικής Κλάσης για τα Κεντριοποιημένα Πειράματα	75
4.9 Πίνακες Σύγχυσης για Καλύτερες Εκτελέσεις Logistic Regression και XGBoost	76
4.10 Καμπύλη Precision-Recall για Καλύτερη Εκτέλεση XGBoost	77
4.11 Διάγραμμα Γραμμής Πορείας F1-Score σε Πειράματα Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων NSL-KDD	80
4.12 Ραβδόγραμμα Συγκριτικής Αξιολόγησης Πλαισίου FedSMOTE στο Σύνολο Δεδομένων NSL-KDD	82
4.13 Πορεία Εξέλιξης Τιμής F1-Score Μειοψηφικής Κλάσης ανά Γύρο Επικοινωνίας. Στιγμιότυπο από Καλύτερη Εκτέλεση Αρχιτεκτονικής Trans-Client SMOTE για Ακραία Στατιστική Ετερογένεια ($\alpha = 0.1$) στο Σύνολο Δεδομένων NSL-KDD	82

Κεφάλαιο 1

Εισαγωγή

1.1 Γενικά

Στις μέρες μας, οι τεχνικές της Τεχνητής Νοημοσύνης και της Μηχανικής Μάθησης βρίσκουν πληθώρα εφαρμογών σε τομείς της καθημερινής και κοινωνικοοικονομικής πραγματικότητας, με χαρακτηριστικά παραδείγματα τον χρηματοοικονομικό τομέα, την υγειονομική περίθαλψη, τη βιομηχανία, την κυβερνοασφάλεια και τις μεταφορές [15]. Ωστόσο, η ραγδαία εξέλιξη της Τεχνητής Νοημοσύνης και η επακόλουθη εκθετική αύξηση των δεδομένων που παράγονται καθημερινά από δισεκατομμύρια συσκευές, από έξυπνα κινητά τηλέφωνα έως κεντρικούς διακομιστές και δίκτυα του Διαδικτύου των Πραγμάτων, έχουν επιφέρει ριζικές αλλαγές στη σύγχρονη ανάλυση δεδομένων. Παραδοσιακά, η υλοποίηση ισχυρών μοντέλων πρόβλεψης, τα οποία βασίζονται στη Μηχανική Μάθηση, συνεπάγεται τη συγκέντρωση τεράστιων όγκων ακατέργαστων δεδομένων σε κεντρικούς υπολογιστικούς διακομιστές. Ενώ αυτή η προσέγγιση παρέχει άμεση πρόσβαση στο σύνολο της πληροφορίας και διευκολύνει την εκπαίδευση των μοντέλων, εγείρει, ωστόσο, σημαντικά ζητήματα ιδιωτικότητας για τους τελικούς χρήστες. Η συγκέντρωση ευαίσθητων προσωπικών πληροφοριών, όπως ιατρικοί φάκελοι ή χρηματοοικονομικές συναλλαγές, σε μια κεντρική τοποθεσία ενέχει σημαντικούς κινδύνους για την ασφάλεια και παραβιάζει θεμελιώδη δικαιώματα ιδιωτικότητας, υπονομεύοντας την τήρηση αυστηρών ρυθμιστικών πλαισίων, όπως ο Γενικός Κανονισμός για την Προστασία Δεδομένων (GDPR) [16].

Η Ομοσπονδιακή Μάθηση (Federated Learning) έχει αναδειχθεί τα τελευταία χρόνια ως μια επαναστατική τεχνική αποκεντρωμένης εκπαίδευσης μοντέλων Μηχανικής Μάθησης. Σε αυτό το πλαίσιο, πολλαπλοί πελάτες, είτε μεμονωμένες συσκευές είτε ολόκληροι οργανισμοί, όπως επιχειρήσεις και τραπεζικά ιδρύματα, συνεργάζονται για την εκπαίδευση ενός κοινού global μοντέλου, χωρίς να απαιτείται η ανταλλαγή των τοπικών δεδομένων τους [17] [18].

Σε περιβάλλοντα Ομοσπονδιακής Μάθησης, ωστόσο, τα δεδομένα εγγενώς δεν μπορούν να ομαδοποιηθούν ώστε να ακολουθούν Ανεξάρτητη και Πανομοιότυπη Κατανομή (I-ID). Κύριοι παράγοντες της στατιστικής ετερογένειας σε περιβάλλοντα Ομοσπονδιακής Μάθησης αποτελούν η αδυναμία ελέγχου του κεντρικού διακομιστή επί των τοπικών δεδομένων, καθώς και η τάση των κόμβων να παράγουν ανεξάρτητα δεδομένα. Τα χαρακτηριστικά της τοπικής συλλογής δεδομένων κάθε κόμβου-πελάτη εξαρτώνται σε μεγάλο βαθμό από τις ιδιαίτερες συνθήκες, τη γεωγραφική τοποθεσία ή ακόμη και το πλαίσιο λειτουργίας κάθε κόμβου [19].

Κεντρικό ρόλο στο πρόβλημα της στατιστικής ετερογένειας διαδραματίζει η Ανισορροπία Κλάσεων. Η Ανισορροπία Κλάσεων αποτελεί το φαινόμενο κατά το οποίο η κατανομή των δειγμάτων εκπαίδευσης μεταξύ διαφορετικών κλάσεων καθίσταται σημαντικά άνιση ή ασύμμετρη. Συγκεκριμένα, η πλειοψηφική κλάση του συνόλου περιέχει συντριπτικά μεγαλύτερο αριθμό δειγμάτων από τις υπόλοιπες μειονοτικές κλάσεις. Στον πραγματικό κόσμο, η Ανισορροπία Κλάσεων αποτελεί συχνά εγγενή ιδιότητα συνόλων δεδομένων, όπου το προς ανίχνευση συμβάν αποτελεί σπάνια περίπτωση, αλλά ταυτόχρονα υψίστης σημασίας από επιχειρησιακής ή/και επιστημονικής άποψης. Χαρακτηριστικά παραδείγματα αποτελούν η ανίχνευση χρηματοοικονομικής απάτης και η αναγνώριση κυβερνοεπιθέσεων, εφόσον οι κακόβουλες συναλλαγές ή οι δικτυακές εισβολές αποτελούν ελάχιστο κλάσμα του συνόλου των περιπτώσεων, ωστόσο η έγκαιρη ανίχνευσή τους αποτελεί απόλυτη προτεραιότητα [20].

Σε περιβάλλοντα Ομοσπονδιακής Μάθησης, το πρόβλημα της Ανισορροπίας Κλάσεων λαμβάνει διττή μορφή, ως ενδο-κομβική και δια-κομβική ανισορροπία. Η ενδο-κομβική ανισορροπία αφορά την άνιση κατανομή των τοπικών δειγμάτων ενός μεμονωμένου κόμβου, όπου μπορεί ακόμη και να απουσιάζουν δείγματα από μία κλάση. Αντίστοιχα, η δια-κομβική ανισορροπία αφορά την ανομοιογένεια της κατανομής των κλάσεων μεταξύ διαφορετικών πελατών στο δίκτυο. Συγκεκριμένα, τα τοπικά δείγματα κάποιου κόμβου μπορεί να αποτελούνται αποκλειστικά από την πλειοψηφική κλάση, ενώ το σύστημα στο σύνολό του να διαθέτει διαφορετική αναλογία [21].

Το πολυδιάστατο αυτό πρόβλημα οδηγεί άμεσα στην υποβάθμιση, ή ακόμη και στην κατάρρευση, της απόδοσης των αποκεντρωμένων μοντέλων και της ικανότητάς τους να γενικεύουν σε νέα, άγνωστα δεδομένα. Τα μοντέλα που εκπαιδεύονται τοπικά πάνω σε μη ισορροπημένα δεδομένα καθίστανται έντονα μεροληπτικά υπέρ της πλειοψηφικής κλάσης. Οι αλγόριθμοι ταξινόμησης στοχεύουν στη βελτιστοποίηση μιας συνάρτησης απώλειας που εφαρμόζεται σε ολόκληρο το σύνολο εκπαίδευσης. Έτσι, ως προτεραιότητα τίθεται η σωστή πρόβλεψη της πλειοψηφικής κλάσης και η αντιμετώπιση της μειονοτικής κλάσης ως θορύβου. Ταυτόχρονα, σε αποκεντρωμένα περιβάλλοντα, ο ρυθμός με τον οποίο το παγκόσμιο μοντέλο μαθαίνει για μια πλειοψηφική κλάση είναι μεγα-

λύτερος σε σχέση με μια μειονοτική, λόγω των ενημερώσεων που αποστέλλονται, με αποτέλεσμα το μοντέλο να ταξινομεί υπέρ της πλειοψηφικής κλάσης [21].

Στην κεντριοποιημένη Μηχανική Μάθηση, ο χρυσός κανόνας για την αποτελεσματική αντιμετώπιση της Ανισορροπίας Κλάσεων είναι η χρήση Συνθετικών Δεδομένων μέσω τεχνικών υπερδειγματοληψίας, όπως ο αλγόριθμος SMOTE (Synthetic Minority Over-sampling Technique). Κύρια λειτουργία του αλγορίθμου SMOTE είναι η δημιουργία νέων, συνθετικών δειγμάτων της μειοψηφικής κλάσης μέσω παρεμβολής στον χώρο των χαρακτηριστικών [22].

Ωστόσο, λόγω των περιορισμών ιδιωτικότητας που επιφέρει η Ομοσπονδιακή Μάθηση, ο κεντρικός διακομιστής αδυνατεί και απαγορεύεται να έχει πρόσβαση στα δεδομένα των πελατών του, με αποτέλεσμα οι κλασικές τεχνικές υπερδειγματοληψίας να καθίστανται ανεφάρμοστες και να εισάγονται τεχνικά και ηθικά διλήμματα ως προς την αυτούσια μεταφορά τους. Συγκεκριμένα, η διαδικασία παρεμβολής του αλγορίθμου SMOTE απαιτεί πρόσβαση στα δείγματα της μειοψηφικής κλάσης για την εξαγωγή των στατιστικών τους ιδιοτήτων και τα παραγόμενα συνθετικά δείγματα καθίστανται ικανά να διαρρεύσουν πληροφορίες για τα αρχικά ακατέργαστα δεδομένα μέσω ειδικά σχεδιασμένων επιθέσεων [23]. Καθίσταται πλέον προφανές ότι η εφαρμογή του αλγορίθμου SMOTE σε δια-κομβικό επίπεδο απαιτεί επιπρόσθετες κρυπτογραφικές εγγυήσεις, με σκοπό την καλύτερη προστασία των δεδομένων που πραγματεύεται η Ομοσπονδιακή Μάθηση.

1.2 Στόχος της διπλωματικής

Στο πλαίσιο της παρούσας διπλωματικής εργασίας ορίζεται ο όρος **FedSMOTE**. Το πλαίσιο FedSMOTE προκύπτει από την ανάγκη για συνεργατική υπερδειγματοληψία, σε συνδυασμό με την απαίτηση για μηδενική διαρροή πληροφορίας, με στόχο τη βελτίωση της απόδοσης των αποκεντρωμένων μοντέλων.

Ακολουθούνται δύο βασικές προσεγγίσεις:

1. Client-Side SMOTE: Η εφαρμογή του αλγορίθμου SMOTE τοπικά στα δεδομένα κάθε κόμβου-πελάτη.

2. Trans-Client SMOTE: Η συνεργατική και δια-κομβική εφαρμογή του αλγορίθμου SMOTE στο σύνολο των δεδομένων με χρήση τεχνικών Πλήρους Ομομορφικής Κρυπτογράφησης.

Παράλληλα, για σκοπούς σύγκρισης και αξιολόγησης, εξετάζεται η επίδραση συνδυασμών αλγορίθμων (Logistic Regression, XGBoost, Multi-Layer Perceptron) με βασικές τεχνικές παραγωγής συνθετικών δεδομένων (SMOTE, ADASYN, Borderline-SMOTE,

GAN-Based Generation) στην απόδοση των μοντέλων σε κεντριοποιημένο επίπεδο.

1.3 Related work

Το σύγχρονο επιστημονικό ενδιαφέρον γύρω από την αντιμετώπιση του προβλήματος της ανισορροπίας κλάσεων σε αποκεντρωμένα συστήματα ομαδοποιεί τις προτεινόμενες λύσεις σε μεθόδους επιπέδου αλγορίθμου και σε μεθόδους επιπέδου δεδομένων. Οι μέθοδοι επιπέδου αλγορίθμου στοχεύουν στον ανασχεδιασμό των συναρτήσεων απώλειας, του ρυθμού εκμάθησης και των πρωτοκόλλων επιλογής πελατών, καθώς και στην ενσωμάτωση ευαισθησίας ως προς το κόστος, με την απόδοση μεγαλύτερων ποινών σε σφάλματα ταξινόμησης της μειοψηφικής κλάσης. Ταυτόχρονα, οι μέθοδοι επιπέδου δεδομένων επιχειρούν να τροποποιήσουν την κατανομή των δεδομένων μέσω τεχνικών υπερδειγματοληψίας ή υποδειγματοληψίας [20].

Παράλληλα, μελέτες αποδεικνύουν πως η στατιστική ετερογένεια των δεδομένων ενέχει καταστροφικό αντίκτυπο στη σύγκλιση της Ομοσπονδιακής Μάθησης. Συγκεκριμένα, οι ενημερώσεις του μοντέλου μετατοπίζουν τα περιθώρια απόφασης του αλγορίθμου υπέρ των δεδομένων με το μεγαλύτερο πλήθος, με αποτέλεσμα την αγνόηση των χαρακτηριστικών της μειοψηφικής κλάσης και την επιδείνωση της ικανότητας του μοντέλου να ταξινομεί σωστά τα δείγματά της [24].

Όσον αφορά την ένταξη του αλγορίθμου παραγωγής Συνθετικών Δεδομένων SMOTE στο πλαίσιο της Ομοσπονδιακής Μάθησης, έχουν πραγματοποιηθεί αρκετές μελέτες σχετικά με την τοπική εφαρμογή του και έχουν γίνει προσπάθειες για τη συνεργατική του υλοποίηση. Συγκεκριμένα, υπάρχουν μελέτες όπου ο αλγόριθμος SMOTE έχει εφαρμοστεί μόνο σε τοπικό επίπεδο, εντός των δεδομένων κάθε κόμβου-πελάτη [25], καθώς και σε συνδυασμό με Διαφορική Ιδιωτικότητα [26] ή με μια παραλλαγή του αλγορίθμου SMOTE με ευαισθησία στην πυκνότητα των τοπικών δεδομένων [27], με υποσχόμενα αποτελέσματα. Ταυτόχρονα, υπάρχουν μελέτες για τη συνεργατική υλοποίηση του αλγορίθμου SMOTE με χρήση Gaussian Mixture Models [28], καθώς και μια πολύ πρόσφατη ερευνητική προσπάθεια με χρήση Πλήρως Ομομορφικής Κρυπτογράφησης σε περιπτώσεις όπου οι κόμβοι-πελάτες διαθέτουν διαφορετικό χώρο χαρακτηριστικών για τον ίδιο πληθυσμό [29].

1.4 Μεθοδολογία - Εργαλεία

Για την υλοποίηση των πειραμάτων έγινε χρήση της γλώσσας προγραμματισμού Python και των αντίστοιχων βιβλιοθηκών της που προορίζονται για Μηχανική Μάθηση, Ανισορροπία Κλάσεων και Πλήρως Ομομορφική Κρυπτογράφηση.

PyTorch [30]: Βιβλιοθήκη της Python που χρησιμοποιήθηκε για την υλοποίηση των Τεχνητών Νευρωνικών Δικτύων που χρησιμοποιήθηκαν στα πειράματα της εργασίας. Αναπτύχθηκε από την ομάδα ανάπτυξης του Facebook και προορίζεται για ερευνητικές και εμπορικές χρήσεις, ξεχωρίζοντας για την ευκολία και την απλότητα στη χρήση της.

Scikit-Learn [31]: Βιβλιοθήκη της Python που παρέχει έτοιμα εργαλεία για τους σκοπούς της Μηχανικής Μάθησης. Συγκεκριμένα, για τους σκοπούς της εργασίας χρησιμοποιήθηκαν έτοιμες και βελτιστοποιημένες υλοποιήσεις αλγορίθμων ταξινόμησης (Logistic Regression), καθώς και εργαλεία για σκοπούς προεπεξεργασίας (Standard Scaler, Train Test Split). Παράλληλα, έγινε εξαγωγή χρήσιμων μετρικών για την τελική αξιολόγηση της απόδοσης των μοντέλων (ROC-AUC, Average Precision, F1-Score).

Imbalanced-Learn [32]: Αποτελεί προέκταση του οικοσυστήματος της Scikit-Learn για την αντιμετώπιση του προβλήματος της Ανισορροπίας Κλάσεων στη Μηχανική Μάθηση. Για τους σκοπούς της εργασίας αξιοποιήθηκαν οι έτοιμες και βελτιστοποιημένες υλοποιήσεις των τεχνικών υπερδειγματοληψίας (SMOTE, ADASYN, Borderline-SMOTE).

TenSEAL [33]: Βιβλιοθήκη της Python που προορίζεται για τη σύνδεση της Μηχανικής Μάθησης με τις δυνατότητες της Ομομορφικής Κρυπτογράφησης. Συγκεκριμένα, για τους σκοπούς της εργασίας χρησιμοποιήθηκε η Πλήρως Ομομορφική Κρυπτογράφηση και το σχήμα CKKS για την εκτέλεση πράξεων πάνω σε κρυπτογραφημένα δεδομένα και την τελική υλοποίηση της προσέγγισης Trans-Client SMOTE.

Λοιπές βιβλιοθήκες που χρησιμοποιήθηκαν για τους σκοπούς της εργασίας ήταν η xgboost για την εισαγωγή του ομώνυμου αλγορίθμου, η NumPy για την εκτέλεση αριθμητικών πράξεων, οι Matplotlib και Seaborn για την οπτικοποίηση χρήσιμων διαγραμμάτων και η time για τον υπολογισμό της χρονικής επιβάρυνσης των κρυπτογραφικών υπολογισμών.

Ταυτόχρονα, λόγω της φύσης των δεδομένων, η εργασία επικεντρώνεται σε Cross-Silo Ομοσπονδιακή Μάθηση, όπου οι κόμβοι-πελάτες αντιστοιχούν σε οργανισμούς, είναι περιορισμένοι σε αριθμό και διαθέτουν μεγάλη υπολογιστική ισχύ και έμπιστα κανάλια επικοινωνίας.

1.5 Συνοπτικά Αποτελέσματα και Συμπεράσματα

Για τους σκοπούς της εργασίας χρησιμοποιούνται δύο διαφορετικά σύνολα δεδομένων που παρουσιάζουν ακραία ανισορροπία (0,17% και 0,07% ποσοστό της μειοψηφικής κλάσης αντίστοιχα), σε συνδυασμό με 10 διαφορετικά seeds για τον διαμοιρασμό των

δεδομένων και τον υπολογισμό της μέσης τιμής και της τυπικής απόκλισης χρήσιμων μετρικών, με στόχο την αντικειμενική εξαγωγή συμπερασμάτων.

Αρχικά, η εργασία αυτή πραγματοποιείται με τη συνεισφορά δημοφιλών τεχνικών υπερδιδασκαλίας στην απόδοση ταξινόμησης δημοφιλών αλγορίθμων Μηχανικής Μάθησης σε κεντρικοποιημένο περιβάλλον. Συγκεκριμένα, χρησιμοποιήθηκαν οι αλγόριθμοι Logistic Regression και XGBoost τόσο αυτόνομα όσο και σε συνδυασμό με τις τεχνικές SMOTE, ADASYN, Borderline-SMOTE. Παράλληλα, δοκιμάστηκε μια χειροκίνητη υλοποίηση του αλγορίθμου SMOTE, καθώς και η αξιοποίηση ενός Παραγωγικού Ανταγωνιστικού Δικτύου (GAN). Τα πειράματα αυτά είχαν ανάμεικτα αποτελέσματα, τα οποία εξαρτώνται από τη φύση των δεδομένων.

Έπειτα, στο κύριο μέρος της εργασίας, πραγματοποιήθηκε η ενσωμάτωση του αλγορίθμου SMOTE σε περιβάλλον Ομοσπονδιακής Μάθησης. Ως πρώτο βήμα, υλοποιήθηκε ένα Multi-Layer Perceptron (MLP) και αξιολογήθηκε η απόδοσή του, τόσο από μόνο του όσο και σε συνδυασμό με τον αλγόριθμο SMOTE, ως ένα βασικό σημείο αναφοράς σε κεντρικοποιημένο περιβάλλον. Επόμενο σημείο αναφοράς υπήρξε η υλοποίηση ενός περιβάλλοντος Ομοσπονδιακής Μάθησης και η αξιολόγηση της απόδοσης του MLP σε συνθήκες IID κατανομής των δεδομένων, καθώς και σε διαφορετικά επίπεδα Non-IID κατανομής. Ακολουθώντας την ίδια λογική, πραγματοποιήθηκαν τα πειράματα τοπικής εφαρμογής του αλγορίθμου SMOTE (Client-Side SMOTE) και της συνεργατικής του εφαρμογής (Trans-Client SMOTE). Για τη συνεργατική υλοποίηση αξιοποιήθηκαν τεχνικές Πλήρους Ομομορφικής Κρυπτογράφησης, προκειμένου να διασφαλιστεί η ιδιωτικότητα των δεδομένων. Ταυτόχρονα, υπολογίστηκαν το μέγεθος του μοντέλου, η συνολική επιβάρυνση στην κίνηση του δικτύου και η χρονική επιβάρυνση των κρυπτογραφικών υπολογισμών.

Τα αποτελέσματα υπήρξαν άκρως υποσχόμενα, καθώς για το πρώτο σύνολο δεδομένων (0,17% ποσοστό μειοψηφικής κλάσης), η συνεργατική υλοποίηση σε IID κατανομή ξεπέρασε οριακά την απόδοση του πειράματος απλής Ομοσπονδιακής Μάθησης, χωρίς ωστόσο να φτάσει το επίπεδο του κεντρικοποιημένου MLP, ενώ παράλληλα ξεπέρασε κατά πολύ την απόδοση σε όλα τα Non-IID επίπεδα. Ταυτόχρονα, για το δεύτερο σύνολο δεδομένων (0,07% ποσοστό μειοψηφικής κλάσης), η συνεργατική υλοποίηση σε IID κατανομή ξεπέρασε κατά πολύ το πείραμα της απλής Ομοσπονδιακής Μάθησης και του κεντρικοποιημένου MLP. Επιπλέον, σε κάθε επίπεδο στατιστικής ετερογένειας, το Trans-Client SMOTE σημείωσε πολύ καλύτερη απόδοση από το πείραμα απλής Ομοσπονδιακής Μάθησης. Έτσι, εξάγεται το συμπέρασμα ότι η υλοποίηση Trans-Client SMOTE βοήθησε σε κάθε περίπτωση το μοντέλο να εξαγάγει συσχετίσεις μεταξύ των δεδομένων που δεν θα μπορούσε να εντοπίσει με διαφορετικό τρόπο, καθώς και να γενικεύει καλύτερα στα δεδομένα της μειοψηφικής κλάσης, αγνοώντας ταυτόχρονα

πιθανά σφάλματα που θα μπορούσε να εισαγάγει η διαδικασία της κρυπτογράφησης στους υπολογισμούς.

1.6 Διάρθρωση της διπλωματικής

Η παρούσα διπλωματική εργασία είναι οργανωμένη σε πέντε Κεφάλαια και τη Βιβλιογραφία.

Στο πρώτο Κεφάλαιο, που αποτελεί την Εισαγωγή, παρουσιάζεται το γενικό πλαίσιο της εργασίας, το κίνητρο πίσω από αυτήν και οι στόχοι της έρευνας. Παράλληλα, γίνεται ανασκόπηση της σχετικής βιβλιογραφίας και παρατίθενται η τεχνολογική υποδομή που χρησιμοποιήθηκε, καθώς και τα συνοπτικά αποτελέσματα και συμπεράσματα που εξήχθησαν.

Στο δεύτερο Κεφάλαιο, που αποτελεί το Θεωρητικό Υπόβαθρο, πραγματοποιείται η ανάλυση των θεμελιωδών εννοιών που αποτελούν τη βάση της εργασίας.

Στο τρίτο Κεφάλαιο, το οποίο αφορά την Μεθοδολογία και την Υλοποίηση, παρατίθεται η πλήρης διάταξη της έρευνας. Αρχικά, παρουσιάζονται τα σύνολα δεδομένων που αξιοποιήθηκαν και ορίζονται οι εξειδικευμένες μετρικές αξιολόγησης. Στη συνέχεια, αναλύονται οι αρχιτεκτονικές των νευρωνικών δικτύων και περιγράφεται λεπτομερώς το ομοσπονδιακό περιβάλλον που αναπτύχθηκε. Κεντρικός άξονας αποτελεί η διεξοδική παρουσίαση του προτεινόμενου πλαισίου FedSMOTE, ενώ η ενότητα ολοκληρώνεται με την παράθεση του πειραματικού περιβάλλοντος και της ακολουθούμενης διαδικασίας.

Στο τέταρτο Κεφάλαιο, παρουσιάζονται και αναλύονται συστηματικά τα Πειραματικά Αποτελέσματα. Πραγματοποιείται εκτενής συγκριτική αξιολόγηση της απόδοσης των μοντέλων σε κεντρικοποιημένες και ομοσπονδιακές διατάξεις υπό διαφορετικά σενάρια στατιστικής ετερογένειας. Ταυτόχρονα, αποτιμάται η αποτελεσματικότητα του πλαισίου FedSMOTE στην ανάκτηση της προγνωστικής ικανότητας των παγκόσμιων μοντέλων και αναλύεται το υπολογιστικό και τηλεπικοινωνιακό κόστος που επιφέρει η κρυπτογραφική του υλοποίηση.

Στο πέμπτο και τελευταίο Κεφάλαιο, πραγματοποιείται η τελική Σύνοψη της διπλωματικής και εξάγονται τα κύρια Συμπεράσματα. Επιπρόσθετα, επισημαίνονται οι εγγενείς περιορισμοί και τα Ανοιχτά Ζητήματα που προέκυψαν από την πειραματική μελέτη, οδηγώντας σε προτεινόμενες κατευθύνσεις για Μελλοντικές Επεκτάσεις στο πεδίο της αποκεντρωμένης και ασφαλούς Μηχανικής Μάθησης.

Κεφάλαιο 2

Θεωρητικό Υπόβαθρο

2.1 Μηχανική Μάθηση

2.1.1 Ορισμός

Η Μηχανική Μάθηση αποτελεί νευραλγικό κλάδο της Επιστήμης των Υπολογιστών και κατεπέκταση της Τεχνητής Νοημοσύνης. Η Μηχανική Μάθηση επικεντρώνεται στην ανάπτυξη υπολογιστικών συστημάτων και αλγορίθμων που έχουν την ικανότητα βελτίωσης της απόδοσής τους σε μια συγκεκριμένη εργασία, αντλώντας γνώση μέσα από τα δεδομένα, παραλείποντας την απαίτηση ρητού προγραμματισμού της κάθε ενέργειας. Ο Tom Mitchell παρέθεσε τον πλέον καθιερωμένο και μαθηματικά αυστηρό ορισμό της Μηχανικής Μάθησης [34]:


Ένα υπολογιστικό πρόγραμμα λέγεται ότι μαθαίνει από την εμπειρία E σε σχέση με κάποια κατηγορία εργασιών T και ένα μέτρο απόδοσης P , αν η απόδοση του στις εργασίες της T , όπως αποτιμάται από το μέτρο P , βελτιώνεται με την εμπειρία E .

Σήμερα, η Μηχανική Μάθηση αντιμετωπίζεται και ως η επιστήμη της βελτιστοποίησης στοχαστικών μοντέλων πάνω σε μεγάλους όγκους δεδομένων, βρίσκοντας εφαρμογές στην αναγνώριση ομιλίας, στην οπτική αναγνώριση αντικειμένων, την ανακάλυψη φαρμάκων, την γονιδιωματική και σε πολλούς άλλους τομείς [35].

2.1.2 Κατηγορίες Μηχανικής Μάθησης

Τα συστήματα Μηχανικής Μάθησης ταξινομούνται παραδοσιακά σε τρεις κύριες κατηγορίες, βάσει της φύσης του σήματος εκπαίδευσης ή την ανάδραση που λαμβάνει το σύστημα:

Επιβλεπόμενη Μάθηση (Supervised Learning): Ο αλγόριθμος εκπαιδεύεται σε σύνο-




Σχήμα 2.1: Είδη Μηχανικής Μάθησης [1]

λα δεδομένων όπου κάθε δείγμα εισόδου συνοδεύεται από την επιθυμητή ετικέτα εξόδου. Στόχος του μοντέλου αποτελεί η εύρεση μιας συνάρτησης χαρτογράφησης προκειμένου να μπορεί να προβλέπει με ακρίβεια την έξοδο για νέα, άγνωστα δεδομένα. Συνήθεις αλγόριθμοι αποτελούν οι εξής: **Logistic Regression, Decision Trees, XG-Boost, Support Vector Machines**. Κύριες πρακτικές της επιβλεπόμενης μάθησης αποτελούν οι εξής:

Ταξινόμηση: Διαδικασία ταξινόμησης των δεδομένων σε κατηγορίες. Χαρακτηριστικά παραδείγματα αποτελούν η ανίχνευση χρηματοπιστωτικής απάτης και η διάγνωση ασθενειών.

Παλινδρόμηση: Διαδικασία πρόβλεψης της συνεχούς αριθμητικής τιμής μίας μεταβλητής. Χαρακτηριστικά παραδείγματα αποτελούν η εκτίμηση ακινήτων και η πρόβλεψη ζήτησης [36].

Μη Επιβλεπόμενη Μάθηση (Unsupervised Learning): Το μοντέλο τροφοδοτείται αποκλειστικά με δεδομένα εισόδου. Κύριο χαρακτηριστικό αποτελεί η απουσία ετικέτων ή κάποιας καθοδήγησης. Στόχος του μοντέλου αποτελεί η ανακάλυψη κρυμμένων δομών, μοτίβων ή συσχετίσεων μέσα από τα δεδομένα. Συνήθεις αλγόριθμοι αποτελούν οι εξής: **K-means Clustering, Hierarchical Clustering, Density-Based Clustering, Apriori Algorithm**. Κύριες πρακτικές της μη-επιβλεπόμενης μάθησης αποτελούν οι




Σχήμα 2.2: Διάγραμμα Ροής Δεδομένων Επιβλεπόμενης Μάθησης [2]

εξής:

Συσταδοποίηση: Διαδικασία ταξινόμησης των δεδομένων σε συστάδες βασισμένοι στην ομοιότητά τους. Χαρακτηριστικά παραδείγματα αποτελούν η συσταδοποίηση πελατών και η ανίχνευση ανωμαλιών.


Μείωση Διαστατικότητας: Διαδικασία μετασχηματισμού δεδομένων από έναν διανυσματικό χώρο υψηλής διάστασης σε έναν διανυσματικό χώρο χαμηλής διάστασης, διατηρώντας τις κρίσιμες δομικές και στατιστικές ιδιότητες των αρχικών δεδομένων. Χαρακτηριστικό παράδειγμα εφαρμογών στις οποίες εφαρμόζεται η μείωση διαστατικότητας αποτελούν η επεξεργασία σημάτων, η αναγνώριση προτύπων και η ανάκτηση πληροφορίας [36].



Σχήμα 2.3: Διάγραμμα Ροής Δεδομένων Μη Επιβλεπόμενης Μάθησης [3]

Ενισχυτική Μάθηση (Reinforcement Learning): Κατηγορία που αντλεί έμπνευση από τη θεωρία ελέγχου, όπου ένας πράκτορας αλληλεπιδρά με ένα δυναμικό περιβάλλον. Ο πράκτορας εκτελεί ενέργειες και λαμβάνει ως ανάδραση ανταμοιβές ή ποινές,

με στόχο την ανάκαλυψη μιας στρατηγικής που θα μεγιστοποιεί το αθροιστικό κέρδος σε βάθος χρόνου [37].



Σχήμα 2.4: Διάγραμμα Ροής Δεδομένων Ενισχυτικής Μάθησης [4]

2.1.3 Ροή Εργασιών Μηχανικής Μάθησης

Η ανάπτυξη και εφαρμογή ενός συστήματος Μηχανικής Μάθησης σε πραγματικές συνθήκες δεν περιορίζεται μόνο στην εκτέλεση ενός αλγορίθμου, ωστόσο αποτελεί μία συστηματική και επαναληπτική διαδικασία [38]. Η τυπική ροή εργασιών Μηχανικής Μάθησης αποτελείται από τα εξής αλληλοεξαρτώμενα στάδια :

Συλλογή Δεδομένων: Πρωταρχικό στάδιο αποτελεί η συγκέντρωση των ακατέργαστων δεδομένων από διάφορες πηγές, όπως βάσεις δεδομένων, αισθητήρες και αρχεία καταγραφής. Η συνολική ποιότητα και ποσότητα αυτών των δεδομένων διαδραματίζουν σημαντικό ρόλο στις δυνατότητες του τελικού συστήματος.


Προεπεξεργασία Δεδομένων: Το πιο κρίσιμο στάδιο. Αφορά τον καθαρισμό των δεδομένων, τη διαχείριση ελλειπουσών και ακραίων τιμών και την κανονικοποίηση των κλιμάκων, πριν τα δεδομένα αυτά τροφοδοτηθούν στον αλγόριθμο. Σε αυτό το στάδιο εντοπίζεται και αντιμετωπίζεται επίσης το πρόβλημα της Ανισορροπίας Κλάσεων.

Μηχανική Χαρακτηριστικών: Μετασχηματισμός των ακατέργαστων δεδομένων με στόχο την βέλτιστη αναπαράσταση του υποκείμενου προβλήματος στα μαθηματικά μοντέλα. Επιλογή των χαρακτηριστικών με την μεγαλύτερη πληροφοριακή αξία, στοχεύοντας στην μεγιστοποίηση της απόδοσης του μοντέλου και στην αποφυγή της υπερπροσαρμογής.

Επιλογή και Εκπαίδευση Μοντέλου: Επιλογή κατάλληλου αλγορίθμου και εκπαίδευση του μοντέλου μέσω της βελτιστοποίησης των εσωτερικών του παραμέτρων με στόχο την ελαχιστοποίηση μίας προκαθορισμένης συνάρτησης σφάλματος.

Αξιολόγηση: Ελέγχεται η ικανότητα γενίκευσης του μοντέλου μέσω εξειδικευμένων μετρικών. Βάσει των αποτελεσμάτων, ρυθμίζονται οι υπερπαραμέτροι του αλγορίθμου και η διαδικασία επαναλαμβάνεται μέχρι να επιτευχθεί η επιθυμητή απόδοση.

Ανάπτυξη και Εξαγωγή Συμπερασμάτων: Το τελικό, βελτιστοποιημένο μοντέλο ενσωματώνεται στο περιβάλλον παραγωγής για την εξαγωγή προβλέψεων σε πραγματικό χρόνο πάνω σε νέα, άγνωστα δεδομένα.



Σχήμα 2.5: Ροή Εργασιών Μηχανικής Μάθησης [5]

2.2 Αλγόριθμοι Ταξινόμησης

Στην παρούσα ενότητα αναλύονται τα θεωρητικά μοντέλα Μηχανικής Μάθησης που αξιοποιήθηκαν για τους σκοπούς της εργασίας. Η επιλογή των συγκεκριμένων αλγορίθμων πραγματοποιήθηκε με γνώμονα την κάλυψη όλου του φάσματος της πολυπλοκότητας. Από απλά, γραμμικά μοντέλα υψηλής ερμηνευσιμότητας (Logistic Regression), έως σύγχρονα, ισχυρά μοντέλα συνόλων (XGBoost) και προηγμένες αρχιτεκτονικές βαθιάς μάθησης (Τεχνητά Νευρωνικά Δίκτυα).


2.2.1 Λογιστική Παλινδρόμηση (Logistic Regression)

Η Λογιστική Παλινδρόμηση είναι ένας από τους πιο θεμελιώδεις και ευρέως χρησιμοποιούμενους στατιστικούς αλγορίθμους για προβλήματα δυαδικής ταξινόμησης. Λειτουργεί υπολογίζοντας την πιθανότητα ένα δείγμα να ανήκει σε μία συγκεκριμένη κλάση. Μαθηματικά αυτο μεταφράζεται με τη χρήση της σιγμοειδούς συνάρτησης για τον μετασχηματισμό της γραμμικής συνδυαστικής εξόδου των χαρακτηριστικών σε μια τιμή στο διάστημα $(0, 1)$. Η πιθανότητα ενός δείγματος X να ανήκει στη θετική κλάση ($Y = 1$) δίνεται από τον τύπο: $P(Y = 1|X) = \frac{1}{1+e^{-(\beta_0+\beta^T X)}}$, όπου X είναι το διάνυσμα χαρακτηριστικών του δείγματος και β το διάνυσμα των βαρών του μοντέλου που βελτιστοποιούνται κατά την εκπαίδευση. Στην περίπτωση που η υπολογιζόμενη πιθανότητα υπερβεί ένα προκαθορισμένο κατώφλι απόφασης (συνήθως 0.5), το δείγμα ταξινομείται στην θετική κλάση. Η Λογιστική Παλινδρόμηση χρησιμοποιείται παραδοσιακά ως το βασικό μοντέλο αναφοράς στην αξιολόγηση συστημάτων Μηχανικής Μάθησης, λόγω της μαθηματικής της απλότητας, της ταχύτητας εκπαίδευσης και της υψηλής ερμηνευσιμότητας των αποτελεσμάτων της [39].

2.2.2 Extreme Gradient Boosting (XGBoost)

Ο αλγόριθμος XGBoost, μια από τις πιο ισχυρές σύγχρονες μεθόδους μηχανικής μάθησης, βασίζεται στην αρχιτεκτονική της ενισχυμένης μάθησης συνόλων με τη χρήση δέντρων απόφασης. Παρουσιάστηκε το 2016 [40] και θεωρείται έως και σήμερα η κορυφαία επιλογή για προβλήματα ταξινόμησης πάνω σε δομημένα σύνολα δεδομένων. Βασική αρχή του αλγορίθμου XGBoost αποτελεί η διαδοχική εκπαίδευση “αδύναμων” ταξινομητών, όπου το κάθε νέο δέντρο προσπαθεί να διορθώσει τα υπολειπόμενα σφάλματα των προηγούμενων δέντρων. Επεκτείνοντας αυτή τη λογική, ο XGBoost εισάγει μαθηματικές και υπολογιστικές καινοτομίες, όπως την ενσωμάτωση κανονικοποίησης στην αντικειμενική συνάρτηση για την αποφυγή της υπερπροσαρμογής, την ικανότητα διαχείρισης αραιών δεδομένων και την παράλληλη κατασκευή των δέντρων. Η αντικειμενική συνάρτηση $\mathcal{L}$ που καλείται να ελαχιστοποιήσει ο αλγόριθμος σε κάθε βήμα εκπαίδευσης t ορίζεται ως: $\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$ όπου l είναι μια παρα-

LOGISTIC REGRESSION




Σχήμα 2.6: Λογιστική Παλινδρόμηση [5]

γωγίσιμη συνάρτηση κόστους που μετρά τη διαφορά μεταξύ της πραγματικής ετικέτας y_i και της τρέχουσας πρόβλεψης, f_i είναι το νέο δέντρο που προστίθεται στο μοντέλο και Ω είναι ο όρος κανονικοποίησης που "αποκόπτει" την πολυπλοκότητα του νέου δέντρου.


2.2.3 Τεχνητά Νευρωνικά Δίκτυα

Τα Τεχνητά Νευρωνικά Δίκτυα (εν συντομία Νευρωνικά Δίκτυα) αποτελούν υπολογιστικά μοντέλα εμπνευσμένα από τη δομή και τη λειτουργία του ανθρώπινου νευρικού συστήματος. Η λειτουργία τους βασίζεται στην προσπάθεια αναπαραγωγής της εγγενούς ικανότητας του ανθρώπινου εγκεφάλου επεξεργασίας πληροφοριών μέσω ενός δικτύου διασυνδεδεμένων βιολογικών νευρώνων. Ιστορικά, πρώτη αναφορά στα Νευρωνικά Δίκτυα εντοπίζεται στο έργο των McCulloch και Pitts (1943) [41], οι οποίοι παρουσίασαν το πρώτο μαθηματικό μοντέλο ενός απλοποιημένου νευρώνα. Στη συνέχεια, το 1958, ο Frank Rosenblatt εισήγαγε την έννοια του Perceptron [42], προωθώντας την εξέλιξη των Νευρωνικών Δικτύων.

Ένα Νευρωνικό Δίκτυο αποτελείται από στοιχειώδεις μονάδες επεξεργασίας, οι οποίες αποκαλούνται τεχνητοί νευρώνες και οργανώνονται σε διαδοχικά επίπεδα. Συγκεκριμένα, ο διαχωρισμός ενός Νευρωνικού Δικτύου σε επίπεδα αποτελείται από το επίπεδο εισόδου, ένα ή περισσότερα κρυφά επίπεδα και το επίπεδο εξόδου. Η μάθηση επιτυγχάνεται μέσω της προσαρμογής των βαρών των συνδέσεων μεταξύ των νευρώνων, επιτρέποντας στο μοντέλο να προσεγγίζει πολύπλοκες, μη γραμμικές συναρτήσεις.



Σχήμα 2.7: XGBoost [6]




Σχήμα 2.8: Σύγκριση Βιολογικού και Τεχνητού Νευρώνα [6]

Multi-Layer Perceptron

Το Multi-Layer Perceptron (MLP) αποτελεί την κλασική αρχιτεκτονική ενός πρόσθιας τροφοδότησης νευρωνικού δικτύου. Η ισχύς του προέρχεται από την ικανότητα να επιλύει προβλήματα που δεν είναι γραμμικά διαχωρίσιμα, ξεπερνώντας τους περιορισμούς του απλού Perceptron. Η λειτουργία του βασίζεται στις μη γραμμικές συναρτήσεις ενεργοποίησης και του αλγόριθμου οπισθοδιάδοσης σφάλματος. Συγκεκριμένα, κάθε νευρώνας εφαρμόζει μια μη γραμμική συνάρτηση (Sigmoid, Tanh, ReLU) στο σταθμισμένο άθροισμα των εισόδων του, καθιστώντας δυνατή την μοντελοποίηση μη γραμμικών σχέσεων. Επιπλέον, ο αλγόριθμος οπισθοδιάδοσης σφάλματος των MLP αποτελεί το θεμέλιο της εκπαίδευσης των σύγχρονων νευρωνικών δικτύων. Ο αλγόριθμος αυτός υπολογίζει την κλίση της συνάρτησης κόστους σε σχέση με τα βάρη του δικτύου, επιτρέποντας την ανανέωσή τους μέσω της μεθόδου της κλιμακωτής καθόδου (Gradient Descent) [43].

Αξιοσημείωτη αναφορά αποτελεί το **Θεώρημα Καθολικής Προσέγγισης (Universal Approximation Theorem)** που ορίζει ότι ένα MLP με τουλάχιστον ένα κρυφό επίπεδο και έναν επαρκή αριθμό νευρώνων μπορεί να προσεγγίσει οποιαδήποτε συνεχή συνάρτηση με αυθαίρετη ακρίβεια [44]. Έτσι, συμπεραίνει εύκολα κανείς την προτίμηση από την επιστημονική κοινότητα για την μέθοδο των MLP στην σύγχρονη Μηχανική Μάθηση.




Σχήμα 2.9: Αρχιτεκτονική και Επίπεδα ενός MLP [7]

Generative Adversarial Networks

Τα Γεννητικά Ανταγωνιστικά Δίκτυα (Generative Adversarial Networks - GAN) αποτελούν μια ριζοσπαστική προσέγγιση στη μη επιβλεπόμενη μάθηση και τη δημιουργία συνθετικών δεδομένων [45]. Η αρχιτεκτονική τους βασίζεται στη θεωρία παιγνίων και

κυρίως σε ένα παίγνιο μηδενικού αθροίσματος μεταξύ δύο νευρωνικών δικτύων. Συγκεκριμένα, από την μία πλευρά, έχουμε τον **Γεννήτορα (Generator)** που προσπαθεί να δημιουργήσει συνθετικά δεδομένα που μοιάζουν με τα πραγματικά, ξεκινώντας από τυχαίο θόρυβο. Από την άλλη πλευρά, ο **Διαχωριστής (Discriminator)** προσπαθεί να διακρίνει αν κάποιο δείγμα προέρχεται από το πραγματικό σύνολο δεδομένων ή αν αποτελεί συνθετικό προϊόν του Γεννήτορα.

Κατά την εκπαίδευση, στόχος του Γεννήτορα είναι να βελτιώνεται συνεχώς προκειμένου να "ξεγελά" τον Διαχωριστή, ενώ ο Διαχωριστής προσπαθεί να γίνει όλο και πιο ακριβής στην ανίχνευση των συνθετικών δειγμάτων. Η διαδικασία αυτή συνεχίζεται έως ότου να επιτευχθεί ένα σημείο ισορροπίας (Ισορροπία Nash), όπου τα συνθετικά δεδομένα έχουν παρόμοιες στατιστικές ιδιότητες με τα πραγματικά δεδομένα.



Σχήμα 2.10: Γεννητικό Ανταγωνιστικό Δίκτυο (GAN) [8]

2.3 Ανισορροπία Κλάσεων


Η Ανισορροπία Κλάσεων (Class Imbalance) αποτελεί μία από τις πιο κρίσιμες και συχνές προκλήσεις στον τομέα της Μηχανικής Μάθησης. Εμφανίζεται σε περιπτώσεις που τα δείγματα εκπαίδευσης δεν κατανέμονται ισομερώς σε όλες τις κατηγορίες και μία ή περισσότερες κλάσεις (πλειοψηφικές) κυριαρχούν αριθμητικά έναντι άλλων (μειοψηφικές) [46].

2.3.1 Φύση του Προβλήματος

Στην πλειονότητα των προβλημάτων του πραγματικού κόσμου όπου η ανίχνευση του συμβάντος που φέρει την μεγαλύτερη βαρύτητα από επιχειρησιακής ή επιστημονικής

Imbalanced Datasets

Imbalanced datasets have many more instances of certain classes than of others.



Σχήμα 2.11: Ανισορροπία Κλάσεων [9]

άποψης, όπως ο εντοπισμός χρηματοπιστωτικών απάτων ή η ανίχνευση κυβερνοεπιθέσεων, η μειονοτική κλάση αποτελεί την κλάση ενδιαφέροντος.

Η Ανισορροπία Κλάσεων μπορεί να κυμανθεί σε διάφορα εύρη και για την αυστηρή ποσοτική αποτίμηση της σοβαρότητας του προβλήματος, η επιστημονική κοινότητα χρησιμοποιεί τον δείκτη **Λόγος Ανισορροπίας (Imbalance Ratio - IR)**. Σε ένα πρόβλημα δυαδικής ταξινόμησης, ο δείκτης αυτός ορίζεται μαθηματικά ως: $IR = \frac{N_{maj}}{N_{min}}$ όπου N_{maj} αποτελεί το πλήθος των δειγμάτων την πλειοψηφικής κλάσης και N_{min} αποτελεί το πλήθος των δειγμάτων της μειονοτικής κλάσης. Στην περίπτωση όπου $IR = 1$, το σύνολο δεδομένων θεωρείται απόλυτα ισορροπημένο. Όσο μεγαλύτερη είναι η τιμή του IR , τόσο πιο έντονη καθίσταται η στατιστική ασυμμετρία. Στη βιβλιογραφία [47], όταν $IR \in (1.5, 9)$ θεωρείται ότι το σύνολο δεδομένων παρουσιάζει χαμηλή ανισορροπία, ενώ όταν $IR > 9$ θεωρείται πρόβλημα υψηλής ή ακραίας ανισορροπίας.


Η παρουσία έντονης ανισορροπίας διαταράσσει τη διαδικασία εκπαίδευσης των παραδοσιακών αλγόριθμων ταξινόμησης. Λόγω του σχεδιασμού τους, οι περισσότεροι αλγόριθμοι Μηχανικής Μάθησης και τα Νευρωνικά Δίκτυα επιχειρούν να ελαχιστοποιήσουν το συνολικό σφάλμα και να μεγιστοποιήσουν την καθολική ακρίβεια. Ως αποτέλεσμα, στην περίπτωση ενός συνόλου δεδομένων με $IR = 100$, ένα μοντέλο μπορεί να επιτύχει ακρίβεια 99% απλώς αγνοώντας πλήρως τη μειονοτική κλάση και ταξινομώντας τα δείγματα στο σύνολό τους ως πλειοψηφικά (Παράδοξο της Ακρίβειας) [20]. Συμπερασματικά, προκύπτει η ανάγκη για υιοθέτηση εναλλακτικών μετρικών αξιολόγησης της απόδοσης του μοντέλου, οι οποίες αναλύονται σε επόμενο κεφάλαιο της εργασίας.

Σε επίπεδο βελτιστοποίησης, η Ανισορροπία Κλάσεων οδηγεί σε μεροληπτική ανανέωση

των βαρών ενός Νευρωνικού Δικτύου. Συγκεκριμένα, το σταθμισμένο άθροισμα του σφάλματος κυριαρχείται από τα δείγματα της πλειοψηφικής κλάσης, με αποτέλεσμα τα χαρακτηριστικά της μειοψηφικής κλάσης να αντιμετωπίζονται από το μοντέλο ως στατιστικός θόρυβος [46].

2.3.2 Τεχνικές Υπερδειγματοληψίας

Για την αντιμετώπιση της Ανισοροπίας Κλάσεων σε επίπεδο δεδομένων, η πλέον καθιερωμένη επιστημονική προσέγγιση είναι αυτή της Υπερδειγματοληψίας. Η **Υπερδειγματοληψία** στοχευεί στην τεχνητή αύξηση των δειγμάτων της μειοψηφικής κλάσης, χωρίς την απώλεια πολύτιμης πληροφορίας που θα προερχόταν από την αφαίρεση δειγμάτων της πλειοψηφικής κλάσης.




Σχήμα 2.12: Υπερδειγματοληψία [10]

Synthetic Minority Over-sampling Technique (SMOTE)

Ο αλγόριθμος **SMOTE** [22] αποτελεί ορόσημο στην Επιστήμη των Δεδομένων. Ως απάντηση στην απλή τυχαία υπερδειγματοληψία, όπου απλώς αντιγράφονται υπάρχοντα δείγματα, οδηγώντας συχνά σε υπερπροσαρμογή, το SMOTE παράγει νέα, μοναδικά συνθετικά δείγματα μέσω γραμμικής παρεμβολής στον χώρο των χαρακτηριστικών της μειοψηφικής κλάσης. Συγκεκριμένα, για κάθε δείγμα x_i της μειονοτικής κλάσης, ο αλγόριθμος εντοπίζει τους k κοντινότερους γείτονές του (με βάση την Ευκλείδεια Απόσταση). Έπειτα, επιλέγει τυχαία έναν γείτονα x_j από τους k κοντινότερους και δημιουργεί

ένα νέο δείγμα x_{new} βάσει του μαθηματικού τύπου: $x_{new} = x_i + \beta * (x_j - x_i)$ όπου β ένας τυχαίος αριθμός στο διάστημα $[0, 1]$. Μέσω αυτής της διαδικασίας, επεκτείνονται τα όρια απόφασης της μειονοτικής κλάσης, ενισχύοντας την γενίκευση στην μειονοτική κλάση.

Η εκτέλεση του αλγορίθμου επαναλαμβάνεται μέχρι την ικανοποίηση του επιθυμητού βαθμού ισορροπίας. Το συνολικό πλήθος των συνθετικών δειγμάτων G που πρέπει να παραχθούν υπολογίζεται ως: $G = (N_{maj} - N_{min}) * \beta$ όπου N_{maj} και N_{min} είναι το πλήθος δειγμάτων της πλειοψηφικής και μειονοτικής κλάσης αντίστοιχα και $\beta \in [0, 1]$ αποτελεί την παράμετρο επιθυμητής αναλογίας. Για πλήρη εξισορρόπηση κλάσεων ορίζουμε $\beta = 1$.



Σχήμα 2.13: Αλγόριθμος SMOTE [11]

Adaptive Synthetic (ADASYN)

Ο αλγόριθμος **ADASYN** [48] εισάγει την έννοια προσαρμοστικής παραγωγής δεδομένων. Ο αλγόριθμος αυτός δεν παράγει τον ίδιο αριθμό συνθετικών δειγμάτων για κάθε αρχικό μειονοτικό δείγμα x_i , αλλά υπολογίζει μια κατανομή πυκνότητας $\hat{r}_i$, η οποία καθορίζει τον αριθμό των συνθετικών δειγμάτων που πρέπει να δημιουργηθούν για κάθε x_i . Συγκεκριμένα, για κάθε x_i , υπολογίζεται ο λόγος $r_i = \frac{\Delta_i}{K}$ όπου Δ_i είναι το πλήθος δειγμάτων της πλειοψηφικής κλάσης στους K κοντινότερους γείτονες. Έπειτα, ο λόγος αυτός κανονικοποιείται ώστε να δημιουργηθεί η κατανομή πυκνότητας: $\hat{r}_i = \frac{r_i}{\sum_{i=1}^{N_{min}} r_i}$. Το πλήθος των συνθετικών δειγμάτων g_i που θα παραχθούν αποκλειστικά για το συγκεκριμένο δείγμα x_i υπολογίζεται ως: $g_i = \hat{r}_i \times G$. Επομένως, ο αλγόριθμος ADASYN μετατοπίζει την

προσοχή του μοντέλου στα πιο “απομονωμένα” και δύσκολα δείγματα, προσαρμόζοντας δυναμικά την παραγωγή συνθετικών δειγμάτων.

Borderline-SMOTE

Ο αλγόριθμος **Borderline-SMOTE** [49] είναι μια στοχευμένη παραλλαγή του κλασικού SMOTE. Λειτουργεί εντοπίζοντας τα δείγματα της μειονοτικής κλάσης που τοποθετούνται πολύ κοντά στα όρια απόφασης μεταξύ των δύο κλάσεων, εφόσον έχουν την μεγαλύτερη πιθανότητα να ταξινομηθούν λανθασμένα. Για κάθε δείγμα x_i της μειοψηφικής κλάσης, ελέγχονται οι k κοντινότεροι γείτονές του. Έστω m το πλήθος των γειτόνων που ανήκουν στην πλειοψηφική κλάση, τότε το δείγμα x_i θα κατηγοριοποιηθεί ως εξής:

- **Ασφαλές:** Αν $m < \frac{k}{2}$, δηλαδή οι περισσότεροι γείτονες ανήκουν στην μειοψηφική κλάση
- **Σε Κίνδυνο:** Αν $\frac{k}{2} \leq m < k$, δηλαδή οι περισσότεροι γείτονες ανήκουν στην πλειοψηφική κλάση
- **Θόρυβος:** Αν $m = k$, δηλαδή όλοι οι γείτονες ανήκουν στην πλειοψηφική κλάση

Έπειτα, ο αλγόριθμος απορρίπτει τα δείγματα που ανήκουν στις κατηγορίες “Ασφαλές” και “Θόρυβος” και εφαρμόζει την γραμμική παρεμβολή του κλασικού SMOTE αποκλειστικά στο υποσύνολο των δεδομένων που ανήκουν στην κατηγορία “Σε Κίνδυνο”, ενισχύοντας έτσι τα όρια απόφασης στα σημεία που ο ταξινομητής συναντά τη μεγαλύτερη δυσκολία.

Συνθετικά Δεδομένα μέσω χρήσης Γεννητικών Ανταγωνιστικών Δίκτυων (GAN)

Τα **Γεννητικά Ανταγωνιστικά Δίκτυα** αποτελούν ένα ισχυρό εργαλείο υπερδειγματοληψίας και παραγωγής συνθετικών δεδομένων [45] [50]. Η αρχιτεκτονική τους βασίζεται σε ένα παίγνιο μηδενικού αθροίσματος μεταξύ του Γεννήτορα και του Διαχωριστή. Στόχος είναι η ελαχιστοποίηση-μεγιστοποίηση συνάρτησης αξίας $V(D, G)$: $\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$ όπου $p_{data}(x)$ είναι η πραγματική κατανομή των μειονοτικών δειγμάτων και $p_z(z)$ η κατανομή του αρχικού θορύβου του Γεννήτορα. Μέσα από αυτή την βελτιστοποίηση, ο Γεννήτορας μαθαίνει τα χαρακτηριστικά της πραγματικής στατιστικής κατανομής και παράγει τα συνθετικά δείγματα $G(z)$, τα οποία είναι στατιστικά πανομοιότυπα με τα πραγματικά δείγματα. Ενώ η τεχνική αυτή προσφέρει εξαιρετικά ρεαλιστικά δεδομένα, συνοδεύεται ωστόσο από υψηλές υπολογιστικές απαιτήσεις.

2.4 Ομοσπονδιακή Μάθηση

Η **Ομοσπονδιακή Μάθηση (Federated Learning - FL)** αποτελεί ένα σύγχρονο παράδειγμα αποκεντρωμένης Μηχανικής Μάθησης, το οποίο καθιστά δυνατή την συνεργατική εκπαίδευση ενός κοινού παγκοσμίου μοντέλου από πολλαπλούς συμμετέχοντες, χωρίς να προκύπτει η ανάγκη ανταλλαγής ή συγκέντρωσης των τοπικών τους δεδομένων. Η θεμελιώδης αρχή της Ομοσπονδιακής Μάθησης είναι η μεταφορά της διαδικασίας της εκπαίδευσης εκεί όπου παράγονται και αποθηκεύονται τα δεδομένα, ανατρέποντας το παραδοσιακό κεντροποιημένο μοντέλο και προάγοντας την διασφάλιση της ιδιωτικότητας και την μείωση του κόστους επικοινωνίας [18] [19].

2.4.1 Ορισμός και Βασική Λειτουργία


Σύμφωνα με τον επίσημο ορισμό, η Ομοσπονδιακή Μάθηση αποτελεί μια διαδικασία μάθησης η οποία στοχεύει στην εκπαίδευση ενός μοντέλου παραμέτρων w , μέσω της ελαχιστοποίησης μίας αντικειμενικής συνάρτησης κόστους πάνω σε δεδομένα τα οποία είναι καταναμημένα σε K πελάτες. Βασική λειτουργία του συστήματος αποτελεί μία επαναληπτική διαδικασία επικοινωνίας μεταξύ ενός κεντρικού υπολογιστικού διακομιστή (Server) και των πελατών-κόμβων, η οποία διακρίνεται σε τέσσερα κύρια στάδια. Σε πρώτο στάδιο, ο διακομιστής αρχικοποιεί το παγκόσμιο μοντέλο και επιλέγει ένα υποσύνολο πελατών, αποστέλλοντας τους τις τρέχουσες παραμέτρους του παγκοσμίου μοντέλου. Έπειτα, κάθε πελάτης είναι υπεύθυνος για την τοπική εκτέλεση του αλγορίθμου βελτιστοποίησης με αποκλειστική χρήση των δικών του τοπικών δεδομένων. Μόλις τελειώσει η διαδικασία της τοπικής εκπαίδευσης κάθε πελάτη, οι πελάτες αποστέλλουν τις ενημερωμένες παραμέτρους των μοντέλων τους πίσω στον κεντρικό διακομιστή. Τέλος, ο κεντρικός διακομιστής είναι υπεύθυνος για την συνδυάση των τοπικών ενημερώσεων κάθε πελάτη, μέσω μίας συνάρτησης συνάθροισης (συνήθως μέσω του αλγορίθμου FedAvg), προκειμένου να επικαιροποιήσει το παγκόσμιο μοντέλο με την γνώση που απέκτησαν οι πελάτες κατά την τοπική τους εκπαίδευση. Μόλις τελειώσει αυτός ο κύκλος επικοινωνίας, ξεκινά εκ νέου, μέχρι να πραγματοποιηθεί η σύγκλιση του global μοντέλου.

2.4.2 Ταξινόμηση Συστημάτων Ομοσπονδιακής Μάθησης

Τα συστήματα Ομοσπονδιακής Μάθησης ταξινομούνται με βάση δύο κύριες διαστάσεις [51]:

Με βάση την Κατανομή των Δεδομένων

Με βάση την κατανομή των δεδομένων στον χώρο των χαρακτηριστικών, η Ομοσπονδιακή Μάθηση διακρίνεται κυρίως σε Οριζόντια και Κάθετη.



Σχήμα 2.14: Παράδειγμα Ομοσπονδιακής Μάθησης [12]

Στην **Οριζόντια Ομοσπονδιακή Μάθηση**, οι πελάτες-κόμβοι μοιράζονται τον ίδιο χώρο χαρακτηριστικών, διαφέρουν ωστόσο ως προς τον πληθυσμό των δειγμάτων. Χαρακτηριστικό παράδειγμα αποτελεί η περίπτωση δύο διαφορετικών νοσοκομείων που αποθηκεύουν τα δεδομένα των ασθενών τους με παρόμοιο τρόπο, αλλά διαθέτουν διαφορετικούς ασθενείς. Η αρχιτεκτονική της Οριζόντιας Ομοσπονδιακής Μάθησης υιοθετείται στην παρούσα εργασία λόγω της φύσης των δεδομένων που αξιοποιήθηκαν για τους σκοπούς της.

Στην **Κάθετη Ομοσπονδιακή Μάθηση**, οι πελάτες-κόμβοι διαθέτουν διαφορετικό χώρο χαρακτηριστικών αλλά για τον ίδιο πληθυσμό δειγμάτων. Χαρακτηριστικό παράδειγμα αποτελεί η περίπτωση ενός τραπεζικού ιδρύματος που διαθέτει τα οικονομικά δεδομένα και μίας πλατφόρμας ηλεκτρονικού εμπορίου που διαθέτει το ιστορικό αγορών για τον ίδιο πληθυσμό πελατών.

Αξιοσημείωτη αναφορά αποτελεί η περίπτωση της **Ομοσπονδιακής Μεταφορικής Μάθησης (Federated Transfer Learning)**, όπου οι πελάτες-κόμβοι διαφέρουν τόσο στον πληθυσμό των δειγμάτων όσο και στον χώρο των χαρακτηριστικών.


Με βάση την Κλίμακα των Συμμετεχόντων Οργανισμών

Με βάση την κλίμακα των οντότητων που συμμετέχουν στην διαδικασία της Ομοσπονδιακής Μάθησης, αυτή διακρίνεται σε Cross-device FL και Cross-silo FL.

Στη **Cross-device FL**, τα δεδομένα προέρχονται από έναν εξαιρετικά μεγάλο αριθμό λιγότερο αξιόπιστων πελατών, όπως έξυπνα κινητά τηλέφωνα και συσκευές του Διαδι-

κτύου των Πραγμάτων, οι οποίοι διαθέτουν μικρότερα σύνολα δεδομένων, περιορισμένη υπολογιστική ισχύ και ασταθείς συνδέσεις δικτύου.

Αντίθετα, στη **Cross-silo FL**, τα δεδομένα προέρχονται από ένα μικρό αριθμό αξιόπιστων και ισχυρών πελατών επιπέδου οργανισμού, όπως νοσοκομεία, ερευνητικά κέντρα και τραπεζικά ιδρύματα, οι οποίοι διαθέτουν μεγάλα σύνολα δεδομένων, ισχυρές υπολογιστικές υποδομές και σταθερές συνδέσεις δικτύου. Η αρχιτεκτονική του Cross-silo FL υιοθετείται στην παρούσα εργασία λόγω απλότητας.



Σχήμα 2.15: Σύγκριση Cross-device και Cross-silo Ομοσπονδιακής Μάθησης [13]

2.4.3 Ο Αλγόριθμος Federated Averaging (FedAvg)

Ο αλγόριθμος **FedAvg** αποτελεί τη θεμέλια μέθοδο συνάθροισης των τοπικών ενημερώσεων στην Ομοσπονδιακή Μάθηση.

Το θεμελιώδες πρόβλημα βελτιστοποίησης στην Ομοσπονδιακή Μάθηση συνίσταται στην ελαχιστοποίηση μιας γλοβαλ αντικειμενικής συνάρτησης απώλειας η οποία κατανέμεται σε ένα σύνολο K πελατών. Κάνοντας την υπόθεση ότι ο πελάτης-κόμβος k κατέχει ένα τοπικό σύνολο δεδομένων D_k μεγέθους n_k και ότι το συνολικό πλήθος των δειγμάτων στο δίκτυο είναι $n = \sum_{k=1}^K n_k$, τότε το παγκόσμιο πρόβλημα βελτιστοποίησης διατυπώνεται ως: $\min_{w \in \mathbb{R}^d} F(w) = \sum_{k=1}^K p_k F_k(w)$ όπου $p_k = \frac{n_k}{n}$ είναι το σχετικό βάρος του κάθε πελάτη-κόμβου με βάση τον όγκο των δεδομένων του και συνολικά ισχύει $\sum_{k=1}^K p_k = 1$. Το διάνυσμα w αναπαριστά τις παραμέτρους του μοντέλου μηχανικής μάθησης.

Η τοπική συνάρτηση κόστους $F_k(w)$ για τον πελάτη-κόμβο k ορίζεται ως ο μέσος όρος

της συνάρτησης απώλειας l πάνω σε όλα τα τοπικά του δείγματα (x_i, y_i) : $F_k(w) = \frac{1}{n_k} \sum_{i \in D_k} l(w; x_i, y_i)$

Για την επίλυση αυτού του καταναμεμένου προβλήματος, προτάθηκε ο αλγόριθμος **Federated Averaging (FedAvg)** [18]. Σε αντίθεση με τον παραδοσιακό καταναμεμένο αλγόριθμο FedSGD, όπου οι πελάτες υπολογίζουν μόνο μία κλίση και την επιστρέφουν στον διακομιστή, ο FedAvg παρέχει την δυνατότητα στους πελάτες-κόμβους να εκτελέσουν πολλαπλά βήματα Στοχαστικής Κλιμακωτής Καθόδου (Stochastic Gradient Descent - SGD) τοπικά, πριν χρειαστεί να επικοινωνήσουν με τον διακομιστή.

Η διαδικασία που ακολουθείται σε κάθε γύρο επικοινωνίας t αναλύεται ως εξής: Αρχικά, ο διακομιστής αποστέλλει το παγκόσμιο μοντέλο w_t σε ένα επιλεγμένο υποσύνολο πελατών. Κάθε πελάτης k αρχικοποιεί το τοπικό του μοντέλο ως $w_t^k = w_t$. Έπειτα, εκτελεί E τοπικές εποχές εκπαίδευσης με μέγεθος δέσμης B . Σε κάθε βήμα τοπικής εκπαίδευσης, τα τοπικά βάρη του μοντέλου ανανεώνονται σύμφωνα με τον κανόνα $w_t^k \leftarrow w_t^k - \eta \nabla F_k(w_t^k; b)$ όπου η είναι ο ρυθμός μάθησης και ∇F_k είναι η κλίση της συνάρτησης κόστους υπολογισμένη στην τρέχουσα δέσμη b .

Μετά την ολοκλήρωση των E τοπικών εποχών, οι πελάτες αποστέλλουν τα νέα τοπικά τους βάρη, έστω w_{t+1}^k στον κεντρικό διακομιστή. Ο διακομιστής τότε υπολογίζει το νέο παγκόσμιο μοντέλο ως τον σταθμισμένο μέσο όρο των τοπικών βαρών: $w_{t+1} = \sum_{k=1}^K p_k w_{t+1}^k$.

Η Μαθηματική Πρόκληση της Ανισορροπίας Κλάσεων

Μέσα από αυτές τις εξισώσεις διακρίνεται και η ευπάθεια του αλγορίθμου σε περιβάλλοντα με στατιστική ετερογένεια και Ανισορροπία Κλάσεων. Στην περίπτωση που τα δεδομένα έχουν IID κατανομή, η αναμενόμενη τιμή της τοπικής κλίσης ισούται με την παγκόσμια κλίση ($\mathbb{E}[\nabla F_k(w)] = \nabla F(w)$). Στην περίπτωση ωστόσο που ένας πελάτης κατέχει έντονα ανισόρροπα δεδομένα, η τοπική συνάρτηση $F_k(w)$ αποκλίνει δραματικά από την παγκόσμια $F(w)$.

Έτσι, η τοπική ανανέωση αναγκάζεται να ωθήσει τα τοπικά βάρη w_t^k προς ένα τοπικό ελάχιστο που αγνοεί πλήρως την μειονοτική κλάση. Τότε, όταν ο κεντρικός διακομιστής προσπαθεί να συναθροίσει αυτά τα αποκλίνοντα διανύσματα βαρών προκαλείται το φαινόμενο της **απόκλισης πελατών (client drift)**, καταρρίπτοντας την ικανότητα του μοντέλου να γενικεύει στην μειονοτική κλάση [52].

2.4.4 Οφέλη και Πλεονεκτήματα της Ομοσπονδιακής Μάθησης

Η υιοθέτηση της Ομοσπονδιακής Μάθησης προσφέρει μια σειρά από θεμελιώδη πλεονεκτήματα σε σχέση με τις παραδοσιακές κεντριοποιημένες προσεγγίσεις, καθιστώντας

την την πλέον υποσχόμενη αρχιτεκτονική για ευαίσθητες εφαρμογές.

Το πιο σημαντικό όφελος που προσφέρει η Ομοσπονδιακή Μάθηση είναι η **Ενισχυμένη Ιδιωτικότητα και η Προστασία Πρωτογενών Δεδομένων**. Εφόσον τα πρωτογενή και ευαίσθητα δεδομένα δεν εγκαταλείπουν ποτέ τη συσκευή ή τον οργανισμό προέλευσης, εξασφαλίζεται η ελαχιστοποίηση της επιφάνειας επίθεσης και αποτρέπεται η μαζική διαρροή δεδομένων που συχνά πλήττει τις κεντρικές βάσεις δεδομένων.

Στη σύγχρονη εποχή, ρυθμιστικά πλαίσια, όπως ο Γενικός Κανονισμός για την Προστασία Δεδομένων (GDPR), επιβάλλουν αυστηρούς περιορισμούς στη συλλογή και μεταφορά προσωπικών δεδομένων. Έτσι, η Ομοσπονδιακή Μάθηση εγγυάται την **Συμμόρφωση με Αυστηρά Νομικά Πλαίσια**, επιτρέποντας σε διάφορους οργανισμούς να συνεργαστούν για την δημιουργία ισχυρών μοντέλων χωρίς την παραβίαση αυτών των κανονισμών εφόσον δεν υφίσταται μεταφορά και διαμοιρασμός των ευαίσθητων δεδομένων.

Η συγκέντρωση πολύ μεγάλων δεδομένων (Big Data) σε έναν κεντρικό διακομιστή απαιτεί τεράστιο εύρος ζώνης και έχει ως αποτέλεσμα σημαντικές καθυστερήσεις. Η Ομοσπονδιακή Μάθηση παρέχει **Ελαχιστοποίηση Κόστους Δικτύου** εφόσον η επικοινωνία περιορίζεται απλώς στην μετάδοση μόνο των παραμέτρων του μοντέλου, οι οποίες είναι κατά κανόνα ασύγκριτα μικρότερες σε όγκο σε σχέση με τα δεδομένα εκπαίδευσης. Σε αυτό συμβάλει και ο αλγόριθμος FedAvg, ο οποίος μειώνει τους απαραίτητους γύρους επικοινωνίας.

Τέλος, η Ομοσπονδιακή Μάθηση επιτρέπει την **Αξιοποίηση Πλουσιότερων Συνόλων Δεδομένων**, αφού επιτρέπει την πρόσβαση σε τεράστιους όγκους δεδομένων που σε διαφορετική περίπτωση θα παρέμεναν απομονωμένοι σε "σιλό" δεδομένων λόγω ανταγωνιστικότητας ή νομικών περιορισμών.

2.4.5 Προκλήσεις και Περιορισμοί της Ομοσπονδιακής Μάθησης

Ενώ η Ομοσπονδιακή Μάθηση προσφέρει αδιαμφισβήτητα οφέλη, η μετάβαση από το κεντριοποιημένο στο ομοσπονδιακό μοντέλο μάθησης εισάγει μια σειρά από νέα σύνθετα προβλήματα.

Συγκεκριμένα, σε ένα τυπικό δίκτυο Ομοσπονδιακής Μάθησης, οι συμμετέχοντες κόμβοι διαθέτουν ασύμμετρες υπολογιστικές δυνατότητες, όπως επεξεργαστική ισχύ, μνήμη, αυτονομία μπαταρίας και ταχύτητα δικτύου, οδηγώντας σε **Υπολογιστική και Επικοινωνιακή Ετερογένεια**. Αυτό οδηγεί στο φαινόμενο των "καθυστερημένων πελατών", όπου ο κεντρικός διακομιστής πρέπει να περιμένει τον πιο αργό πελάτη-κόμβο για να ολοκληρώσει την συνάθροιση. Επιπλέον, σε βαθιά νευρωνικά δίκτυα με εκατομ-

μύρια παραμέτρους, η συνεχής επαναποστολή των βαρών του μοντέλου δημιουργεί ένα ασφυκτικό σημείο συμφόρησης στο εύρος ζώνης του δικτύου [19].

Τα τοπικά δεδομένα των πελάτων σπάνια είναι ανεξάρτητα και ισόνομα καταναμημένα (IID κατανομή). Η **Ανισορροπία Κλάσεων** αποτελεί την πιο κρίσιμη μορφή **Στατιστικής Ετερογένειας**. Σε ακραίες περιπτώσεις, όπου ένας πελάτης μπορεί ακόμα και να μην κατέχει καθόλου δείγματα της μειοψηφικής κλάσης, η τοπική βελτιστοποίηση προκαλεί δραματική απόκλιση των βαρών και καταρρίπτει την γενίκευση του τελικού μοντέλου.


Η θεμελιώδης υπόσχεση της Ομοσπονδιακής Μάθησης είναι η ασφάλεια των πρωτογενών δεδομένων. Ωστόσο, πρόσφατες έρευνες [23] έχουν αποδείξει ότι ακόμα και η απλή ανταλλαγή παραμέτρων ή κλίσεων ενέχει **Κινδύνους Ασφάλειας και Διαρροής Ιδιωτικότητας**. Ένας κακόβουλος διακομιστής ή πελάτης-κόμβος μπορεί να αξιοποιήσει τις κλίσεις, μέσω επιθέσεων ανακατασκευής, για να ανακτήσει με υψηλή ακρίβεια τα αρχικά δεδομένα εκπαίδευσης. Έτσι, μέσω αυτού του περιορισμού, καθίσταται επιτακτική η ανάγκη ενσωμάτωσης πρόσθετων μηχανισμών προστασίας, όπως η Πλήρως Ομομορφική Κρυπτογράφηση.

2.5 Πλήρως Ομομορφική Κρυπτογράφηση

Η **Ομομορφική Κρυπτογράφηση** αποτελεί μια κατηγορία κρυπτογραφικών συστημάτων, η οποία επιτρέπει την απευθείας εκτέλεση μαθηματικών υπολογισμών πάνω σε κρυπτογραφημένα δεδομένα, χωρίς να χρειάζεται η αποκρυπτογράφηση τους. Το αποτέλεσμα αυτών των υπολογισμών παραμένει κρυπτογραφημένο και όταν πλέον αποκρυπτογραφηθεί είναι πανομοιότυπο με το αποτέλεσμα που θα προέκυπτε αν οι ίδιες πράξεις είχαν εκτελεστεί στα αρχικά καθαρά δεδομένα. Η ιδέα αυτή παρουσιάστηκε αρχικά το 1978 [53], ωστόσο η πρώτη θεωρητικά πλήρης υλοποίηση (**Πλήρως Ομομορφική Κρυπτογράφηση (Fully Homomorphic Encryption - FHE)**) παρουσιάστηκε το 2009 [54].

2.5.1 Μαθηματικός Ορισμός και Ιδιότητες

Ένα κρυπτογραφικό σχήμα χαρακτηρίζεται ως Πλήρως Ομομορφικό αν υποστηρίζει την εκτέλεση αυθαίρετου αριθμού προσθέσεων και πολλαπλασιασμών επάνω στα κρυπτογραφημένα δείγματα. Έστω ότι $\mathcal{E}$ η συνάρτηση κρυπτογράφησης, $\mathcal{D}$ η συνάρτηση αποκρυπτογράφησης και m_1, m_2 δύο μηνύματα καθαρών δεδομένων. Ένα Πλήρως Ομομορφικό σχήμα πρέπει να ικανοποιεί την ιδιότητα του **Ομομορφισμού Πρόσθεσης**: $\mathcal{D}(\mathcal{E}(m_1) \oplus \mathcal{E}(m_2)) = m_1 + m_2$ και του **Ομομορφισμού Πολλαπλασιασμού**: $\mathcal{D}(\mathcal{E}(m_1) \otimes \mathcal{E}(m_2)) = m_1 \times m_2$ όπου $\oplus$ και $\otimes$ αντιπροσωπεύουν τις αντίστοιχες πράξεις



Σχήμα 2.16: Διάγραμμα Πλήρως Ομομορφικής Κρυπτογράφησης [14]

στον κρυπτογραφημένο χώρο. Οι δύο στοιχειώδεις αυτές πράξεις αρκούν για την κατασκευή οποιουδήποτε πολυωνυμικού υπολογισμού, καθιστώντας δυνατή την ασφαλή αξιολόγηση πολύπλοκων συναρτήσεων Μηχανικής Μάθησης σε μη έμπιστα περιβάλλοντα [55].

2.5.2 Το Σχήμα CKKS

Τα πρώτα σχήματα FHE σχεδιάστηκαν για να εκτελούν ακριβή αριθμητική αποκλειστικά πάνω σε ακέραιους αριθμούς. Ωστόσο, οι τεχνικές της Μηχανικής Μάθησης, όπως η ανανέωση των βαρών μέσω κλιμακωτής καθόδου ή η γραμμική παρεμβολή του αλγορίθμου SMOTE, απαιτούν πράξεις με πραγματικούς αριθμούς κινητής υποδιαστολής.

Προς την επίλυση αυτού του περιορισμού, εισήχθη το σχήμα **CKKS** [56] ένα σχήμα ομομορφικής κρυπτογράφησης προσεγγιστικής αριθμητικής. Η βασική του καινοτομία αποτελεί η εισαγωγή ενός παράγοντα κλιμάκωσης Δ , ο οποίος μετατρέπει τους πραγματικούς αριθμούς σε ακέραιους πριν την κρυπτογράφησή τους σε πολυωνυμικούς δακτυλίους.

Όσο πραγματοποιούνται οι ομομορφικοί πολλαπλασιασμοί, ο παράγοντας κλιμάκωσης αυξάνεται εκθετικά, εφόσον το γινόμενο δύο αριθμών κλιμακωμένων κατά Δ παράγει ένα αποτέλεσμα κλιμακωμένο κατά Δ^2 . Το σχήμα CKKS διαχειρίζεται αυτή την εκθετική αύξηση μέσω της ενσωματωμένης λειτουργίας επανακλιμάκωσης. Η λειτουργία αυτή μειώνει το μέγεθος του κρυπτοκειμένου και απορρίπτει τα λιγότερο σημαντικά ψηφία,

διατηρώντας την πολυπλοκότητα των δεδομένων διαχειρίσιμη και αποτρέποντας πιθανή υπερχείλιση. Στην παρούσα εργασία, το σχήμα CKKS αξιοποιείται, μέσω της βιβλιοθήκης TenSEAL για την δημιουργία κρυπτογραφημένων συνθετικών δειγμάτων στην προσέγγιση Trans-Client SMOTE.

Κεφάλαιο 3

Μεθοδολογία και Υλοποίηση

3.1 Παρουσίαση Συνόλων Δεδομένων

Για τους σκοπούς της ρεαλιστικής αποτίμησης της συμπεριφοράς των προαναφερθέντων αλγορίθμων σε συνδυασμό με τις τεχνικές υπερδειγματοληψίας που αναλύθηκαν, καθώς και για την πειραματική αξιολόγηση του πλαισίου FedSMOTE σε συνθήκες ακραίας Ανισορροπίας Κλάσεων, επιλέχθηκαν δύο ξεχωριστά σύνολα δεδομένων. Συγκεκριμένα, αξιοποιήθηκαν δύο θεμελιώδη σύνολα δεδομένων από τον χρηματοοικονομικό τομέα και την κυβερνοασφάλεια. Η επιλογή αυτή πραγματοποιήθηκε με γνώμονα την διασφάλιση ότι τα αποτελέσματα της παρούσας εργασίας αποδεικνύουν ισχυρή γενικευσιμότητα για το πλαίσιο FedSMOTE και ειδικότερα για την προσέγγιση Trans-Client SMOTE, η οποία αποτελεί πρωτότυπο προϊόν της εργασίας.


3.1.1 Σύνολο Δεδομένων Ανίχνευσης Χρηματοοικονομικής Απάτης (Credit Card Fraud Detection Dataset)

Το πρώτο σύνολο δεδομένων αφορά την ανίχνευση απατηλών συναλλαγών με πιστωτικές κάρτες. Συγκεκριμένα, το σύνολο περιέχει συναλλαγές που πραγματοποιήθηκαν από Ευρωπαίους κατόχους καρτών εντός δύο ημερών τον Σεπτέμβριο του 2013. Το σύνολο αυτό αποτελεί προϊόν της ερευνητικής ομάδας Machine Learning Group του Université Libre de Bruxelles (ULB) και διατίθεται δημόσια μέσω της πλατφόρμας Kaggle.

Το σύνολο δεδομένων αποτελείται συνολικά από 284.807 συναλλαγές. Οι απατηλές συναλλαγές εκπροσωπούνται μόνο από 492 δείγματα αντιπροσωπεύοντας μόλις το 0,173% του συνόλου. Ο Λόγος Ανισορροπίας προκύπτει ως: $IR = \frac{N_{maj}}{N_{min}} = \frac{284807}{492} \approx 577,9$, επιβεβαιώνοντας την παρουσία ακραίας ανισορροπίας.

Το σύνολο περιλαμβάνει 31 αριθμητικά χαρακτηριστικά. Λόγω αυστηρών περιορισμών

εμπιστευτικότητα και προστασίας προσωπικών δεδομένων, τα 28 από αυτά (V1-V28) έχουν υποστεί μετασχηματισμό μέσω Ανάλυσης Κύριων Συνιστώσων (Principal Component Analysis - PCA), η οποία αποτελεί δημοφιλή τεχνική Μείωσης Διαστατικότητας της Μη Επιβλεπόμενης Μάθησης. Τα μόνα χαρακτηριστικά που παρέχονται στην αρχική τους μορφή είναι ο Χρόνος (Time, τα δευτερόλεπτα που παρήλθαν από την πρώτη συναλλαγή) και το Ποσό (Amount, το χρηματικό ποσό της συναλλαγής). Για τους σκοπούς της εργασίας και την ορθή εκπαίδευση των αλγορίθμων, εφαρμόστηκε κανονικοποίηση σε όλα τα χαρακτηριστικά, εκτός από την μεταβλητή-στόχο, προκειμένου η κατανομή κάθε χαρακτηριστικού να έχει μέση τιμή 0 και τυπική απόκλιση ίση με 1. Η μεταβλητή-στόχος Class λαμβάνει την τιμή 0 για τις νόμιμες και 1 για τις απατηλές συναλλαγές.



Σχήμα 3.1: Ανισορροπία Κλάσεων στο Σύνολο Credit Card Fraud Detection

3.1.2 Σύνολο Δεδομένων NSL-KDD (User-to-Root Attacks)

Το δεύτερο σύνολο δεδομένων προέρχεται από τον τομέα της ανίχνευσης εισβολών σε δίκτυα. Για τις ανάγκες της εργασίας, τα πειράματα επικεντρώθηκαν στον διαχωρισμό της κανονικής δικτυακής κίνησης από τις επιθέσεις τύπου User-to-Root (U2R). Στις επιθέσεις τύπου U2R ο επιτιθέμενος ξεκινά με πρόσβαση ενός απλού χρήστη στο

σύστημα και προσπαθεί να εκμεταλλευτεί ευπάθειες για να αποκτήσει δικαιώματα διαχειριστή.


Το σύνολο περιέχει 41 χαρακτηριστικά τα οποία περιγράφουν τη δικτυακή ροή, χωρισμένα σε βασικά (διάρκεια, τύπος πρωτοκόλλου), χαρακτηριστικά περιεχομένου και στατιστικά χαρακτηριστικά κίνησης.

Ωστόσο, το σύνολο δεδομένων περιέχει δείγματα και από επιθέσεις άλλου τύπου (DoS, Probe, R2L). Εφόσον η εργασία πραγματεύεται την Ανισορροπία Κλάσεων σε προβλήματα δυαδικής ταξινόμησης, διατηρούνται μόνο τα δείγματα κανονικής κίνησης με ετικέτα normal και της κίνησης με ετικέτες επιθέσεων τύπου U2R, όπως buffer-overflow, loadmodule, perl, rootkit, sqlattack, xterm, ps. Έτσι, διαγράφονται τα υπόλοιπα δείγματα και το πρόβλημα ταξινόμησης μετατρέπεται σε δυαδικό, με την νόμιμη κίνηση να αποτελεί την κλάση 0 και τις επιθέσεις τύπου U2R να ομαδοποιούνται στην ενιαία κλάση 1. Παράλληλα, εφαρμόστηκε κωδικοποίηση στα κατηγορικά χαρακτηριστικά προκειμένου να μετασχηματιστούν σε αριθμητικά διανύσματα, εφόσον οι αλγόριθμοι δεν δέχονται κείμενο, μέσω Κωδικοποίησης One-Hot. Έπειτα, εφαρμόστηκε τυποποίηση στα αριθμητικά χαρακτηριστικά, λόγω ύπαρξης τεράστιων διακυμάνσεων και ακραίων τιμών.

Οι επιθέσεις U2R είναι εξαιρετικά σπάνιες και πολύπλοκες. Στο σύνολο δεδομένων NSL-KDD εντοπίζονται 67.343 δείγματα κανονικής κίνησης έναντι μόνο 52 δειγμάτων επιθέσεων τύπου U2R, αντιπροσωπεύοντας μόλις το 0,0772% του συνόλου. Ο Λόγος Ανισορροπίας προκύπτει ως: $IR = \frac{N_{maj}}{N_{min}} = \frac{67343}{52} \approx 1295.1$, επιβεβαιώνοντας την παρουσία ακραίας ανισορροπίας.

3.2 Μετρικές Αξιολόγησης

Η αξιολόγηση μοντέλων Μηχανικής Μάθησης σε περιβάλλοντα ακραίας Ανισορροπίας Κλάσεων καθιστά τη χρήση παραδοσιακών μετρικών, όπως η Καθολική Ακρίβεια, εντελώς λανθασμένη και παραπλανητική. Χρησιμοποιώντας το παράδειγμα του συνόλου δεδομένων Credit Card Fraud Detection, του οποίου η πλειοψηφική κλάση αποτελεί το 0,2% του συνόλου και όπως έχει προηγηθεί στην ανάλυση του θεωρητικού υπόβαθρου, ένα μοντέλο μπορεί να φτάσει επίπεδα καθολικής ακρίβειας ακόμα και γύρω στο 99,8%, απλώς ταξινομώντας όλες τις συναλλαγές ως νόμιμες. Ένα μοντέλο δηλαδή μπορεί να επιτύχει σχεδόν τέλεια απόδοση, χρησιμοποιώντας αποκλειστικά την μετρική της καθολικής ακρίβειας, με το να προβλέψει ότι κανένα δείγμα δεν ανήκει στην μειοψηφική κλάση. Ως επακόλουθο, προκύπτει η ανάγκη για την υιοθέτηση εξειδικευμένων μετρικών που εστιάζουν στη συμπεριφορά του μοντέλου ως προς τη μειοψηφική κλάση.



Σχήμα 3.2: Ανισορροπία Κλάσεων στο Σύνολο NSL-KDD

3.2.1 Πίνακας Σύγχυσης (Confusion Matrix)

Ο Πίνακας Σύγχυσης [57] αποτελεί τη βάση για τον υπολογισμό όλων των προηγμένων μετρικών σε προβλήματα δυαδικής ταξινόμησης. Πρόκειται για έναν πίνακα 2×2 που προορίζεται για την αποτύπωση των πραγματικών ετικέτων σε σχέση με τις προβλέψεις που κάνει το μοντέλο Μηχανικής Μάθησης. Τα τέσσερα στοιχεία του πίνακα, με σειρά από πάνω αριστερά προς κάτω δεξιά, αναλύονται ως εξής:

- **Αληθώς Αρνητικά (True Negatives - TN):** Αριθμός δειγμάτων της πλειοψηφικής κλάσης (κλάση 0) που το μοντέλο αναγνώρισε ορθά.
- **Ψευδώς Θετικά (False Positives - FP) - Σφάλμα Τύπου I:** Αριθμός δειγμάτων της πλειοψηφικής κλάσης που εσφαλμένα θεωρήθηκαν ως θετικά.
- **Ψευδώς Αρνητικά (False Negatives - FN) - Σφάλμα Τύπου II:** Αριθμός δειγμάτων της μειοψηφικής κλάσης που διέφυγαν της ανίχνευσης και ταξινομήθηκαν εσφαλμένα ως δείγματα της πλειοψηφικής κλάσης.
- **Αληθώς Θετικά (True Positives - TP):** Αριθμός δειγμάτων της μειοψηφικής κλάσης (κλάση 1) που το μοντέλο εντόπισε σωστά.

Γενικά, όσο περισσότερα στοιχεία υπάρχουν στην διαγώνιο του Πίνακα Σύγχυσης, τόσο καλύτερη αποδεικνύεται η επίδοση του ταξινομητή.

3.2.2 Precision, Recall, F1-Score


Αντλώντας τις πληροφορίες που παρέχει ο Πίνακας Σύγχυσης, ορίζονται οι τρεις σημαντικότερες μετρικές για την ποσοτικοποίηση της απόδοσης του μοντέλου στην μειονοτική κλάση [57].

Precision (Ακρίβεια)

Το **Precision** ποσοτικοποιεί την αξιοπιστία του μοντέλου όσον αφορά τις περιπτώσεις που αυτό θα προβλέψει ένα δείγμα ως θετικό, δηλαδή την Θετική Προγνωστική Αξία. Μαθηματικά εκφράζεται ως ο λόγος των σωστών θετικών προβλέψεων του μοντέλου προς το σύνολο των δειγμάτων που ταξινομήθηκαν ως θετικά:

$$Precision = \frac{TP}{TP+FP}.$$

Σε πραγματικές εφαρμογές, χαμηλά επίπεδα Precision συνεπάγονται πάρα πολλές περιπτώσεις Εσφαλμένων Συναγερμών (False Positives), οδηγώντας στη αύξηση των λειτουργικών κόστων για τον πελάτη-οργανισμό.



Σχήμα 3.3: Παράδειγμα Πίνακα Σύγχυσης στο Σύνολο Credit Card Fraud Detection

Recall (Ανάκληση)

Το **Recall** ποσοτικοποιεί την ικανότητα του μοντέλου να εντοπίζει τον πραγματικό κίνδυνο, δηλαδή το Ποσοστό Αληθώς Θετικών. Μαθηματικά εκφράζεται ως ο λόγος των σωστών θετικών προβλέψεων του μοντέλου προς το σύνολο των πραγματικά θετικών δειγμάτων:

$$Recall = \frac{TP}{TP+FN}.$$

Το Recall αποτελεί την πιο κρίσιμη μετρική σε περιβάλλοντα όπου η μη ανίχνευση του συμβάντος ενδιαφέροντος ενέχει σημαντικά υψηλούς κινδύνους. Ένα μοντέλο με χαμηλά επίπεδα Recall αποτυγχάνει ουσιαστικά στον βασικό του σκοπό, εφόσον επιτρέπει περιπτώσεις της μειονοτικής κλάσης να περνάνε από το σύστημα απαρατήρητες.

F1-Score

Το **F1-Score** προκύπτει από την εγγενή σχέση ανταλλαγής που υπάρχει μεταξύ Precision και Recall και αποτελεί τον αρμονικό μέσο τους. Μαθηματικά εκφράζεται ως:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}.$$

Σε προβλήματα όπου παρουσιάζεται Ανισορροπία Κλάσεων, το F1-Score αποτελεί τον πιο ισχυρό δείκτη αξιολόγησης, ειδικά όσον αφορά την απόδοση του μοντέλου στην μειοψηφική κλάση. Το F1-Score λαμβάνει υψηλές τιμές μόνο στην περίπτωση που το μοντέλο πετύχει ταυτόχρονα υψηλά επίπεδα Precision και υψηλά επίπεδα Recall, αγνοώντας πλήρως τον όγκο των Αληθώς Αρνητικών δειγμάτων, τα οποία παραμορφώνουν την τιμή της Καθολικής Ακρίβειας.

Στα πλαίσια της τρέχουσας εργασίας, η αξιολόγηση των διάφορων πειραμάτων βασίζεται κυρίως στην μετρική F1-Score της μειοψηφικής κλάσης.

3.2.3 Καμπύλες Επίδοσης (ROC-AUC & Average Precision)

Εφόσον τα στατιστικά μοντέλα μπορούν να έχουν ως έξοδο την πιθανότητα υπαγωγής ενός δείγματος σε μία κλάση, η αξιολόγηση τους σε πολλαπλά κατώφλια απόφασης παρέχει μια πιο ολοκληρωμένη εικόνα της διαχωριστικής τους ικανότητας.

ROC-AUC (Receiver Operating Characteristic - Area Under Curve)

Η καμπύλη **ROC** [58] αποτελεί μια γραφική παράσταση η οποία απεικονίζει την απόδοση του μοντέλου σε όλα τα πιθανά κατώφλια ταξινόμησης. Σε αυτό το γράφημα, ο άξονας Y αντιπροσωπεύει το Ποσοστό Αληθώς Θετικών ($TPR = Recall = \frac{TP}{TP+FN}$), δηλαδή το ποσοστό των πραγματικά θετικών που το μοντέλο εντόπισε σωστά, ενώ ο άξονας X

αντιπροσωπεύει το Ποσοστό Ψευδώς Θετικών ($FPR = \frac{FP}{TN+FP}$), δηλαδή το ποσοστό των πραγματικά αρνητικών που το μοντέλο ταξινόμησε λανθασμένα ως θετικά (Εσφαλμένοι Συναγερμοί). Στην θεωρητικά ιδανική περίπτωση, μια καμπύλη ROC πλησιάζει την πάνω αριστερή γωνία, εφόσον το ιδανικό TPR παίρνει τιμή 1, ενώ το ιδανικό FPR παίρνει τιμή 0. Η διαγώνια γραμμή στη μέση του γραφήματος αναπαριστά ένα μοντέλο που κάνει προβλέψεις εντελώς στην τύχη.

Το **AUC** μετράει το συνολικό εμβαδόν κάτω από την καμπύλη ROC: $AUC = \int_0^1 TPR(FPR^{-1}(x))dx$. Ουσιαστικά, αποτελεί την απεικόνιση της απόδοσης του μοντέλου ανεξαρτήτως κατωφλίου σε έναν αριθμό μέσα στο διάστημα από το 0 έως το 1. Υπάρχουν χαρακτηριστικές περιπτώσεις της τιμής AUC που υποδηλώνουν συγκεκριμένα χαρακτηριστικά της απόδοσης του μοντέλου. Συγκεκριμένα, στην περίπτωση που $AUC = 1.0$, τότε το μοντέλο είναι τέλειο και διαχωρίζει απόλυτα τις δύο κλάσεις, χωρίς κανένα λάθος. Ενώ, στην περίπτωση που $AUC = 0.5$, το μοντέλο δεν μαθαίνει τίποτα από το σύνολο εκπαίδευσης και απλώς κάνει τις προβλέψεις του εντελώς στην τύχη. Ταυτόχρονα, στην περίπτωση που $AUC < 0.5$, το μοντέλο είναι χειρότερο ακόμα και από την τύχη, που σημαίνει ότι έχει γίνει κάποιο καταστροφικό λάθος και αυτό κάνει αντίθετες προβλέψεις από ότι θα έπρεπε.

Πρακτικά, το AUC δείχνει πόσο καλά το μοντέλο κατατάσσει τις προβλέψεις του. Για παράδειγμα, αν το AUC έχει τιμή 0.8, σημαίνει ότι υπάρχει 80% πιθανότητα το μοντέλο να δώσει μεγαλύτερη πιθανότητα σε ένα θετικό δείγμα παρά σε ένα αρνητικό.


Η ROC-AUC αποτελεί την δεύτερη μετρική στην οποία βασίζεται η αξιολόγηση της απόδοσης των διάφορων πειραμάτων της τρέχουσας εργασίας.

Average Precision - Precision Recall Curve

Η καμπύλη **Precision Recall Curve** [59] προκύπτει από τη γραφική παράσταση του Precision στον άξονα Y σε συνάρτηση με το Recall στον άξονα X για ένα συνεχές φάσμα τιμών του κατωφλίου απόφασης. Στην θεωρητικά ιδανική περίπτωση, η καμπύλη αυτή διέρχεται από το σημείο (1,1), δηλαδή την πάνω δεξιά γωνία, γεγονός που υποδηλώνει ταυτόχρονα μέγιστες τιμές για Precision και Recall.

Ωστόσο, υπάρχει ένας εγγενής συμβιβασμός μεταξύ αυτών των δύο μετρικών. Αυτός ο συμβιβασμός πηγάζει από το γεγονός ότι όσο το κατώφλι ταξινόμησης μειώνεται με σκοπό την αύξηση του Recall του μοντέλου και τον επακόλουθο του εντοπισμό περισσότερων θετικών δειγμάτων, ταυτόχρονα αυξάνεται και ο αριθμός των εσφαλμένων θετικών ταξινομήσεων (FP), το οποίο οδηγεί σε πτώση του Precision.

Η μετρική του **Average Precision** πρακτικά συνοψίζει την πληροφορία που παρέχει η καμπύλη Precision-Recall σε μια ενιαία αριθμητική τιμή, εκφράζοντας ουσιαστικά το




Σχήμα 3.4: Παράδειγμα Καμπύλης ROC στο Σύνολο Credit Card Fraud Detection

εμβαδόν κάτω από την καμπύλη (Area Under the PR Curve - AUPRC). Μαθηματικά, το Average Precision ορίζεται ως το ολοκλήρωμα της συνάρτησης του Precision ως προς το Recall: $AP = \int_0^1 \text{Precision}(\text{Recall})d(\text{Recall})$.

Πρακτικά ωστόσο τα πραγματικά σύνολα δεδομένων αποτελούνται από διακριτά δείγματα και η καμπύλη δεν είναι απολύτως συνεχής. Ως αποτέλεσμα η τιμή του Average Precision υπολογίζεται συνήθως ως το σταθμισμένο άθροισμα των τιμών του Precision σε κάθε κατώφλι, με βάρη την εκάστοτε μεταβολή του Recall σε σχέση με το προηγούμενο κατώφλι: $AP = \sum_n (\text{Recall}_n - \text{Recall}_{n-1}) * \text{Precision}_n$.

Η τιμή του AP κυμαίνεται στο διάστημα $[0,1]$. Στην περίπτωση που η τιμή του ισούται με 1.0, αυτό αντιπροσωπεύει τον τέλειο ταξινομητή. Η επίδοση ενός τυχαίου ταξινομητή δεν ισούται σταθερά με 0.5, αλλά αντιστοιχεί ακριβώς στο ποσοστό της θετικής κλάσης στο σύνολο δεδομένων.



Σχήμα 3.5: Παράδειγμα Καμπύλης Precision-Recall στο Σύνολο Credit Card Fraud Detection

Πλεονέκτημα της Average Precision έναντι της ROC-AUC

Η μετρική Average Precision έχει σχεδιαστεί ειδικά για περιπτώσεις όπου υπάρχει ακραία Ανισορροπία Κλάσεων. Η θεμελιώδης διαφορά και το κύριο πλεονέκτημά της Average Precision έναντι της ROC-AUC εγκείται στην απουσία των Αληθώς Αρνητικών δειγμάτων από τον υπολογισμό της [60].

Σε προβλήματα όπου υπάρχει ακραία Ανισορροπία Κλάσεων, η μετρική ROC-AUC ενδέχεται να καταστεί παραπλανητική. Σε τέτοια σενάρια, ένας μεγάλος αριθμός Ψευδώς Θετικών (FP) ενδέχεται να έχει αμελητέα επίπτωση στο Ποσοστό Ψευδώς Θετικών ($FPR = \frac{FP}{FP+TN}$) της καμπύλης ROC, εξαιτίας της παρουσίας ενός τεράστιου όγκου Αληθώς Αρνητικών (TN). Έτσι, η ROC-AUC μπορεί να παρουσιάζει τεχνητά αισιόδοξες επιδόσεις.

Αντίθετα, η Average Precision αξιολογεί την προγνωστική ικανότητα του μοντέλου εστιάζοντας αποκλειστικά στην θετική κλάση και στα σφάλματα που αφορούν μόνο αυτήν (FP και FN). Ως αποτέλεσμα, προσφέρει μια πιο αυστηρή και αξιόπιστη αποτίμηση της απόδοσης του αλγορίθμου όταν αυτός καλείται να διαχειριστεί έντονα ανισόρροπα σύνολα δεδομένων.

Η Average Precision αποτελεί την τρίτη μετρική στην οποία βασίζεται η αξιολόγηση της απόδοσης των διάφορων πειραμάτων της τρέχουσας εργασίας.

3.3 Αρχιτεκτονική Νευρωνικών Δικτύων

3.3.1 MLP

Για την ταξινόμηση των δειγμάτων σε κεντριοποιημένο και ομοσπονδιακό περιβάλλον, υλοποιήθηκε ένα πρόσθιας τροφοδότησης νευρωνικό δίκτυο τύπου MLP. Η αρχιτεκτονική ακολουθεί μια αυστηρή στρατηγική σταδιακής συμπίεσης της πληροφορίας με τη δομή $d \rightarrow 64 \rightarrow 32 \rightarrow 16 \rightarrow 1$, όπου d είναι η διάσταση του διανύσματος εισόδου.

Προκειμένου να διασφαλιστεί η ταχεία σύγκλιση και η ικανότητα γενίκευσης του μοντέλου, κάθε κρυφό επίπεδο ενισχύθηκε με μηχανισμούς Κανονικοποίησης Δεσμής (Batch Normalization) και Απόρριψης Νευρώνων (Dropout). Σε κάθε επίπεδο l η μαθηματική επεξεργασία που ακολουθείται αναλύεται ως εξής:

1. **Γραμμικός Μετασχηματισμός:** Υπολογίζεται η μη κανονικοποιημένη έξοδος

$$z^{(l)} = W^{(l)}h^{(l-1)} + b^{(l)}, \text{ όπου}$$

- $z^{(l)}$ είναι το διάνυσμα της μη κανονικοποιημένης εξόδου του επιπέδου l ,

- $\mathbf{W}^{(l)}$ ο πίνακας βαρών του επιπέδου l . Τα στοιχεία του δείχνουν την δύναμη της σύνδεσης μεταξύ των τεχνητών νευρώνων του προηγούμενου και του τρέχοντος επιπέδου,
- $\mathbf{h}^{(l-1)}$ το διάνυσμα εξόδου του προηγούμενου επιπέδου $l - 1$. Αν το επίπεδο l είναι το πρώτο κρυφό επίπεδο του δικτύου, τότε το $\mathbf{h}^{(0)}$ αντιπροσωπεύει τα αρχικά δεδομένα εισόδου και
- $\mathbf{b}^{(l)}$ το διάνυσμα πόλωσης του επιπέδου l . Λειτουργεί μετατοπίζοντας την έξοδο, δίνοντας στο μοντέλο μεγαλύτερη ευελιξία στην προσαρμογή του ως προς τα δεδομένα.

2. **Μη Γραμμική Ενεργοποίηση:** Εφαρμόζεται η συνάρτηση ReLU, $a^{(l)} = \max(0, z^{(l)})$, όπου

- $a^{(l)}$ είναι η έξοδος μετά την ενεργοποίηση,
- $z^{(l)}$ η είσοδος στην συνάρτηση και
- $\max(0, z^{(l)})$ η συνάρτηση **ReLU** (Rectified Linear Unit). Η λειτουργία της προσομοιάζει μια απλή λογική πύλη, όπου αν η είσοδος είναι αρνητική βγάζει 0, ενώ αν η είσοδος είναι θετική την αφήνει να περάσει ως έχει.

3. **Κανονικοποίηση Δέσμης:** Για την αντιμετώπιση του φαινομένου της εσωτερικής μεταβολής των συνδιακυμάνσεων, εφαρμόζεται ο μετασχηματισμός $\hat{a}^{(l)} = \gamma^{(l)} \frac{a^{(l)} - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta^{(l)}$, όπου

- $\hat{a}^{(l)}$ είναι η κανονικοποιημένη έξοδος,
- $a^{(l)}$ το αποτέλεσμα από το βήμα 2, το οποίο τροφοδοτείται εδώ ως είσοδος,
- μ_B η μέση τιμή των τιμών του $z^{(l)}$ για τη συγκεκριμένη δέσμη δεδομένων,
- σ_B^2 η διασπορά των τιμών του $z^{(l)}$ για τη συγκεκριμένη δέσμη δεδομένων,
- ϵ μια πολύ μικρή σταθερά που προστίθεται στον παρονομαστή καθαρά για μαθηματική ευστάθεια,
- $\gamma^{(l)}$ η εκπαιδεύσιμη παράμετρος κλιμάκωσης. Το δίκτυο τη μαθαίνει για να μπορεί να κλιμακώσει τις τιμές των δεδομένων σε περίπτωση που χρειαστεί και
- $\beta^{(l)}$ η εκπαιδεύσιμη παράμετρος μετατόπισης. Το δίκτυο τη μαθαίνει για την μετατόπιση της κατανομής των τιμών

4. **Απόρριψη Νευρώνων:** Για τον περιορισμό της υπερπροσαρμογής, απενεργοποιούνται τυχαίοι νευρώνες, εφαρμόζοντας την συνάρτηση $\mathbf{h}^{(l)} = \hat{\mathbf{a}}^{(l)} \odot \mathbf{r}$, όπου

- $\mathbf{h}^{(l)}$ είναι η τελική έξοδος του επιπέδου l . Αυτό το διάνυσμα έπειτα θα αποτελέσει την είσοδο $\mathbf{h}^{(l)}$ για τον υπολογισμό του γραμμικού μετασχηματισμού στο επόμενο επίπεδο $l + 1$,
- $\hat{\mathbf{a}}^{(l)}$ η έξοδος της κανονικοποίησης δέσμης,
- $\odot$ ο τελεστής πολλαπλασιασμού κατά στοιχείο, ο οποίος πολλαπλασιάζει τα στοιχεία του $\hat{\mathbf{a}}^{(l)}$ ένα προς ένα με τα αντίστοιχα του $\mathbf{r}$,
- $\mathbf{r}$ ένα διάνυσμα-μάσκα που αποτελείται από άσους και μηδενικά και παράγεται από την κατανομή Bernoulli και $p = 0.3$ η πιθανότητα ένα στοιχείο του διανύσματος $\mathbf{r}$ να γίνει 0. Πρακτικά, αυτό σημαίνει ότι κατά την εκπαίδευση, το 30% των νευρώνων αυτού του επιπέδου θα απενεργοποιηθεί εντελώς τυχάια, αναγκάζοντας τους υπόλοιπους νευρώνες να δουλέψουν πιο σκληρά και ανεξάρτητα.

5. **Σιγμοειδής Συνάρτηση:** Εξαίρεση αποτελεί το επίπεδο εξόδου, όπου μετά τον γραμμικό μετασχηματισμό, εφαρμόζεται μόνο η Σιγμοειδής Συνάρτηση $\hat{y} = \sigma(\mathbf{h}^{(l)}) = \frac{1}{1+e^{-\mathbf{h}^{(l)}}}$, όπου

- $\hat{y}$ είναι η τελική έξοδος και πρόβλεψη του δικτύου,
- $\mathbf{h}^{(l)}$ η έξοδος του τελευταίου κρυφού επιπέδου και είσοδος του επιπέδου εξόδου

Συνοψίζοντας, η τελική δομή του νευρωνικού δικτύου MLP αναλύεται ως εξής:

- **Επίπεδο Εισόδου:** Linear(d,64) + ReLU + BatchNorm(64) + Dropout(0.3)
- **Κρυφό Επίπεδο 1:** Linear(64,32) + ReLU + BatchNorm(32) + Dropout(0.3)
- **Κρυφό Επίπεδο 2:** Linear(32,16) + ReLU + BatchNorm(16) + Dropout(0.3)
- **Επίπεδο Εξόδου:** Linear(16,1) + Sigmoid

Η συγκεκριμένη πολυστρωματική δομή επιτρέπει στο μοντέλο να εξάγει ιεραρχικά χαρακτηριστικά από τα σύνθετα μη-γραμμικά δεδομένα εκπαίδευσης, ξεκινώντας από απλούς γραμμικούς συνδυασμούς και καταλήγοντας σε σύνθετες μη γραμμικές συσχετίσεις, πριν την τελική ταξινόμηση. Η ενσωμάτωση της Κανονικοποίησης Δέσμης είναι ιδιαίτερα κρίσιμη στην Ομοσπονδιακή Μάθηση, καθώς βοηθά στην εξομάλυνση των διαφορών μεταξύ των τοπικών κλίσεων που προκύπτουν από την στατιστική ετερογένεια των πελατών-κόμβων.

3.3.2 GAN

Γεννήτορας (Generator)

Ο Γεννήτορας ορίζεται ως μια παραγωγίσιμη συνάρτηση $G(\mathbf{z}; \theta_g)$, η οποία χαρτογραφεί το διάνυσμα θορύβου $\mathbf{z}$ από ένα λανθάνοντα χώρο χαμηλής διάστασης στον χώρο των πραγματικών δεδομένων. Συγκεκριμένα, η δομή του Γεννήτορα αναλύεται ως εξής:

- **Επίπεδο Εισόδου:** $\text{Linear}(d_l, 64) + \text{ReLU}$, όπου d_l είναι η διάσταση του λανθάνοντα χώρου και στα πειράματα έχει οριστεί ίση με 32,
- **Κρυφό Επίπεδο:** $\text{Linear}(64, 128) + \text{ReLU}$,
- **Επίπεδο Εξόδου:** $\text{Linear}(128, d_d) + \text{Tanh}$, όπου d_d είναι η διάσταση των πραγματικών δεδομένων.

Στο επίπεδο εξόδου, εφαρμόζεται η συνάρτηση $\text{Tanh} = \frac{e^x - e^{-x}}{e^x + e^{-x}}$, η οποία καθίσταται κρίσιμη για την σταθερότητα, εφόσον περιορίζει την έξοδο στο διάστημα $(-1, 1)$, ευθυγραμμίζοντας τα συνθετικά δεδομένα με το εύρος των κανονικοποιημένων πραγματικών δεδομένων.

Διαχωριστής (Discriminator)

Ο Διαχωριστής λειτουργεί ως ένας ταξινομητής $D(\mathbf{x}; \theta_d)$, ο οποίος εκτιμά την πιθανότητα ένα δείγμα $\mathbf{x}$ να προέρχεται από τα πραγματικά δεδομένα και όχι από τον Γεννήτορα. Συγκεκριμένα, η δομή του Διαχωριστή αναλύεται ως εξής:

- **Επίπεδο Εισόδου:** $\text{Linear}(d_d, 128) + \text{ReLU}$, όπου d_d είναι η διάσταση των πραγματικών δεδομένων,
- **Κρυφό Επίπεδο:** $\text{Linear}(128, 64) + \text{ReLU}$,
- **Επίπεδο Εξόδου:** $\text{Linear}(64, 1) + \text{Sigmoid}$.

Στο επίπεδο εξόδου, εφαρμόζεται η σιγμοειδής συνάρτηση προκειμένου να εξαχθεί η τελική πρόβλεψη του δικτύου σχετικά με την φύση των δεδομένων που του τροφοδοτήθηκαν.

3.4 Ομοσπονδιακό Περιβάλλον

3.4.1 Ομοσπονδιακή Αρχιτεκτονική και Πρωτόκολλο Εκπαίδευσης & Αξιολόγησης

Για την προσομοίωση ενός Ομοσπονδιακού Περιβάλλοντος, το διαθέσιμο σύνολο δεδομένων κατανεμήθηκε σε $K = 5$ διακριτούς κόμβους-πελάτες. Πριν πραγματοποιηθεί αυτός ο τοπικός διαμοιρασμός, απομονώθηκε κεντρικά ένα ποσοστό 20% των συνολικών δεδομένων, το οποίο λειτούργησε ως ένα παγκόσμιο σύνολο αξιολόγησης υπό την εποπτεία του κεντρικού διακομιστή. Η στρατηγική αυτή διασφαλίζει την αμερόληπτη και αντικειμενική αξιολόγηση της γενίκευσης του παγκόσμιου μοντέλου στο τέλος κάθε γύρου επικοινωνίας.

Το πρωτόκολλο εκπαίδευσης σχεδιάστηκε στα πρότυπα της αρχιτεκτονικής Cross-silo, προσομοιώνοντας τη συνεργασία μεταξύ αξιόπιστων και ισχυρών οργανισμών. Βάσει αυτής της παραδοχής, θεωρείται ότι η συστημική ετερογένεια, όπως οι περιορισμοί υπολογιστικής ισχύος και καθυστερήσεις δικτύου, είναι αμελητέα. Συνεπώς, σε κάθε γύρο ομοσπονδιακής εκπαίδευσης εφαρμόζεται πλήρης συμμετοχή, με το σύνολο των 5 κόμβων-πελατών να συνεισφέρει ενεργά στην ανανέωση των βαρών.

Η εκπαίδευση του ομοσπονδιακού μοντέλου υλοποιείται μέσω μιας επαναληπτικής διαδικασίας συγχρονισμού μεταξύ του κεντρικού διακομιστή και των επιμέρους κόμβων-πελατών. Κάθε πλήρης κύκλος αυτής της διαδικασίας ορίζεται ως ένας γύρος επικοινωνίας. Η εκτέλεση του κάθε γύρου απαρτίζεται από τα στάδια της τοπικής βελτιστοποίησης στους κόμβους-πελάτες και την παγκόσμια συνάθροιση και αξιολόγηση στον κεντρικό διακομιστή.

Τοπική Εκπαίδευση

Κατά την έναρξη του γύρου t , ο κεντρικός διακομιστής μεταδίδει το τρέχον διάνυσμα βαρών του παγκόσμιου μοντέλου $\mathbf{w}_t$ στους συμμετέχοντες κόμβους-πελάτες. Κάθε πελάτης k αρχικοποιεί το τοπικό του μοντέλο με αυτά τα βάρη και εκτελεί ανεξάρτητη τοπική εκπαίδευση χρησιμοποιώντας το δικό του τοπικό σύνολο δεδομένων $\mathcal{D}_k$. Η τοπική εκπαίδευση διαρκεί για έναν προκαθορισμένο αριθμό τοπικών εποχών E . Παράλληλα, αξιοποιούνται ως συνάρτηση απώλειας η δυαδική διασταυρούμενη εντροπία με logits και ως αλγόριθμος βελτιστοποίησης ο αλγόριθμος Adam. Ταυτόχρονα, η ίδια διαδικασία ακολουθείται και στην κεντριοποιημένη περίπτωση.

Συνάρτηση Απώλειας: Δυναμική Διασταυρούμενη Εντροπία με Logits (BCEWithLogitsLoss)

Στην εκπαίδευση του Νευρωνικού Δικτύου MLP, σε κεντρικοποιημένο και σε ομοσπονδιακό επίπεδο, η βελτιστοποίηση των βαρών πραγματοποιείται μέσω της ελαχιστοποίησης μιας συνάρτησης κόστους. Στην παρούσα εργασία, ως συνάρτηση κόστους/απώλειας, επιλέχθηκε η Δυναμική Διασταυρούμενη Εντροπία συνδυασμένη με τα Logits του δικτύου (BCEWithLogitsLoss) [61].

Μαθηματικά, η τυπική Δυναμική Διασταυρούμενη Εντροπία (BCE) μεταξύ της πραγματικής ετικέτας $y \in \{0, 1\}$ και της προβλεπόμενης πιθανότητας $\hat{y} \in (0, 1)$ ορίζεται ως: $\mathcal{L}_{BCE}(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$.

Για να παραχθεί η πιθανότητα $\hat{y}$, η ακατέργαστη έξοδος του τελευταίου γραμμικού επιπέδου του νευρωνικού δικτύου (έστω $z \in \mathbb{R}$, γνωστή ως logit) περνάει μέσα από μια σιγμοειδή συνάρτηση ενεργοποίησης: $\hat{y} = \sigma(z) = \frac{1}{1+e^{-z}}$.

Με την διαδοχική και ανεξάρτητη εφαρμογή αυτών των δύο πράξεων, το σύστημα καθίσταται εξαιρετικά ευάλωτο σε προβλήματα αριθμητικής αστάθειας. Συγκεκριμένα, για μεγάλες αρνητικές τιμές του z , ο όρος e^{-z} τείνει στο άπειρο, προκαλώντας υπολογιστική υπερχείλιση, ενώ ταυτόχρονα η $\hat{y}$ στρογγυλοποιείται στο 0, οδηγώντας τον υπολογισμό του $\log(0)$ σε απροσδιοριστία.

Η συνάρτηση BCEWithLogitsLoss επιλύει αυτό το υπολογιστικό κενό ενσωματώνοντας αναλυτικά τη σιγμοειδή συνάρτηση μέσα στην εξίσωση της εντροπίας. Αντικαθιστώντας την $\sigma(z)$ στην $\mathcal{L}_{BCE}$ και αξιοποιώντας ιδιότητες των λογαρίθμων, η συνάρτηση απώλειας διατυπώνεται ως εξής: $\mathcal{L}(y, z) = \max(z, 0) - zy + \log(1 + e^{-|z|})$.

Η εισαγωγή της απόλυτης τιμής $|z|$ στον εκθέτη και η χρήση της συνάρτησης $\max$ εγγυώνται την απόλυτη αριθμητική ευστάθεια κατά τον υπολογισμό της κλίσης $\nabla \mathcal{L}$. Αυτό είναι ζωτικής σημασίας στην Ομοσπονδιακή Μάθηση, αφού οι εκρηκτικές κλίσεις σε τοπικό επίπεδο μπορούν να διαφθείρουν ανεπανόρθωτα την παγκόσμια συνάθροιση βαρών του αλγορίθμου FedAvg.

Πέραν του ρόλου της στη βελτιστοποίηση, η συστηματική καταγραφή της παγκόσμιας απώλειας στην εκπαίδευση ανά γύρο επικοινωνίας αποτελεί τον κυριότερο διαγνωστικό δείκτη σύγκλισης του συστήματος. Σε περιβάλλοντα με Ανισορροπία Κλάσεων, οι αντιφατικές τοπικές κλίσεις των κόμβων-πελατών προκαλούν το φαινόμενο της απόκλισης, το οποίο αποτυπώνεται ως έντονες διακυμάνσεις και αδυναμία ελαχιστοποίησης της καμπύλης της απώλειας.

Αλγόριθμος Βελτιστοποίησης Adam (Adaptive Moment Estimation)

Για την ενημέρωση των βαρών των τοπικών νευρωνικών δικτύων MLP, καθώς και του κεντριοποιημένου GAN, επελέγη ο αλγόριθμος βελτιστοποίησης Adam [62]. Ο Adam αποτελεί μια προηγμένη μέθοδο στοχαστικής βελτιστοποίησης η οποία συνδυάζει τα πλεονεκτήματα δύο άλλων δημοφιλών μεθόδων, του AdaGrad και του RMSProp.

Βασική καινοτομία αυτού του αλγορίθμου αποτελεί ο υπολογισμός προσαρμοστικών ρυθμών εκμάθησης για κάθε παράμετρο ξεχωριστά, αξιοποιώντας εκτιμήσεις την πρώτης και δεύτερης ροπής των κλίσεων. Μαθηματικά, έστω g_t η κλίση της αντικειμενικής συνάρτησης ως προς τις παραμέτρους θ στο χρονικό βήμα t . Ο αλγόριθμος υπολογίζει τον εκθετικά κινούμενο μέσο όρο των κλίσεων (πρώτη ροπή, m_t) και των τετραγώνων των κλίσεων (δεύτερη μη κεντρική ροπή, v_t) ως εξής: $m_t = \beta_1 m_{t-1} + (1 - \beta_1)g_t$, $v_t = \beta_2 v_{t-1} + (1 - \beta_2)g_t^2$ όπου β_1 και β_2 οι υπερπαραμέτροι που ελέγχουν τον ρυθμό απόσβεσης των κινητών μέσων όρων, με τυπικές τιμές $\beta_1 = 0.9$ και $\beta_2 = 0.999$.

Επειδή τα διανύσματα m_t και v_t αρχικοποιούνται ως μηδενικά, παρατηρείται μια μεροληψία προς το μηδέν κατά τα πρώτα βήματα της εκπαίδευσης. Για την εξάλειψη αυτής της μεροληψίας, ο αλγόριθμος Adam εφαρμόζει μια διόρθωση, εξάγοντας τις διορθωμένες εκτιμήσεις $\hat{m}_t$ και $\hat{v}_t$ ως εξής: $\hat{m}_t = \frac{m_t}{1-\beta_1^t}$, $\hat{v}_t = \frac{v_t}{1-\beta_2^t}$.

Τέλος, ο κανόνας ανανέωσης των παραμέτρων του μοντέλου διαμορφώνεται ως: $\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$ όπου η είναι ο αρχικός ρυθμός εκμάθησης και ϵ μια πολύ μικρή σταθερά για σκοπούς αριθμητικής ευστάθειας.

Η εφαρμογή του Adam σε ομοσπονδιακά περιβάλλοντα, και ειδικά υπό ακραία Non-IID κατανομή κλάσεων, αποδεικνύεται στρατηγικής σημασίας, εφόσον οι κλίσεις που υπολογίζονται τοπικά από τους πελάτες παρουσιάζουν υψηλή διακύμανση και θόρυβο. Ο Adam, εξομαλύνοντας την πορεία μέσω της πρώτης ροπής και προσαρμόζοντας το βήμα μέσω της δεύτερης, επιτυγχάνει ταχύτερη και πιο σταθερή σύγκλιση. Ταυτόχρονα, έχει αποδειχθεί βιβλιογραφικά πως η εκπαίδευση αρχιτεκτονικών GAN είναι εξαιρετικά ασταθής. Η ικανότητα του Adam να διατηρεί διαφορετικό ρυθμό εκμάθησης για κάθε βάρος του δικτύου, αποτρέπει τις απότομες ταλαντώσεις κατά τη διάρκεια του ανταγωνιστικού παιχνιδιού μεταξύ Γεννήτορα και Διαχωριστή.

Global Συνάθροιση

Αφού ολοκληρωθούν οι E εποχές τοπικής εκπαίδευσης, οι πελάτες αποστέλλουν τα επικαιροποιημένα τοπικά τους βάρη w_{t+1}^k πίσω στον κεντρικό διακομιστή. Για τη σύνθεση του νέου παγκόσμιου μοντέλου, εφαρμόζεται ο αλγόριθμος FedAvg. Ο κεντρικός διακομιστής υπολογίζει τον σταθμισμένο μέσο όρο των παραμέτρων, δίνοντας βαρύτητα ανάλογη του πλήθους των δεδομένων n_k κάθε κόμβου-πελάτη σε σχέση με το συνολικό

πλήθος δειγμάτων n : $\mathbf{w}_{t+1} = \sum_{k=1}^K \frac{n_k}{n} \mathbf{w}_{t+1}^k$

Αξιολόγηση και Επιλογή Βέλτιστου Μοντέλου

Με την ολοκλήρωση της συνάθροισης σε κάθε γύρο επικοινωνίας, το νέο παγκόσμιο μοντέλο $\mathbf{w}_{t+1}$ υποβάλλεται σε διαδικασία επικύρωσης. Η αξιολόγηση πραγματοποιείται αποκλειστικά στον κεντρικό συντονιστή, χρησιμοποιώντας το ανεξάρτητο υποσύνολο δεδομένων που είχε κρατηθεί αρχικά.

Λόγω της στοχαστικής φύσης της εκπαίδευσης και της πιθανής αστάθειας που εισάγει η Ανισορροπία Κλάσεων και η δομή του νευρωνικού δικτύου, η τελική επιλογή του μοντέλου δεν βασίζεται απαραίτητα στον τελευταίο γύρο επικοινωνίας. Αντίθετα, εφαρμόζεται μια στρατηγική διατήρησης της βέλτιστης κατάστασης. Καθ'όλη τη διάρκεια της ομοσπονδιακής διαδικασίας, παρακολουθείται η επίδοση του μοντέλου ως προς το F1-Score της μειοψηφικής κλάσης, καθώς αποτελεί την πλέον αντιπροσωπευτική μετρική για την ισορροπία μεταξύ Precision και Recall. Το μοντέλο που επιτυγχάνει την μέγιστη τιμή F1-Score στο σύνολο δεδομένων αξιολόγησης αποθηκεύεται ως το βέλτιστο μοντέλο, διασφαλίζοντας ότι η τελική αξιολόγηση και εξαγωγή συμπερασμάτων θα βασιστούν στην ποιοτικότερη δυνατή σύγκλιση που επιτεύχθηκε κατά την πειραματική διαδικασία.

Υπερπαράμετροι Εκπαίδευσης (Training Hyperparameters)

Για την εξασφάλιση της αναπαραγωγιμότητας των πειραμάτων και τη βέλτιστη σύγκλιση των μοντέλων, ορίστηκαν οι ακόλουθες υπερπαράμετροι, οι οποίες διατηρήθηκαν σταθερές σε όλα τα σενάρια κατανομής δεδομένων:

- **Αριθμός Κόμβων-Πελατών (Number of Clients):** 5
- **Γύροι Επικοινωνίας (Communication Rounds):** 20
- **Τοπικές Εποχές (Local Epochs):** 3
- **Μέγεθος Δέσμης (Batch Size):** 512
- **Ρυθμός Μάθησης (Learning Rate):** 0,001

3.4.2 Στρατηγικές Κατανομής Δεδομένων

Για τη ρεαλιστική προσομοίωση των συνθηκών που επικρατούν στα ομοσπονδιακά δίκτυα και την αξιολόγηση της ανθεκτικότητας των μοντέλων απέναντι στη στατιστική ετερογένεια, η κατανομή των δεδομένων εκπαίδευσης στους κόμβους-πελάτες πραγματοποιήθηκε παράλληλα και υπό Ισόνομη και Ανεξάρτητη Κατανομή (IID) και υπό

διαφορετικές κλίμακες Μη-Ισόνομης Κατανομής (Non-IID). Με αυτόν τον τρόπο, η αξιολόγηση κάλυψε όλο το φάσμα της ετερογένειας σε όλα τα ομοσπονδιακά πειράματα της παρούσας εργασίας.

Ανεξάρτητη και Όμοια Κατανομή (IID)

Σε αυτό το σενάριο, το παγκόσμιο σύνολο δεδομένων εκπαίδευσης ανακατεύεται τυχαία και κατανέμεται ομοιόμορφα στους συμμετέχοντες κόμβους-πελάτες. Αυτό εξασφαλίζει ότι η τοπική στατιστική κατανομή κλάσεων κάθε κόμβου-πελάτη αποτελεί έναν αντιπροσωπευτικό μικρόκοσμο της συνολικής παγκόσμιας κατανομής. Το σενάριο IID κατανομής αξιοποιείται ως σημείο αναφοράς για την αποτίμηση της μέγιστης θεωρητικής απόδοσης του συστήματος.

Μη Ανεξάρτητη και Όμοια Κατανομή (Non-IID)

Σε πραγματικές εφαρμογές της Ομοσπονδιακής Μάθησης, τα δεδομένα είναι εγγενώς Non-IID, εφόσον κάθε κόμβος-πελάτης παρατηρεί διαφορετικά πρότυπα συμπεριφοράς. Για τη μαθηματικά ελεγχόμενη προσωμοίωση αυτού του φαινομένου, αξιοποιήθηκε η κατανομή Dirichlet [63].

Μαθηματικά, εάν $\mathbf{p}$ είναι η αρχική, παγκόσμια κατανομή των κλάσεων, η αναλογία των δειγμάτων p_k που λαμβάνει ο κάθε πελάτης k προκύπτει μέσω δειγματοληψίας από την κατανομή: $p_k \sim \text{Dir}(\mathbf{a}\mathbf{p})$

Η παράμετρος συγκέντρωσης $\mathbf{a}$ ελέγχει τον βαθμό της ετερογένειας. Καθώς η τιμή του $\mathbf{a}$ τείνει στο άπειρο, η κατανομή προσεγγίζει το σενάριο IID. Καθώς το $\mathbf{a}$ τείνει στο μηδέν, η ετερογένεια γίνεται ακραία. Στα πειράματα αξιολογήθηκαν τρία διακριτά επίπεδα ανισορροπίας:

- $\mathbf{a} = 1.0$ (**Ήπια Ετερογένεια**): Οι κόμβοι-πελάτες παρουσιάζουν διαφοροποιήσεις στον όγκο των δεδομένων ανά κλάση, διατηρώντας ωστόσο μια σχετική, αν και ασύμμετρη, ποικιλομορφία δειγμάτων.
- $\mathbf{a} = 0.5$ (**Υψηλή Ετερογένεια**): Εισάγεται έντονη στατιστική ετερογένεια. Η εκπροσώπηση της μειοψηφικής κλάσης διαφέρει ισχυρά ανά κόμβο-πελάτη, με παρουσία περιπτώσεων όπου η μειοψηφική κλάση απουσιάζει εντελώς από τα δεδομένα ενός ή περισσότερων κόμβων-πελατών.
- $\mathbf{a} = 0.1$ (**Ακραία Ετερογένεια**): Το πλέον απαιτητικό σενάριο. Πλέον, η εκπροσώπηση της μειοψηφικής αλλά και της πλειοψηφικής κλάσης διαφέρει ακραία ανά κόμβο-πελάτη. Σημειώνονται περιπτώσεις όπου τα δείγματα της μειοψηφικής κλάσης συγκεντρώνονται μόνο σε 2 πελάτες, χωρίς ισόποσο διαμερισμό μεταξύ αυτών, περιπτώσεις όπου κάποιος κόμβος-πελάτης δεν διαθέτει καθόλου

δεδομένα από καμία κλάση και περιπτώσεις όπου, εντός κάποιου κόμβου-πελάτη, τα δεδομένα της μειοψηφικής κλάσης πλησιάζουν ή υπερτερούν σε αριθμό των δεδομένων της πλειοψηφικής κλάσης.

Η επιλογή αυτής της κλιμακωτής ετερογένειας είναι κρίσιμη για την παρούσα μελέτη. Προκαλεί στοχευμένα το φαινόμενο της Απόκλισης Πελατών, καθώς οι τοπικές κλίσεις των πελατών κατευθύνονται σε εντελώς διαφορετικά τοπικά ελάχιστα, καταδεικνύοντας έτσι τη λειτουργική αναγκαιότητα ενσωμάτωσης τεχνικών παραγωγής συνθετικών δεδομένων.


3.5 FedSMOTE

3.5.1 Client-Side SMOTE

Η προσέγγιση Client-Side SMOTE αποτελεί μια τεχνική προεπεξεργασίας επιπέδου δεδομένων, η οποία εκτελείται αυτόνομα σε κάθε κόμβο-πελάτη πριν από την έναρξη του πρώτου γύρου ομοσπονδιακής επικοινωνίας. Κάθε πελάτης k αναλύει το τοπικό του σύνολο δεδομένων $\mathcal{D}_k$ και εφόσον διαθέτει αρκετά δείγματα της μειοψηφικής κλάσης, εφαρμόζεται ο αλγόριθμος SMOTE για την παραγωγή συνθετικών δειγμάτων.

Η τοπική εξισορρόπηση των κλάσεων στοχεύει στην τροποποίηση της τοπικής συνάρτησης κόστους $F_k(w)$. Χωρίς την υπερδειγματοληψία, η κλίση $\nabla F_k(w)$ κυριαρχείται από τα δείγματα της πλειοψηφικής κλάσης, οδηγώντας σε τοπικές ενημερώσεις βαρών που αγνοούν τα χαρακτηριστικά της μειονοτικής κλάσης. Με την εφαρμογή του Client-Side SMOTE, οι τοπικές ανανεώσεις w_{t+1}^k γίνονται πιο αντιπροσωπευτικές, μετριάζοντας το φαινόμενο της απόκλισης πελάτη που προκαλείται από τη στατιστική ετερογένεια.

Παρά την απλότητα στην υλοποίηση, η τεχνική αυτή παρουσιάζει σημαντικούς περιορισμούς σε περιβάλλοντα υψηλής στατιστικής ετερογένειας. Σε περιπτώσεις όπου ένας πελάτης διαθέτει πολύ περιορισμένο αριθμό μειονοτικών δειγμάτων, η τοπική παρεμβολή πραγματοποιείται σε έναν εξαιρετικά περιορισμένο χώρο χαρακτηριστικών. Αυτό οδηγεί στην παραγωγή δειγμάτων με χαμηλή ποικιλομορφία, αυξάνοντας τον κίνδυνο υπερπροσαρμογής του τοπικού μοντέλου και αποτρέποντας την εκμάθηση της συνολικής κατανομής της μειονοτικής κλάσης που είναι διασκορπισμένη στο δίκτυο. Ταυτόχρονα, όταν κάποιος πελάτης δεν διαθέτει καθόλου δείγματα της μειοψηφικής κλάσης, εξ ορισμού δεν μπορεί να εφαρμοστεί ο αλγόριθμος SMOTE. Για την αντιμετώπιση αυτών των περιορισμών, ο αλγόριθμος SMOTE εφαρμόζεται μόνο στις περιπτώσεις που υπάρχουν τουλάχιστον 5 δείγματα της μειοψηφικής κλάσης.



Σχήμα 3.6: Αναπαράσταση Προσέγγισης Client-Side SMOTE

3.5.2 Trans-Client SMOTE

Η αρχιτεκτονική (Client-Side SMOTE) αδυνατεί να αντιμετωπίσει σε ορισμένες περιπτώσεις την ακραία στατιστική ετερογένεια, λόγω της έλλειψης επαρκούς ποικιλομορφίας στα τοπικά μειονοτικά δείγματα. Για την επίλυση αυτού του κρίσιμου περιορισμού, στην παρούσα εργασία προτείνεται και υλοποιείται η αρχιτεκτονική Trans-Client SMOTE. Πρόκειται για ένα καινοτόμο πρωτόκολλο το οποίο επιτρέπει τη συνεργατική παραγωγή συνθετικών δειγμάτων μέσω της παρεμβολής δεδομένων από διαφορετικούς πελάτες, διασφαλίζοντας παράλληλα την απόλυτη ιδιωτικότητα μέσω της υιοθέτησης τεχνικών Πλήρους Ομομορφικής Κρυπτογράφησης.

Για την υλοποίηση των μαθηματικών πράξεων στον κρυπτογραφημένο χώρο, επιλέχθηκε το σχήμα CKKS. Η επιλογή του σχήματος CKKS έγινε με γνώμονα την δυνατότητα του να εκτελεί πράξεις προσεγγιστικής κινητής υποδιαστολής, κάτι το οποίο είναι απολύτως απαραίτητο για τον πολλαπλασιασμό με δεκαδικούς συντελεστές κατά την παρεμβολή του SMOTE.

Το πρωτόκολλο του Trans-Client SMOTE εκτελείται πριν την έναρξη της κανονικής ομοσπονδιακής εκπαίδευσης και περιλαμβάνει τα ακόλουθα 7 διακριτά βήματα:

1. **Εξαγωγή Αντιπροσωπευτικών Δειγμάτων:** Κάθε κόμβος-πελάτης σαρώνει το τοπικό του σύνολο δεδομένων και απομονώνει τα δείγματα της μειοψηφικής κλάσης. Προκειμένου να μειωθεί ο υπολογιστικός και τηλεπικοινωνιακός φόρ-

τος της κρυπτογράφησης, ο πελάτης δεν χρησιμοποιεί ολόκληρο το μειονοτικό του σύνολο, αλλά υπολογίζει ένα υποσύνολο αντιπροσωπευτικών δειγμάτων, υπολογίζοντας το κέντρο μάζας και επιλέγοντας τα k κοντινότερα δείγματα κατά την Ευκλείδεια Απόσταση, τα οποία συνοψίζουν τον τοπικό χώρο χαρακτηριστικών του.

2. **Πλήρως Ομομορφική Κρυπτογράφηση με Σχήμα CKKS:** Τα παραγόμενα αντιπροσωπευτικά δείγματα κρυπτογραφούνται τοπικά χρησιμοποιώντας το δημόσιο κλειδί του συστήματος μέσω του σχήματος FHE (CKKS). Εάν $\mathbf{x}_i$ ένα διάνυσμα χαρακτηριστικών, τότε το προκύπτον κρυπτοκείμενο συμβολίζεται ως $Enc(\mathbf{x}_i)$.
3. **Μετάδοση στον Κεντρικό Διακομιστή:** Τα κρυπτογραφημένα δείγματα αποστέλλονται με ασφάλεια στον κεντρικό διακομιστή. Σε αυτό το στάδιο, ο διακομιστής συγκεντρώνει την κρυπτογραφημένη γνώση της μειονοτικής κλάσης από ολόκληρο το δίκτυο, χωρίς να έχει καμία απολύτως πρόσβαση στις πραγματικές τιμές των δειγμάτων.
4. **Ομομορφική Παρεμβολή:** Ο συντονιστής αναλαμβάνει την παραγωγή των νέων συνθετικών δειγμάτων εφαρμόζοντας τον αλγόριθμο SMOTE απευθείας στον κρυπτογραφημένο χώρο. Για ένα κρυπτογραφημένο δείγμα $Enc(\mathbf{x}_i)$ ενός πελάτη και ένα δείγμα $Enc(\mathbf{x}_j)$ ενός άλλου, η δημιουργία του νέου κρυπτογραφημένου δείγματος εκφράζεται ως: $Enc(\mathbf{x}_{new}) = Enc(\mathbf{x}_i) \oplus \lambda \otimes (Enc(\mathbf{x}_j) \ominus Enc(\mathbf{x}_i))$. Στον κλασικό αλγόριθμο SMOTE, η παράμετρος λ είναι μια συνεχής τυχαία μεταβλητή με ομοιόμορφη κατανομή στο $[0, 1]$. Ωστόσο, στην ομομορφική κρυπτογράφηση με σχήμα CKKS, ο πολλαπλασιασμός απαιτεί διαχείριση της κλίμακας και προκαθορισμένη ακρίβεια. Για να διατηρηθεί η σταθερότητα των πολυωνύμων και να αποφευχθεί η εκθετική αύξηση του θορύβου, ορίστηκε η χρήση διακριτών τιμών παρεμβολής, επιλέγοντας το λ τυχαία από το πεπερασμένο σύνολο $\{0.1, 0.2, 0.3, \dots, 0.9\}$. Η στρατηγική αυτή γεφυρώνει τις απαιτήσεις του SMOTE με τους δομικούς περιορισμούς της Πλήρως Ομομορφικής Κρυπτογράφησης. Ταυτόχρονα, στη μαθηματική διατύπωση χρησιμοποιούνται τα σύμβολα $\oplus, \ominus, \otimes$ για να υποδηλώσουν ρητά ότι οι πράξεις της πρόσθεσης, αφαίρεσης και πολλαπλασιασμού εκτελούνται ομομορφικά στον κρυπτογραφημένο χώρο των πολυωνυμικών δακτυλίων του σχήματος CKKS, διαφοροποιώντας τες από την τυπική αριθμητική των πραγματικών αριθμών.
5. **Τυχαία Μετάθεση, Κατάτμηση και Επιστροφή Συνθετικών Δειγμάτων:** Μετά την ολοκλήρωση της ομομορφικής παρεμβολής στον κρυπτογραφικό χώρο, δεν προκρίνεται η καθολική μετάδοση του ενιαίου συνθετικού συνόλου προς όλους τους διαθέσιμους κόμβους-πελάτες, προκειμένου να αποφευχθεί η τεχνητή στατιστική ομογενοποίηση του δικτύου. Ο κεντρικός διακομιστής καθίσταται υπε-


ύθυνος για την εφαρμογή ενός αλγορίθμου τυχαίας μετάθεσης επί του συνόλου των παραχθέντων κρυπτογραφημένων δειγμάτων $Enc(\mathbf{x}_{new})$, διασφαλίζοντας την στατιστική ανεξαρτησία κατά την κατανομή. Στη συνέχεια, το σύνολο των κρυπτογραφημένων συνθετικών δειγμάτων κατατέμενεται σε K ισομερή και αμοιβαίως ξένα υποσύνολα, όπου K το πλήθος των διαθέσιμων κόμβων-πελατών. Κάθε διακριτό υποσύνολο έπειτα μεταδίδεται στοχευμένα στον αντίστοιχο πελάτη.

6. **Αποκρυπτογράφηση και Τοπική Ενσωμάτωση:** Κάθε κόμβος-πελάτης λαμβάνει το αποκλειστικό κρυπτογραφημένο υποσύνολο που του αντιστοιχεί και χρησιμοποιεί το μυστικό του κλειδί για να αποκρυπτογραφήσει τα ληφθέντα δεδομένα: $\mathbf{x}_{new} = Dec(Enc(\mathbf{x}_{new}))$. Το αποτέλεσμα είναι ένα ολοκαίνουργιο, καθαρό συνθετικό υποσύνολο δεδομένων, το οποίο, αν και εμπεριέχει ενσωματωμένη τη συλλογική στατιστική πληροφορία από ολόκληρο το δίκτυο, είναι μοναδικό για κάθε πελάτη και δεν επαναλαμβάνεται στους υπόλοιπους κόμβους. Με τον τρόπο αυτό, αποτρέπεται το φαινόμενο της υπερεκπαίδευσης του παγκόσμιου μοντέλου λόγω διπλότυπων δειγμάτων και διατηρείται ανέπαφη η στατιστική ετερογένεια του συστήματος. Τέλος, το συνθετικό υποσύνολο αυτό ενσωματώνεται στο αρχικό τοπικό σύνολο εκπαίδευσης, επιτυγχάνοντας την βέλτιστη εξισορρόπηση των κλάσεων.
7. **Ομοσπονδιακή Εκπαίδευση:** Έχοντας πλέον εξαλείψει την ακραία τοπική ανισορροπία μέσω των συνεργατικών συνθετικών δεδομένων, το δίκτυο προχωρά στην τυπική επαναληπτική διαδικασία της Ομοσπονδιακής Εκπαίδευσης, επιτυγχάνοντας ταχύτερη και πιο εύρωστη σύγκλιση, χωρίς το μοντέλο να επηρεάζεται από το φαινόμενο της απόκλισης. Ταυτόχρονα, το μοντέλο εξάγει γνώση από το σύνολο του δικτύου, που σε περίπτωση ακραίας στατιστικής ετερογένειας, θα ήταν αδύνατο.


3.6 Πειραματικό Περιβάλλον και Διαδικασία

Λόγω των υψηλών υπολογιστικών απαιτήσεων που εισάγει η εκπαίδευση Νευρωνικών Δικτύων και κυρίως η εκτέλεση ομομορφικών πράξεων στον κρυπτογραφημένο χώρο, ο κώδικας εκτελέστηκε τοπικά με χρήση Μονάδας Επεξεργασίας Γραφικών, η οποία επέτρεψε την παράλληλη επεξεργασία των τανυστών και την ταχύτερη σύγκλιση των μοντέλων.

Στη Μηχανική Μάθηση, η τυχαία αρχικοποίηση των βαρών και ο στοχαστικός τρόπος δειγματοληψίας των δεδομένων μπορούν να οδηγήσουν σε αποκλίσεις στα αποτελέσματα. Για την εξάλειψη αυτού του παράγοντα και τη διασφάλιση της αναπαραγωγιμότητας, κάθε πείραμα εκτελέστηκε 10 διαδοχικές φορές, χρησιμοποιώντας ένα σύνολο από



Σχήμα 3.7: Αναπαράσταση Προσέγγισης Trans-Client SMOTE - Μέρος 1ο



Σχήμα 3.8: Αναπαράσταση Προσέγγισης Trans-Client SMOTE - Μέρος 2ο

10 διαφορετικούς, προκαθορισμένους σπόρους τυχαιότητας. Ταυτόχρονα, οι μετρικές αξιολόγησης που εξάγονται από τα αποτελέσματα των πειραμάτων δεν αποτελούν μεμονωμένες τιμές, αλλά υπολογίστηκαν ως η μέση τιμή και η τυπική απόκλιση των 10 εκτελέσεων. Η αναφορά της τυπικής απόκλισης επιτρέπει την εκτίμηση της σταθερότητας του προτεινόμενου συστήματος κάτω από διαφορετικές αρχικοποιήσεις.

Η πειραματική διαδικασία οργανώθηκε κλιμακωτά, ξεκινώντας από απλούστερες μορφές εκπαίδευσης και καταλήγοντας στην πλήρη υλοποίηση του FedSMOTE. Συγκεκριμένα, η σειρά με την οποία πραγματοποιήθηκαν τα πειράματα για το κάθε σύνολο δεδομένων είναι η εξής:

1. Baseline Logistic Regression
2. Baseline XGBoost
3. Logistic Regression + Manual SMOTE
4. XGBoost + Manual SMOTE
5. Logistic Regression + SMOTE
6. XGBoost + SMOTE
7. Logistic Regression + ADASYN
8. XGBoost + ADASYN
9. Logistic Regression + Borderline SMOTE
10. XGBoost + Borderline SMOTE
11. Logistic Regression + GAN
12. XGBoost + GAN
13. Centralized MLP
14. Centralized MLP + SMOTE
15. Plain FL + IID
16. Plain FL + Non-IID ($\alpha = 0.1$)
17. Plain FL + Non-IID ($\alpha = 0.5$)
18. Plain FL + Non-IID ($\alpha = 1.0$)
19. Client-Side SMOTE + IID
20. Client-Side SMOTE + Non-IID ($\alpha = 0.1$)
21. Client-Side SMOTE + Non-IID ($\alpha = 0.5$)

- 22. Client-Side SMOTE + Non-IID ($\alpha = 1.0$)
- 23. Trans-Client SMOTE + IID
- 24. Trans-Client SMOTE + Non-IID ($\alpha = 0.1$)
- 25. Trans-Client SMOTE + Non-IID ($\alpha = 0.5$)
- 26. Trans-Client SMOTE + Non-IID ($\alpha = 1.0$)

Κεφάλαιο 4

Πειραματική Αξιολόγηση

Στο παρόν κεφάλαιο παρατίθεται η αναλυτική αξιολόγηση των πειραματικών διατάξεων, με στόχο την ποσοτική και ποιοτική αποτίμηση της απόδοσης των υπό εξέταση τεχνικών και την εξαγωγή συμπερασμάτων. Η πειραματική διαδικασία σχεδιάστηκε με σκοπό την συγκριτική μελέτη μοντέλων σε περιβάλλοντα κεντριοποιημένης και ομοσπονδιακής μάθησης, υπό την παρουσία ακραίας Ανισορροπίας Κλάσεων.

Σε πρώτο στάδιο εξετάζεται η επίδραση καθιερώμενων τεχνικών παραγωγής συνθετικών δεδομένων (SMOTE, ADASYN, Borderline-SMOTE, GAN) στην απόδοση αλγορίθμων ταξινόμησης (Logistic Regression, XGBoost, MLP) σε κεντριοποιημένο επίπεδο. Στον πυρήνα της πειραματικής αξιολόγησης, βρίσκεται η επικύρωση του πλαισίου FedSMOTE, το οποίο αξιολογείται τόσο σε τοπικό όσο και σε συνεργατικό επίπεδο. Προκειμένου να ελεγχθεί η ανθεκτικότητα των προτεινόμενων αρχιτεκτονικών στη στατιστική ετερογένεια, τα πειράματα εκτελούνται τόσο σε Ισόνομη και Ανεξάρτητη Κατανομή (IID) όσο και σε κλιμακούμενα επίπεδα Μη-Ισόνομης Κατανομής (Non-IID). Για την εξαγωγή ασφαλών και αντικειμενικών συμπερασμάτων, αποφεύγεται η χρήση της καθολικής ακρίβειας και η απόδοση των μοντέλων κρίνεται βάσει εξειδικευμένων μετρικών που εστιάζουν στη μειονοτική κλάση.

Η ανάλυση των αποτελεσμάτων διακρίνεται σε δύο κύριες ενότητες, καθεμία εκ των οποίων αφιερώνεται στο κάθε σύνολο δεδομένων που αξιοποιήθηκαν στο πλαίσιο της παρούσας εργασίας. Για τη συστηματική και συγκριτική παρουσίαση των ευρημάτων, η ανάλυση εντός κάθε συνόλου δεδομένων ακολουθεί μια κλιμακωτή προσέγγιση. Αρχικά, παρατίθεται η επίδοση των μοντέλων στο κεντριοποιημένο περιβάλλον ως ιδεατό σημείο αναφοράς. Στη συνέχεια, εξετάζεται η απόδοση της παραδοσιακής Ομοσπονδιακής Μάθησης και αναδεικνύονται οι αδυναμίες της, προκειμένου να ακολουθήσει η αξιολόγηση του προτεινόμενου πλαισίου FedSMOTE. Τέλος, πραγματοποιείται η απαραίτητη μελέτη της υπολογιστικής και επικοινωνιακής επιβάρυνσης που εισάγουν η


ομοσπονδιακή μάθηση και οι κρυπτογραφικοί μηχανισμοί.

4.1 Πειραματικά Αποτελέσματα από το Σύνολο Δεδομένων Credit Card Fraud Detection

4.1.1 Αξιολόγηση Μοντέλων σε Κεντριοποιημένο Περιβάλλον

Πειραματική Διάταξη	ROC-AUC Score	Average Precision	F1 Score (Μειονοτική Κλάση)
Logistic Regression	0.8025 ± 0.0268	0.5406 ± 0.0471	0.7196 ± 0.0382
XGBoost	0.8821 ± 0.0152	0.6857 ± 0.0369	0.8247 ± 0.0228
Logistic Regression + Χειροκίνητο SMOTE	0.9254 ± 0.0207	0.1337 ± 0.0243	0.2618 ± 0.039
XGBoost + Χειροκίνητο SMOTE	0.8845 ± 0.0226	0.6324 ± 0.0596	0.793 ± 0.0376
Logistic Regression + SMOTE	0.9437 ± 0.0142	0.0548 ± 0.0035	0.1124 ± 0.0068
XGBoost + SMOTE	0.9202 ± 0.016	0.6399 ± 0.0405	0.798 ± 0.0259
Logistic Regression + ADASYN	0.9263 ± 0.0101	0.0171 ± 0.0008	0.0356 ± 0.0019
XGBoost + ADASYN	0.9211 ± 0.0165	0.6010 ± 0.0373	0.7716 ± 0.0246
Logistic Regression + Borderline SMOTE	0.9227 ± 0.0151	0.1232 ± 0.0388	0.2434 ± 0.0649
XGBoost + Borderline SMOTE	0.9137 ± 0.0152	0.7291 ± 0.0381	0.8527 ± 0.0225
Logistic Regression + GAN	0.7892 ± 0.0292	0.492 ± 0.0449	0.6862 ± 0.0368
XGBoost + GAN	0.9010 ± 0.0186	0.7566 ± 0.0368	0.8662 ± 0.0222
MLP	0.9055 ± 0.0176	0.7113 ± 0.0344	0.842 ± 0.0208
MLP + SMOTE	0.9196 ± 0.0168	0.5799 ± 0.0376	0.757 ± 0.0248


Πίνακας 4.1: Κεντριοποιημένα Πειράματα στο Σύνολο Δεδομένων Credit Card Fraud Detection



Σχήμα 4.1: Ραβδόγραμμα Μετρικής F1-Score της Μειοψηφικής Κλάσης για τα Κεντριοποιημένα Πειράματα

Αξιολόγηση Βασικών Αλγορίθμων

Η πειραματική διαδικασία ξεκινά με την αξιολόγηση των βασικών αλγορίθμων ταξινόμησης Logistic Regression και XGBoost, χωρίς να εφαρμόζεται τεχνική υπερδειγματοληψίας, με σκοπό να καθοριστεί το σημείο αναφοράς. Από το ραβδόγραμμα και τον πίνακα των αποτελεσμάτων, καθίσταται προφανής η υπεροχή του αλγορίθμου XGBoost σε προβλήματα Ανισοροπίας Κλάσεων έναντι του Logistic Regression. Η διαφορά αυτή οφείλεται στην εγγενή ικανότητα του αλγορίθμου XGBoost στην μοντελοποίηση μη γραμμικών συσχετίσεων στον χώρο των χαρακτηριστικών, σε αντίθεση με το Logistic Regression, το οποίο επικεντρώνεται στην αναζήτηση ενός απλού γραμμικού όριου απόφασης, καθιστώντας δύσκολο τον εντοπισμό σπάνιων περιπτώσεων απάτης.




Σχήμα 4.2: Πίνακες Σύγχυσης για Καλύτερες Εκτελέσεις Logistic Regression και XGBoost

Από τη σύγκριση των Πινάκων Σύγχυσης των καλύτερων εκτελέσεων των δύο αλγορίθμων, διακρίνεται πως ο αλγόριθμος Logistic Regression αδυνατεί να εντοπίσει 30 περιπτώσεις απάτης (αριθμός Ψευδών Αρνητικών), ενώ αντίστοιχα ξεφεύγουν 22 δείγματα απάτης από τον αλγόριθμο XGBoost, επιβεβαιώνοντας την συγκριτική υπεροχή του.

Επίδραση Τεχνικών Υπερδειγματοληψίας

Η ενσωμάτωση τεχνικών υπερδειγματοληψίας αναδεικνύει κρίσιμα συμπεράσματα, επιβεβαιώνοντας την ανάγκη χρήσης εξειδικευμένων μετρικών. Η ανάγκη αυτή τονίζεται και στην περίπτωση της εφαρμογής των αλγορίθμων SMOTE και ADASYN στον αλγόριθμο Logistic Regression, όπου η μετρική ROC-AUC σημειώνει σημαντική αύξηση σε σχέση με το σημείο αναφοράς, υποδεικνύοντας μια ραγδαία βελτίωση. Παραδόξως, ωστόσο, οι μετρικές Average Precision και F1-Score καταρρέουν, καθιστώντας άχρηστο το μοντέλο. Το ίδιο ισχύει, σε μικρότερο βαθμό, και στις περιπτώσεις όπου εφαρμόζεται Χειροκίνητο SMOTE και Bordeline-SMOTE, καθιστώντας προφανές ότι ο αλγόριθμος Logistic Regression δεν λειτουργεί ομαλά και συμπληρωματικά με δημοφιλείς τεχνικές υπερδειγματοληψίας. Οι πτώσεις αυτές στην απόδοση οφείλονται στην γραμμική παρεμβολή των τεχνικών που βασίζονται στο SMOTE. Η δημιουργία συνθετικών δειγμάτων τα οποία εισβάλλουν στον χώρο της πλειοψηφικής κλάσης, λειτουργούν ως θόρυβος, αναγκάζοντας το γραμμικό μοντέλο στην ταξινόμηση πλήθους νόμιμων συναλλαγών ως απατηλές, αυξάνοντας τον αριθμό των Ψευδώς Θετικών.

Ο ισχυρότερος ταξινομητής XGBoost επιδεικνύει μεγαλύτερη ανθεκτικότητα στον θόρυβο, με τις περισσότερες τεχνικές υπερδειγματοληψίας ωστόσο να προκαλούν μια ασθενή πτώση στην απόδοση του σε σχέση με το σημείο αναφοράς. Ουσιαστική βελτίωση στην απόδοση του μοντέλου σημειώνεται στην περίπτωση εφαρμογής Borderline-SMOTE, όπου ενισχύονται τα δείγματα μόνο στα κρίσιμα όρια απόφασης. Ταυτόχρονα, τα καλύτερα συνολικά αποτελέσματα σε αυτό το σύνολο δεδομένων καταγράφονται στον συνδυασμό του αλγορίθμου XGBoost με συνθετικά δεδομένα που έχουν παραχθεί μέσω ενός παραγωγικού ανταγωνιστικού δικτύου (GAN), με τις μέσες τιμές των μετρικών Average Precision και F1-Score να φτάνουν στις 0.7566 και 0.8662 αντίστοιχα, καθώς τα συνθετικά δείγματα ακολουθούν την πραγματική στατιστική κατανομή της μειοψηφικής κλάσης χωρίς την εισαγωγή τεχνητού θορύβου. Αξιοσημείωτο γεγονός αποτελεί η επίτευξη τιμής F1-Score 0.9022 στην καλύτερη εκτέλεση του συνδυασμού XGBoost + GAN, καθώς αποτελεί την υψηλότερη τιμή F1-Score που επιτεύχθηκε σε αυτό το σύνολο δεδομένων.



Σχήμα 4.3: Σύγκριση Καμπύλης Precision-Recall για Καλύτερες Εκτελέσεις XGBoost και XGBoost + GAN

Αξιολόγηση Νευρωνικού Δικτύου

Το Νευρωνικό Δίκτυο MLP, το οποίο αποτελεί και την αρχιτεκτονική η οποία αξιοποιείται και στα πλαίσια της Ομοσπονδιακής Μάθησης, εμφανίζει εξαιρετικά ισχυρή απόδοση στο κεντρικοποιημένο επίπεδο. Επιτυγχάνει τιμή F1-Score 0.842 και Average Precision 0.7113, ξεπερνώντας έτσι την επίδοση του Logistic Regression και ανταγωνίζεται άμεσα το XGBoost. Η ιεραρχική εξαγωγή χαρακτηριστικών και η χρήση Dropout επιτρέπουν στο δίκτυο τον ικανοποιητικό διαχωρισμό κλάσεων, παρά την ακραία ανισορροπία.

Κατά την εισαγωγή του αλγορίθμου SMOTE στην εκπαίδευση του Νευρωνικού Δικτύου, παρατηρείται πτώση της απόδοσης, με το F1-Score να μειώνεται στο 0.757. Με αυτόν τον τρόπο, επιβεβαιώνει ότι, σε συνθήκες ακραίας ανισορροπίας, τα βαθιά νευρωνικά δίκτυα ενδέχεται να υποστούν υπερπροσαρμογή στα τεχνητά μοτίβα της γραμμικής παρεμβολής. Η εισαγωγή θορύβου αλλοιώνει τα περίπλοκα μη γραμμικά όρια που χτίζει το δίκτυο, αυξάνοντας τον αριθμό των Ψευδώς Θετικών.

4.1.2 Αξιολόγηση Ομοσπονδιακής Μάθησης


Στην τρέχουσα ενότητα αξιολογείται η απόδοση του Νευρωνικού Δικτύου σε Ομοσπονδιακό Περιβάλλον, αξιοποιώντας τον κλασικό αλγόριθμο συνάθροισης FedAvg. Συγκεκριμένα, εξετάζεται η συμπεριφορά του συστήματος υπό διαφορετικές συνθήκες στατιστικής κατανομής των δεδομένων (IID και κλιμακούμενες Non-IID κατανομές).

Πειραματική Διάταξη	ROC-AUC Score	Average Precision	F1 Score (Μειονοτική Κλάση)
Ομοσπονδιακή Μάθηση + IID Κατανομή	0.9019 ± 0.0178	0.6874 ± 0.0405	0.8279 ± 0.0246
Ομοσπονδιακή Μάθηση + Non-IID Κατανομή ($\alpha = 0.1$)	0.5754 ± 0.13	0.1397 ± 0.2332	0.1867 ± 0.2993
Ομοσπονδιακή Μάθηση + Non-IID Κατανομή ($\alpha = 0.5$)	0.752 ± 0.1458	0.4367 ± 0.2464	0.5737 ± 0.2955
Ομοσπονδιακή Μάθηση + Non-IID Κατανομή ($\alpha = 1.0$)	0.8581 ± 0.0919	0.6227 ± 0.1612	0.7669 ± 0.1574

Πίνακας 4.2: Πειράματα Απλής Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων Credit Card Fraud Detection

Ανεξάρτητη και Όμοια Κατανομή (IID)

Στο ιδανικό σενάριο της Ισόνομης και Ανεξάρτητης Κατανομής (IID), ο ταξινομητής επιδεικνύει εξαιρετική σταθερότητα και ικανότητα γενίκευσης. Ο ταξινομητής αυτός προσεγγίζει σε πολύ μεγάλο βαθμό την απόδοση του αντίστοιχου κεντρικοποιημένου Νευρωνικού Δικτύου, με μέσες τιμές F1 0.8279 και Average Precision 0.6874, αποδεικνύοντας την αποδοτικότητα του FedAvg σε περιβάλλοντα όπου δεν υφίσταται στατιστική ετερογένεια μεταξύ τοπικών κόμβων-πελατών. Ταυτόχρονα, η πολύ μικρή πτώση της απόδοσης αποτελεί ελάχιστο συμβιβασμό για την διασφάλιση της ιδιωτικότητας που προσφέρει η Ομοσπονδιακή Μάθηση.



Σχήμα 4.4: Σύγκριση Πινάκων Σύγκρισης για Καλύτερες Εκτελέσεις Κεντριοποιημένου MLP και MLP + SMOTE


Μη Ανεξάρτητη και Όμοια Κατανομή (Non-IID)

Η μετάβαση σε ρεαλιστικά σενάρια κατανομής αποκαλύπτει τις θεμελιώδεις αδυναμίες της Ομοσπονδιακής Μάθησης όσον αφορά τη Στατιστική Ετερογένεια και την Ανισορροπία Κλάσεων. Η εισαγωγή ετερογένειας προκαλεί δραματική και κλιμακούμενη πτώση της απόδοσης του μοντέλου, η οποία αποτυπώνεται σε όλες τις εξεταζόμενες μετρικές.

Σε συνθήκες ήπιας ετερογένειας ($\alpha = 1.0$), η μέση τιμή της μετρικής F1-Score υποχωρεί στο 0.7669, με την τυπική απόκλιση να αυξάνεται αισθητά (± 0.1574), υποδεικνύοντας την παρουσία αστάθειας. Όσο η ετερογένεια αυξάνεται ($\alpha = 0.5$), κυριαρχεί η απόκλιση των πελατών, με το παγκόσμιο δίκτυο να συναντάει δυσκολίες στην σύνθεση των αντικρουόμενων τοπικών κλίσεων, με αποτέλεσμα την ραγδαία πτώση στις τιμές των μετρικών, με την μέση τιμή του F1 στο 0.5737 και της Average Precision στο 0.4367.

Στο πιο απαιτητικό σενάριο ακραίας ετερογένειας ($\alpha = 0.1$), ακολουθεί η κατάρρευση του ομοσπονδιακού μοντέλου. Η μετρική F1 συρρικνώνεται στην τιμή 0.1867, με τεράστια αναλογικά τυπική απόκλιση (± 0.2993). Έτσι, αποδεικνύεται η πλήρη αδυναμία σύγκλισης του αλγορίθμου σε συνθήκες ακραίας στατιστικής ετερογένειας, με την πλειοψηφία των περιπτώσεων να σημειώνει μηδενικό F1-Score. Σε αυτές τις περιπτώσεις, οι τοπικές ανανεώσεις αγνοούν σχεδόν εξ ολοκλήρου τα χαρακτηριστικά της μειονοτικής κλάσης.

Από την παραπάνω ανάλυση, καθίσταται αναγκαία η ενσωμάτωση τεχνικών εξισορρόπησης δεδομένων σε ομοσπονδιακό επίπεδο. Έτσι, αναδεικνύεται η αναγκαιότητα και η πρακτική αξία του προτεινόμενου πλαισίου FedSMOTE, με την ανάλυση να ακολουθεί στην επόμενη υποενότητα.



Σχήμα 4.5: Διάγραμμα Γραμμής Πορείας F1-Score σε Πειράματα Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων Credit Card Fraud Detection

4.1.3 Αξιολόγηση του Πλαισίου FedSMOTE

Με αποδεδειγμένη την αδυναμία του ομοσπονδιακού μοντέλου να ανταπεξέλθει σε συνθήκες στατιστικής ετερογένειας, αξιολογείται πλέον το προτεινόμενο πλαίσιο FedSMOTE. Η ανάλυση που πραγματοποιείται απαρτίζεται από την τοπική εφαρμογή του αλγορίθμου (Client-Side SMOTE) και από την καινοτόμο συνεργατική του υλοποίηση (Trans-Client SMOTE).

Πειραματική Διάταξη	ROC-AUC Score	Average Precision	F1 Score (Μειονοτική Κλάση)
Client-Side SMOTE + IID Κατανομή	0.9216 ± 0.0178	0.5995 ± 0.0439	0.7703 ± 0.0292
Client-Side SMOTE + Non-IID Κατανομή ($\alpha = 0.1$)	0.6871 ± 0.1803	0.3067 ± 0.2956	0.4057 ± 0.3624
Client-Side SMOTE + Non-IID Κατανομή ($\alpha = 0.5$)	0.9069 ± 0.0255	0.6189 ± 0.1091	0.7763 ± 0.0943
Client-Side SMOTE + Non-IID Κατανομή ($\alpha = 1.0$)	0.913 ± 0.021	0.6364 ± 0.0427	0.7957 ± 0.0275
Trans-Client SMOTE + IID Κατανομή	0.9024 ± 0.0176	0.6903 ± 0.034	0.8298 ± 0.0207
Trans-Client SMOTE + Non-IID Κατανομή ($\alpha = 0.1$)	0.677 ± 0.162	0.324 ± 0.291	0.4177 ± 0.3624
Trans-Client SMOTE + Non-IID Κατανομή ($\alpha = 0.5$)	0.8933 ± 0.0235	0.6733 ± 0.0454	0.8187 ± 0.0286
Trans-Client SMOTE + Non-IID Κατανομή ($\alpha = 1.0$)	0.8922 ± 0.0191	0.6683 ± 0.0361	0.816 ± 0.0226

Πίνακας 4.3: Πειράματα Πλαισίου Fed-SMOTE στο Σύνολο Δεδομένων Credit Card Fraud Detection

Client-Side SMOTE

Η προσέγγιση Client-Side SMOTE εφαρμόζει τον αλγόριθμο υπερδειγματοληψίας SMOTE αυστηρά στα τοπικά δεδομένα κάθε επιμέρους κόμβου-πελάτη.

Με βάση τα αποτελέσματα, συμπεραίνει κανείς πως αυτή η τεχνική προσφέρει ένα σημαντικό αντιστάθμισμα απέναντι στην στατιστική ετερογένεια. Σε συνθήκες ήπιας στατιστικής ετερογένειας ($\alpha = 1.0$), η μέση τιμή της μετρικής F1-Score βελτιώνεται στο 0.7957 σε σχέση με το 0.7669 της απλής Ομοσπονδιακής Μάθησης και αποδεικνύεται πιο σταθερή τεχνική λόγω της μικρότερης τυπικής απόκλισης. Σε συνθήκες υψηλής ετερογένειας ($\alpha = 0.5$), το μοντέλο διαθέτει ακόμα υψηλή προγνωστική ικανότητα, με μέση τιμή F1-Score 0.7763 σε σχέση με την τιμή 0.5737 του αντίστοιχου πειράματος απλής Ομοσπονδιακής Μάθησης.

Παρόλα αυτά, η μέθοδος Client-Side SMOTE συναντά περιορισμούς. Αρχικά, στο ι-δανικό σενάριο της IID κατανομής, η τοπική παραγωγή συνθετικών δεδομένων εισάγει υπολογιστικό θόρυβο, με αποτέλεσμα μια μικρή πτώση της απόδοσης σε σχέση με την απλή Ομοσπονδιακή Μάθηση. Ταυτόχρονα, σε ακραία στατιστική ετερογένεια ($\alpha = 0.1$), η μέθοδος δεν καταφέρνει να προσφέρει μια ικανοποιητική λύση. Παρότι σημειώνει διπλάσια μέση τιμή F1-Score σε σχέση με το αντίστοιχο πείραμα απλής Ομοσπονδιακής Μάθησης, παραμένει εξαιρετικά ασταθής, σημειώνοντας τυπική απόκλιση παρόμοια με την μέση τιμή. Το γεγονός αυτό οφείλεται στο ότι οι κόμβοι-πελάτες δεν διαθέτουν επαρκή αριθμό ή ποικιλομορφία μειονοτικών δειγμάτων εντός των τοπικών τους δεδομένων,

προκειμένου να εκτελεστεί μια ουσιαστική παρεμβολή στον χώρο των χαρακτηριστικών, οδηγώντας σε τοπική υπερπροσαρμογή.

Trans-Client SMOTE


Η υλοποίηση Trans-Client SMOTE αποτελεί τη λύση στους περιορισμούς που εισάγει η τοπική υπερδειγματοληψία, μέσω της αξιοποίησης ασφαλούς και δια-κομβικής παρεμβολής. Τα πειραματικά ευρήματα επιβεβαιώνουν την υπεροχή της συγκεκριμένης αρχιτεκτονικής σε όλα τα εξεταζόμενα σενάρια.

Αξιοσημείωτο εύρημα αποτελεί η σταθερότητα που επιδεικνύει το μοντέλο στην πλειονότητα των βαθμών στατιστικής ετερογένειας. Στο ιδανικό σενάριο IID κατανομής, το μοντέλο επιτυγχάνει μέσες τιμές F1-Score 0.8298 και Average Precision 0.6903, αποδεικνύοντας ότι η παρεμβολή με χρήση κρυπτογραφίας δεν εισάγει τον καταστροφικό θόρυβο που παρατηρήθηκε στη μέθοδο Client-Side SMOTE και ξεπερνώντας κατά λίγο την επίδοση της απλής Ομοσπονδιακής Μάθησης. Σε συνθήκες ήπιας ($\alpha = 1.0$) και υψηλής ($\alpha = 0.5$) στατιστικής ετερογένειας, η μέθοδος Trans-Client SMOTE διατηρεί την απόδοσή της σε πανομοιότυπα επίπεδα με το IID σενάριο (μέση τιμή F1-Score 0.8160 και 0.8187 αντίστοιχα). Μέσω της άντλησης πληροφορίας από όλο το δίκτυο, η μέθοδος αυτή εξαλείφει πλήρως το φαινόμενο της απόκλισης πελατών, επιτρέποντας στο μοντέλο να γενικεύει με εξαιρετική ακρίβεια στη μειονοτική κλάση. Ταυτόχρονα, μέσω αυτής της αρχιτεκτονικής, το μοντέλο μπορεί να εξαγάγει συσχετίσεις μεταξύ των δεδομένων, με τρόπο που δεν θα ήταν δυνατό σε άλλη περίπτωση.


Στο σενάριο ακραίας στατιστικής ετερογένειας ($\alpha = 0.1$), η δια-κομβική προσέγγιση καταγράφει την βέλτιστη απόδοση με μέσες τιμές F1-Score και Average Precision 0.4177 και 0.3240 αντίστοιχα, ξεπερνώντας κατά πολύ τα αντίστοιχα πειράματα της απλής Ομοσπονδιακής Μάθησης και σε αρκετά μικρότερο βαθμό της αρχιτεκτονικής Client-Side SMOTE. Ενώ η τυπική απόκλιση παραμένει σε υψηλά επίπεδα (± 0.3624) για τη μετρική F1-Score, αντανakλώντας τη θεμελιώδη δυσκολία του συγκεκριμένου σενάριου όπου ορισμένοι κόμβοι-πελάτες στερούνται πλήρως δείγματα της μειονοτικής κλάσης, το σύστημα κατάφερε σε ορισμένες εκτελέσεις να συγκλίνει αποτελεσματικά. Για την καλύτερη εκτέλεση της αρχιτεκτονικής Trans-Client SMOTE σε ακραία στατιστική ετερογένεια, η τιμή F1-Score έφτασε στο 0.8342, αποδεικνύοντας τη δυναμική της δια-κομβικής συνεργασίας κάτω από αυστηρές κρυπτογραφικές εγγυήσεις.

4.1.4 Υπολογιστική Επιβάρυνση και Κόστος Επικοινωνίας

Η αξιολόγηση ενός αποκεντρωμένου συστήματος, σε συνδυασμό με την ενσωμάτωση κρυπτογραφικών πρωτοκόλλων, δεν θεωρείται πλήρης αν δεν συνυπολογιστεί το λειτουργικό του κόστος. Συγκεκριμένα, αναλύεται το μέγεθος του εκπαιδευόμενου μο-



Σχήμα 4.6: Ραβδόγραμμα Συγκριτικής Αξιολόγησης Πλαισίου FedSMOTE στο Σύνολο Δεδομένων Credit Card Fraud Detection



Σχήμα 4.7: Πορεία Εξέλιξης Τιμής F1-Score Μειοψηφικής Κλάσης ανά Γύρο Επικοινωνίας. Στιγμιότυπο από Καλύτερη Εκτέλεση Αρχιτεκτονικής Trans-Client SMOTE για Υψηλή Στατιστική Ετερογένεια ($\alpha = 0.5$) στο Σύνολο Δεδομένων Credit Card Fraud Detection

ντέλου, η τηλεπικοινωνιακή επιβάρυνση του δικτύου και το πρόσθετο υπολογιστικό κόστος που εισάγει η Πλήρως Ομομορφική Κρυπτογράφηση.

Τηλεπικοινωνιακή Επιβάρυνση και Μέγεθος Μοντέλου

Όσον αφορά τις απαιτήσεις μετάδοσης, το σχεδιασμένο Νευρωνικό Δίκτυο χαρακτηρίζεται από εξαιρετική συμπίεση παραμέτρων, διατηρώντας σταθερό μέγεθος μόλις 0.02MB σε όλες τις πειραματικές διατάξεις. Το μέγεθος αυτό καθιστά την επικοινωνία μεταξύ του κεντρικού διακομιστή και των 5 κόμβων-πελατών εξαιρετικά αποδοτική. Σε έναν πλήρη κύκλο ομοσπονδιακής εκπαίδευσης, που αποτελείται από 20 γύρους επικοινωνίας, το συνολικό κόστος επικοινωνίας στο δίκτυο ανέρχεται σταθερά στο χαμηλό επίπεδο των 3.81MB. Το εύρημα αυτό αποδεικνύει πως η προτεινόμενη αρχιτεκτονική ικανοποιεί πλήρως τους αυστηρούς περιορισμούς εύρους ζώνης που συχνά διέπουν τα ομοσπονδιακά περιβάλλοντα, εξασφαλίζοντας ταχεία αποστολή και λήψη των βαρών χωρίς να προκαλείται συμφόρηση δικτύου.

Υπολογιστικό Κόστος Κρυπτογραφίας

Η πλέον κρίσιμη μέτρηση αφορά τον πρόσθετο χρόνο που απαιτείται για την εκτέλεση της κρυπτογράφησης, της ομομορφικής παρεμβολής και της αποκρυπτογράφησης των συνθετικών δεδομένων κατά την εφαρμογή της αρχιτεκτονικής Trans-Client SMOTE. Για την επιτάχυνση των πράξεων του σχήματος CKKS, ο κώδικας εκτελέστηκε τοπικά αξιοποιώντας την ισχυρή υπολογιστική αρχιτεκτονική μιας μονάδας γραφικών.

Τα αποτελέσματα καταδεικνύουν μια εξαιρετικά ενδιαφέρουσα άμεση συσχέτιση μεταξύ του πρόσθετου υπολογιστικού χρόνου και του βαθμού στατιστικής ετερογένειας. Στο ιδανικό σενάριο της IID κατανομής των δεδομένων και της ήπιας στατιστικής ετερογένειας, η χρονική επιβάρυνση ανήλθε στο μέγιστο επίπεδο των 2.26 και 4.22 δευτερολέπτων αντίστοιχα. Καθώς η ετερογένεια αυξάνεται, φτάνοντας υψηλά και ακραία επίπεδα, ο πρόσθετος χρόνος μειώνεται σημαντικά στα 0.69 και 0.70 δευτερόλεπτα αντίστοιχα.

Αυτή η φθίνουσα πορεία της χρονικής επιβάρυνσης ερμηνεύεται πλήρως από τη φύση της κατανομής Dirichlet. Υπό IID κατανομή ή ήπια στατιστική ετερογένεια, τα δείγματα της μειονοτικής κλάσης κατανέμονται σχεδόν σε όλους τους κόμβους. Συνεπώς, όλοι οι κόμβοι-πελάτες συμμετέχουν ενεργά στη φάση της προεπεξεργασίας, δηλαδή στην εξαγωγή αντιπροσωπευτικών δειγμάτων και στην εκτέλεση της κρυπτογράφησης, με αποτέλεσμα ο κεντρικός διακομιστής να υπολογίζει έναν μεγάλο αριθμό ομομορφικών παρεμβολών.

Αντίθετα, στο ακραίο σενάριο στατιστικής ετερογένειας, η πλειοψηφία των μειονοτικών δειγμάτων συγκεντρώνεται σε ελάχιστους κόμβους-πελάτες, ενώ οι υπόλοιποι δεν δια-

θέτουν κανένα μειονοτικό δείγμα στο τοπικό τους σύνολο. Έτσι, οι κόμβοι-πελάτες χωρίς τα δείγματα της μειοψηφικής κλάσης δεν μπορούν να εκτελέσουν καμία κρυπτογραφική πράξη και ο κεντρικός διακομιστής επεξεργάζεται έναν δραματικά μικρότερο όγκο κρυπτογραφημένων μηνυμάτων, ρίχνοντας τον χρόνο στα 0.69 δευτερόλεπτα.

Σε κάθε περίπτωση, η καταγεγραμμένη επιβάρυνση των περίπου 4 δευτερολέπτων στο χειρότερο σενάριο κρίνεται απολύτως αμελητέα. Το σύστημα επιτυγχάνει μια δραματική βελτίωση της προγνωστικής του ικανότητας με ελάχιστο χρονικό κόστος, αποδεικνύοντας την πρακτική βιωσιμότητα και την εξαιρετική αποδοτικότητα της αρχιτεκτονικής Trans-Client SMOTE σε σύγχρονες υπολογιστικές υποδομές.


4.2 Πειραματικά Αποτελέσματα από το Σύνολο Δεδομένων NSL-KKD (U2R Attacks)

4.2.1 Αξιολόγηση Μοντέλων σε Κεντριοποιημένο Περιβάλλον

Πειραματική Διάταξη	ROC-AUC Score	Average Precision	F1 Score (Μειονοτική Κλάση)
Logistic Regression	0.7099 ± 0.0663	0.3232 ± 0.1146	0.5275 ± 0.1189
XGBoost	0.8249 ± 0.0602	0.5508 ± 0.1063	0.7241 ± 0.0769
Logistic Regression + Χειροκίνητο SMOTE	0.7654 ± 0.1262	0.0025 ± 0.0013	0.0053 ± 0.0028
XGBoost + Χειροκίνητο SMOTE	0.7017 ± 0.0797	0.0073 ± 0.0098	0.0267 ± 0.0346
Logistic Regression + SMOTE	0.935 ± 0.0581	0.0557 ± 0.0151	0.1164 ± 0.0196
XGBoost + SMOTE	0.8599 ± 0.0768	0.5056 ± 0.1704	0.6954 ± 0.1194
Logistic Regression + ADASYN	0.9348 ± 0.0582	0.0532 ± 0.0147	0.1113 ± 0.019
XGBoost + ADASYN	0.8599 ± 0.07	0.491 ± 0.134	0.688 ± 0.0984
Logistic Regression + Borderline SMOTE	0.9208 ± 0.06	0.0639 ± 0.0226	0.1354 ± 0.0332
XGBoost + Borderline SMOTE	0.8599 ± 0.0735	0.5231 ± 0.1485	0.7103 ± 0.1049
Logistic Regression + GAN	0.7449 ± 0.0522	0.3423 ± 0.1077	0.5642 ± 0.0922
XGBoost + GAN	0.815 ± 0.0634	0.554 ± 0.1296	0.7231 ± 0.1008
MLP	0.648 ± 0.0935	0.1878 ± 0.1592	0.3154 ± 0.2533
MLP + SMOTE	0.8882 ± 0.0734	0.1133 ± 0.038	0.2392 ± 0.0435

Πίνακας 4.4: Κεντριοποιημένα Πειράματα στο Σύνολο Δεδομένων NSL-KDD (U2R Attacks)

Η πειραματική μελέτη στο σύνολο δεδομένων NSL-KDD και πιο συγκεκριμένα στον εντοπισμό των επιθέσεων τύπου User-to-Root (U2R), έχει ως αφετηρία την αποτίμηση των μοντέλων σε κεντριοποιημένο περιβάλλον. Το συγκεκριμένο πρόβλημα χαρακτηρίζεται από ακραία σπανιότητα της μειονοτικής κλάσης, με μόνο 52 δείγματα της συνολικά, γεγονός που καθιστά το έργο της ταξινόμησης εξαιρετικά απαιτητικό, όπως μαρτυράται και από τις αυξημένες τυπικές αποκλίσεις των αποτελεσμάτων.



Σχήμα 4.8: Ραβδόγραμμα Μετρικής F1-Score της Μειοψηφικής Κλάσης για τα Κεντριοποιημένα Πειράματα


Αξιολόγηση Βασικών Αλγορίθμων

Συγκρίνοντας τις υλοποιήσεις των βασικών αλγορίθμων Logistic Regression και XGBoost χωρίς υπερδעיγματοληψία, ο ταξινομητής XGBoost επιδεικνύει σαφή υπεροχή, με μέσες τιμές F1-Score και Average Precision 0.7241 και 0.5508 αντίστοιχα, σε σχέση με τις τιμές 0.5275 και 0.3232 του Logistic Regression. Η διαφορά αυτή επιβεβαιώνει την καταλληλότητα των δενδρικών μοντέλων συνόλου στην απομόνωση εξαιρετικά σπάνιων και μη γραμμικών μοτίβων στον χώρο των χαρακτηριστικών της δικτυακής κίνησης, έναντι των αυστηρά γραμμικών μοντέλων τα οποία δεν μπορούν να εντοπίσουν τις πολύπλοκες επιθέσεις U2R.

Από τη σύγκριση των Πινάκων Σύγχυσης των καλύτερων εκτελέσεων των δύο αλγορίθμων, διακρίνεται πως ο αλγόριθμος Logistic Regression αδυνατεί να εντοπίσει 4 περιπτώσεις δικτυακών επιθέσεων απάτης (αριθμός Ψευδών Αρνητικών), ενώ αντίστοιχα ξεφύγουν 2 δείγματα απάτης από τον αλγόριθμο XGBoost, επιβεβαιώνοντας την συγκριτική υπεροχή του.

Επίδραση Τεχνικών Υπερδעיγματοληψίας


Η εισαγωγή τεχνικών υπερδעיγματοληψίας αναδεικνύει και σε αυτό το σύνολο δεδομένων την ακαταλληλότητα της μετρικής ROC-AUC. Συγκεκριμένα, η εφαρμογή του αλγορίθμου SMOTE σε συνδυασμό με Logistic Regression σημειώνει υψηλή τιμή 0.935 στην μετρική ROC-AUC, σε αντίθεση με την τιμή της F1-Score, η οποία καταρρέει στο 0.1164. Η ίδια συμπεριφορά καταγράφεται και στις περιπτώσεις συνδυασμού Logi-



Σχήμα 4.9: Πίνακες Σύγχυσης για Καλύτερες Εκτελέσεις Logistic Regression και XG-Boost

stic Regression με Χειροκίνητο SMOTE, ADASYN, Borderline-SMOTE καθώς και στο συνδυασμό XGBoost με Χειροκίνητο SMOTE.

Αυτό το φαινόμενο μπορεί να εξηγηθεί από την φύση των δεδομένων. Εξαιτίας του εξαιρετικά μικρού αριθμού διαθέσιμων δειγμάτων επιθέσεων U2R, η γεωμετρική παρεμβολή που εκτελούν οι παραδοσιακοί αλγόριθμοι υπερδειγματοληψίας παράγει συνθετικά δείγματα τα οποία διεισδύουν στην περιοχή της κανονικής δικτυακής κίνησης. Έτσι, ο παραγόμενος θόρυβος οδηγεί το μοντέλο σε αυξημένο αριθμό Ψευδών Θετικών. Ακόμη και στην περίπτωση του αλγορίθμου XGBoost, ο συνδυασμός με SMOTE, ADASYN, Borderline-SMOTE δεν προσφέρει κάποια βελτίωση στην επίδοση του ταξινομητή, και αντιθέτως οδηγεί σε ελαφριά πτώση της μετρικής F1-Score. Εξαιρεση αποτελεί η χρήση GAN, το οποίο διατηρεί την απόδοση του XGBoost στα επίπεδα του σημείου αναφοράς, παράγοντας ρεαλιστικότερα δείγματα. Εύκολα εξάγεται το συμπέρασμα πως οι βασικές τεχνικές υπερδειγματοληψίας δεν προσφέρουν βελτίωση στην απόδοση των βασικών ταξινομητών Logistic Regression και XGBoost σε αυτό το σύνολο δεδομένων, όπου η μειονοτική κλάση είναι εξαιρετικά σπάνια.



Σχήμα 4.10: Καμπύλη Precision-Recall για Καλύτερη Εκτέλεση XGBoost

Αξιολόγηση Νευρωνικού Δικτύου

Το Νευρωνικό Δίκτυο MLP αντιμετωπίζει σημαντικές προκλήσεις στο συγκεκριμένο σύνολο δεδομένων. Σε κεντριοποιημένο περιβάλλον, το δίκτυο καταγράφει χαμηλό F1-Score με μέση τιμή 0.3154 και έντονη πειραματική αστάθεια με τυπική απόκλιση ± 0.2533 . Ο ανεπαρκής όγκος δεδομένων εκπαίδευσης της μειονοτικής κλάσης δεν επιτρέπει στα βάρη του δικτύου να συγκλίνουν βέλτιστα, οδηγώντας σε υπερπροσαρμογή ως προς την κλάση των επιθέσεων.

Η ενσωμάτωση του αλγορίθμου SMOTE στην εκπαίδευση του Νευρωνικού Δικτύου επιδεινώνει την απόδοση του ταξινομητή, με πτώση της μέσης τιμής της F1-Score στο 0.2392 και της Average Precision στο 0.1133, παρά την αύξηση της ROC-AUC στο 0.8882. Όπως ίσχυε και προηγουμένως, η εισαγωγή θορύβου από τα παραγόμενα συνθετικά δείγματα αποπροσανατολίζει την κλιμακωτή κάθοδο του Νευρωνικού Δικτύου. Η αδυναμία του να γενικεύσει αποτελεσματικά σε κεντριοποιημένο περιβάλλον, προϋδεάζει τη διερεύνηση εναλλακτικών, αποκεντρωμένων μεθόδων ενίσχυσης της πληροφορίας, καθιστώντας παράλληλα αναγκαία και την υιοθέτηση του πλαισίου FedSMOTE.

4.2.2 Αξιολόγηση Ομοσπονδιακής Μάθησης

Στο σύνολο δεδομένων NSL-KDD, το ομοσπονδιακό περιβάλλον αναδεικνύει περαιτέρω τις προκλήσεις που εισάγει η ακραία σπανιότητα της μειονοτικής κλάσης σε συνδυασμό με τη διανομή των δεδομένων σε πολλαπλούς κόμβους-πελάτες.

Πειραματική Διάταξη	ROC-AUC Score	Average Precision	F1 Score (Μειονοτική Κλάση)
Ομοσπονδιακή Μάθηση + IID Κατανομή	0.6030 ± 0.0911	0.1127 ± 0.129	0.208 ± 0.2194
Ομοσπονδιακή Μάθηση + Non-IID Κατανομή ($\alpha = 0.1$)	0.4934 ± 0.1068	0.001 ± 0.0008	0.0051 ± 0.0125
Ομοσπονδιακή Μάθηση + Non-IID Κατανομή ($\alpha = 0.5$)	0.5134 ± 0.1235	0.041 ± 0.1198	0.0621 ± 0.1702
Ομοσπονδιακή Μάθηση + Non-IID Κατανομή ($\alpha = 1.0$)	0.6064 ± 0.0915	0.1331 ± 0.1452	0.2294 ± 0.2311

Πίνακας 4.5: Πειράματα Απλής Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων NSL-KDD (U2R Attacks)

Ανεξάρτητη και Όμοια Κατανομή (IID)

Στο ιδανικό σενάριο της IID κατανομής, η απόδοση του μοντέλου υποβαθμίζεται αισθητά σε σχέση με το κεντριοποιημένο περιβάλλον, με το ομοσπονδιακό μοντέλο να καταγράφει μέσες τιμές F1-Score και Average Precision 0.208 και 0.1127 αντίστοιχα. Ο διαμοιρασμός των 52 δειγμάτων της μειονοτικής κλάσης σε 5 συμμετέχοντες κόμβους-πελάτες καθιστά πρακτικά αδύνατη τη σύγκλιση της τοπικής συνάρτησης κόστους. Το γεγονός αυτό αποτυπώνεται περαιτέρω στην τεράστια τυπική απόκλιση (± 0.2194), με

τις μισές εκτελέσεις να σημειώνουν μηδενικό F1-Score, υποδεικνύοντας ακραία πειραματική αστάθεια, όπου στις περιπτώσεις όπου το μοντέλο συγκλίνει να οφείλονται σε ευνοϊκές αρχικοποιήσεις και τον μηχανισμό αποθήκευσης της καλύτερης τιμής F1-Score.

Μη Ανεξάρτητη και Όμοια Κατανομή (Non-IID)


Η εισαγωγή στατιστικής ετερογένειας επιτείνει περαιτέρω την αδυναμία του συστήματος. Σε συνθήκες ήπιας ετερογένειας ($\alpha = 1.0$), το σύστημα παρουσιάζει μια μικρή βελτίωση με μέση τιμή του F1-Score στο 0.2294, η οποία ωστόσο συνοδεύεται από ακραία αναλογικά τυπική απόκλιση (± 0.2311). Η συμπεριφορά αυτή οφείλεται στη μη ομοιόμορφη συγκέντρωση των ελάχιστων επιθέσεων U2R σε συγκεκριμένους κόμβους-πελάτες. Στην περίπτωση όπου κάποιος κόμβος-πελάτης συγκεντρώσει ένα ικανοποιητικό υποσύνολο των επιθέσεων, μπορεί να πετύχει την εκπαίδευση ενός ισχυρότερου τοπικού μοντέλου, χωρίς την εγγύηση της σταθερής γενίκευσης του παγκόσμιου μοντέλου.

Όσο ο βαθμός στατιστικής ετερογένειας αυξάνεται, το σύστημα καταρρέει ολοκληρωτικά. Στο πιο ακραίο σενάριο ($\alpha = 0.1$), το F1-Score και Average Precision μηδενίζονται ουσιαστικά με την μετρική ROC-AUC να καταγράφει μέση τιμή 0.4934, υποδηλώνοντας χειρότερη επίδοση ακόμα και από την εντελώς τυχαία ταξινόμηση. Στην περίπτωση αυτή, η πλειοψηφία των κόμβων-πελατών δεν διαθέτει δείγματα της μειονοτικής κλάσης, με τις τοπικές ανανεώσεις των βαρών να βελτιστοποιούνται αποκλειστικά για την αναγνώριση της κανονικής δικτυακής κίνησης, οδηγώντας σε ένα μοντέλο που δεν μπορεί να αναγνωρίσει της δικτυακές εισβολές.

Τα παραπάνω συμπεράσματα αποδεικνύουν πως σε προβλήματα κρίσιμης ανίχνευσης με συνθήκες ακραίας σπανιότητας δεδομένων, η παραδοσιακή Ομοσπονδιακή Μάθηση αδυνατεί να προσφέρει λειτουργικές λύσεις. Η ανάγκη τεχνητής ενίσχυσης της μειονοτικής κλάσης κρίνεται επιβεβλημένη, καθιστώντας αναγκαία την υιοθέτηση του πλαισίου FedSMOTE.

4.2.3 Αξιολόγηση του Πλαισίου FedSMOTE

Με αποδεδειγμένη την πλήρη κατάρρευση της κλασικής Ομοσπονδιακής Μάθησης απέναντι στην ακραία σπανιότητα της μειονοτικής κλάσης, ακολουθεί η πειραματική αποτίμηση του πλαισίου FedSMOTE. Η ανάλυση στοχεύει στην διευκρίνιση της επίδρασης της τεχνητής ενίσχυσης των μειονοτικών δειγμάτων, είτε σε τοπικό είτε σε διακομικό επίπεδο, στην ικανότητα γενίκευσης του ομοσπονδιακού συστήματος.



Σχήμα 4.11: Διάγραμμα Γραμμής Πορείας F1-Score σε Πειράματα Ομοσπονδιακής Μάθησης στο Σύνολο Δεδομένων NSL-KDD

Πειραματική Διάταξη	ROC-AUC Score	Average Precision	F1 Score (Μειονοτική Κλάση)
Client-Side SMOTE + IID Κατανομή	0.8493 $\pm$ 0.0806	0.2572 $\pm$ 0.1812	0.4449 $\pm$ 0.1692
Client-Side SMOTE + Non-IID Κατανομή ($\alpha = 0.1$)	0.5334 $\pm$ 0.1739	0.0191 $\pm$ 0.055	0.0342 $\pm$ 0.0997
Client-Side SMOTE + Non-IID Κατανομή ($\alpha = 0.5$)	0.7641 $\pm$ 0.1224	0.1937 $\pm$ 0.1435	0.3578 $\pm$ 0.21
Client-Side SMOTE + Non-IID Κατανομή ($\alpha = 1.0$)	0.7524 $\pm$ 0.1998	0.1716 $\pm$ 0.1089	0.3334 $\pm$ 0.1908
Trans-Client SMOTE + IID Κατανομή	0.8198 $\pm$ 0.0557	0.3884 $\pm$ 0.1	0.6134 $\pm$ 0.0857
Trans-Client SMOTE + Non-IID Κατανομή ($\alpha = 0.1$)	0.5134 $\pm$ 0.1173	0.041 $\pm$ 0.0915	0.0692 $\pm$ 0.1414
Trans-Client SMOTE + Non-IID Κατανομή ($\alpha = 0.5$)	0.6748 $\pm$ 0.0683	0.2975 $\pm$ 0.1123	0.471 $\pm$ 0.165
Trans-Client SMOTE + Non-IID Κατανομή ($\alpha = 1.0$)	0.7549 $\pm$ 0.0687	0.3692 $\pm$ 0.1097	0.5801 $\pm$ 0.0982

Πίνακας 4.6: Πειράματα Πλαισίου Fed-SMOTE στο Σύνολο Δεδομένων NSL-KDD (U2R Attacks)

Client-Side SMOTE

Η εφαρμογή τοπικής υπερδειγματοληψίας επιδρά θετικά σε σχέση με την απλή Ομοσπονδιακή Μάθηση, ανεξαρτήτως του ελάχιστου αριθμού διαθέσιμων δειγμάτων ανά κόμβο. Στο ιδανικό σενάριο της IID κατανομής, η τοπική παρεμβολή του αλγορίθμου SMOTE καταφέρνει να ενισχύσει σημαντικά τα όρια απόφασης. Συγκεκριμένα, επιτυγχάνεται υπερδιπλασιασμός της μέσης τιμής των μετρικών F1-Score και Average Precision, σημειώνοντας τιμές 0.449 και 0.2572 αντίστοιχα. Η επίδοση της αρχιτεκτονικής Client-Side SMOTE ξεπερνά και το κεντρικοποιημένο Νευρωνικό Δίκτυο, υποδεικνύοντας πως ο συνδυασμός τοπικής υπερδειγματοληψίας και ομοσπονδιακής συνάθροισης αποδίδει θετικά αποτελέσματα, ακόμα και σε συνθήκες ακραίας σπανιότητας δεδομένων.

Σε σενάρια στατιστικής ετερογένειας, η επίδοση της αρχιτεκτονικής Client-Side SMOTE διατηρείται σε ικανοποιητικά επίπεδα για ήπια και υψηλή ετερογένεια, με μέσες τιμές F1-Score 0.3334 και 0.3578 αντίστοιχα. Παρόλα αυτά, οι υψηλές τυπικές α-

ποκλίσεις μαρτυρούν την έντονη αστάθεια του συστήματος, η οποία εξαρτάται από την τυχαία κατανομή των μειονοτικών δειγμάτων στους κόμβους-πελάτες ανά εκτέλεση. Ταυτόχρονα, σε συνθήκες ακραίας ετερογένειας ($\alpha = 0.1$), το σύστημα εξακολουθεί να καταρέει πλήρως, με τη συντριπτική πλειοψηφία των εκτελέσεων να σημειώνει μηδενικό F1-Score, καθώς η πλειοψηφία των κόμβων-πελατών ανά εκτέλεση δεν διαθέτει τον ελάχιστο απαιτούμενο αριθμό δειγμάτων της μειονοτικής κλάσης προκειμένου να εκτελεστεί τοπικά ο αλγόριθμος SMOTE.


Trans-Client SMOTE

Η ενσωμάτωση της αρχιτεκτονικής Trans-Client SMOTE στο σύνολο δεδομένων NSL-KDD αποτελεί την απτή απόδειξη των πειραματικών ευρημάτων σε σχέση με την αποτελεσματικότητα της προτεινόμενης αρχιτεκτονικής. Η ικανότητα της να αντλεί στατιστική πληροφορία από το σύνολο των διαθέσιμων δειγμάτων της μειονοτικής κλάσης επιλύει το πρόβλημα της ακραίας Ανισορροπίας Κλάσεων σε Ομοσπονδιακά Περιβάλλοντα.


Στο ιδανικό IID σενάριο, οι μέσες τιμές των F1-Score και Average Precision φτάνουν το 0.6134 και 0.3884 αντίστοιχα. Το πείραμα αυτό διαθέτει τις υψηλότερες καταγεγραμμένες τιμές μετρικών στο σύνολο των ομοσπονδιακών πειραμάτων, με αυτές να αποτελούν εξαιρετική επίδοση για ένα Νευρωνικό Δίκτυο που εκπαιδεύεται σε Ομοσπονδιακό Περιβάλλον με μόλις 52 δείγματα της μειοψηφικής κλάσης και συνθετικά δεδομένα που έχουν παραχθεί σε κρυπτογραφημένο χώρο. Η δια-κομβική παρεμβολή εμπλουτίζει τον χώρο των χαρακτηριστικών με ποικιλομορφία, την οποία κάποιος κόμβος-πελάτης δεν μπορούσε να αντλήσει με διαφορετικό τρόπο.

Σε συνθήκες ήπιας ($\alpha = 1.0$) και υψηλής ($\alpha = 0.5$) στατιστικής ετερογένειας, η δια-κομβική προσέγγιση επιτυγχάνει υψηλά καταγεγραμμένα αποτελέσματα με μέσες τιμές F1-Score 0.5801 και 0.4710 αντίστοιχα. Στο σενάριο της ακραίας στατιστικής ετερογένειας ($\alpha = 0.1$), παρότι το σύστημα συναντά δυσκολίες στην σταθερή σύγκλιση, με μέση τιμή F1-Score 0.0692, καταφέρνει διπλάσια απόδοση συγκριτικά με την αρχιτεκτονική Client-Side SMOTE. Για την καλύτερη εκτέλεση της αρχιτεκτονικής Trans-Client SMOTE σε ακραία στατιστική ετερογένεια, η τιμή F1-Score έφτασε στο 0.4615, επιβεβαιώνοντας την δυσκολία του προβλήματος υπο συνθήκες ακραίας στατιστικής ετερογένειας και εξαιρετικής σπανιότητας δεδομένων, οι οποίες παραμένουν ανοιχτές προκλήσεις για την Ομοσπονδιακή Μάθηση.

Με αυτά τα ευρήματα, αποδεικνύεται πλήρως πως η συνεργατική παραγωγή Συνθετικών Δεδομένων σε Ομοσπονδιακά Περιβάλλοντα προσφέρει ισχυρότατη άμυνα στα προαναφερόμενα προβλήματα, καθιστώντας την αρχιτεκτονική Trans-Client SMOTE μια εξαιρετικά υποσχόμενη λύση.



Σχήμα 4.12: Ραβδόγραμμα Συγκριτικής Αξιολόγησης Πλαισίου FedSMOTE στο Σύνολο Δεδομένων NSL-KDD



Σχήμα 4.13: Πορεία Εξέλιξης Τιμής F1-Score Μειοψηφικής Κλάσης ανά Γύρο Επικοινωνίας. Στιγμιότυπο από Καλύτερη Εκτέλεση Αρχιτεκτονικής Trans-Client SMOTE για Ακραία Στατιστική Ετερογένεια ($\alpha = 0.1$) στο Σύνολο Δεδομένων NSL-KDD

4.2.4 Υπολογιστική Επιβάρυνση και Κόστος Επικοινωνίας

Η αξιολόγηση της αρχιτεκτονικής Trans-Client SMOTE στο σύνολο δεδομένων NSL-KDD ολοκληρώνεται με την αποτίμηση του λειτουργικού κόστους του δικτύου. Η ανάλυση εστιάζει στον όγκο των δεδομένων που διακινούνται μέσω των τηλεπικοινωνιακών καναλιών, καθώς και στην υπολογιστική επιβάρυνση που προκαλείται από την ενσωμάτωση της Πλήρους Ομομορφικής Κρυπτογράφησης.

Τηλεπικοινωνιακή Επιβάρυνση και Μέγεθος Μοντέλου

Το μέγεθος του παγκοσμίου μοντέλου ανέρχεται σταθερά στα 0.03MB σε όλες τις πειραματικές διατάξεις. Το μικρό αυτό μέγεθος διασφαλίζει πως στο σύνολο των 20 γύρων επικοινωνίας μεταξύ του κεντρικού διακομιστή και των 5 συμμετεχόντων κόμβων-πελατών, το συνολικό κόστος επικοινωνίας διατηρείται στα 5.96MB. Συνεπώς, η προτεινόμενη λύση είναι απόλυτα βιώσιμη τηλεπικοινωνιακά, επιτρέποντας την ταχεία ανταλλαγή βαρών, αποτρέποντας την πρόκληση συμφόρησης στο δίκτυο.

Υπολογιστικό Κόστος Κρυπτογραφίας

Ο πρόσθετος υπολογιστικός χρόνος που απαιτείται για τους κρυπτογραφικούς μετασχηματισμούς, τη δια-κομβική παρεμβολή και την αποκρυπτογράφηση των συνθετικών δειγμάτων αναδεικνύει την ισχυρή εξάρτηση του πρωτοκόλλου από τον βαθμό στατιστικής ετερογένειας των δεδομένων.

Στο ιδανικό σενάριο της IID κατανομής των δεδομένων, η χρονική επιβάρυνση καταγράφεται στα 4.04 δευτερόλεπτα. Σε αυτήν την περίπτωση, τα ελάχιστα διαθέσιμα δείγματα της μειοψηφικής κλάσης μοιράζονται ομοιόμορφα στο δίκτυο, υποχρεώνοντας το σύνολο των κόμβων-πελατών να συμμετάσχει ενεργά στη διαδικασία παραγωγής συνθετικών δεδομένων και αυξάνοντας τον όγκο των ομομορφικών πράξεων στον κεντρικό διακομιστή.

Σε συνθήκες στατιστικής ετερογένειας, προκαλείται σημαντική μείωση του χρονικού κόστους. Συγκεκριμένα, σε συνθήκες ήπιας και υψηλής στατιστικής ετερογένειας ο χρόνος υποχώρησε στα 1.25 και 0.44 δευτερόλεπτα αντίστοιχα, ενώ στο πιο ακραίο σενάριο το χρονικό κόστος ελαχιστοποιήθηκε στα 0.45 δευτερόλεπτα.

Αξίζει να σημειωθεί ότι, σε αντίθεση με την κατανομή IID, στα πειράματα στατιστικής ετερογένειας παρατηρήθηκε έντονη μεταβλητότητα του υπολογιστικού χρόνου μεταξύ διαφορετικών εκτελέσεων. Το φαινόμενο αυτό ερμηνεύεται άμεσα από την ακραία σπανιότητα της μειονοτικής κλάσης (μόλις 52 δείγματα). Υπό κατανομή Dirichlet, η τυχαία διασπορά αυτού του πολύ μικρού πληθυσμού δημιουργεί τεράστιες διαφοροποιήσεις ανά εκτέλεση: σε ορισμένα σενάρια, τα δείγματα ενδέχεται να συγκεντρωθούν αποκλει-

στικά σε έναν ή δύο κόμβους, απαλλάσσοντας το υπόλοιπο δίκτυο από οποιονδήποτε υπολογιστικό φόρτο κρυπτογράφησης, γεγονός που ελαχιστοποιεί τον παγκόσμιο χρόνο. Σε άλλες περιπτώσεις, η πιο διεσπαρμένη τοποθέτησή τους αυξάνει τον αριθμό των συμμετεχόντων κόμβων, προκαλώντας διακυμάνσεις στον χρόνο του κρυπτογραφικού πρωτοκόλλου.

Συμπερασματικά, η αρχιτεκτονική Trans-Client SMOTE κατορθώνει να ανακτήσει την προγνωστική ικανότητα του συστήματος, εισάγοντας ένα υπολογιστικό κόστος το οποίο, ακόμη και στη χειρόστη περίπτωση των περίπου 4 δευτερολέπτων, κρίνεται απολύτως αμελητέο για εφαρμογές ασφάλειας δικτύων.

Κεφάλαιο 5

Συμπεράσματα, Ανοιχτά Ζητήματα και Μελλοντικές Επεκτάσεις

Στο τελικό κεφάλαιο της τρέχουσας διπλωματικής εργασίας, πραγματοποιείται μια ανακεφαλαίωση των κυριότερων ευρημάτων της έρευνας που διεξήχθη. Σε πρώτο στάδιο, συνοψίζεται η συνεισφορά των προτεινόμενων αρχιτεκτονικών στην αξιοποίηση Συνθετικών Δεδομένων για την αντιμετώπιση του προβλήματος της Ανισορροπίας Κλάσεων σε Περιβάλλοντα Ομοσπονδιακής Μάθησης. Στη συνέχεια, επισημαίνονται οι εγγενείς περιορισμοί και τα ανοιχτά ερευνητικά ζητήματα που σχετίζονται με την ενσωμάτωση του πλαισίου FedSMOTE, οδηγώντας σε προτάσεις και μελλοντικές επεκτάσεις επί του συγκεκριμένου ερευνητικού πεδίου.

5.1 Σύνοψη και Βασικά Συμπεράσματα

Η παρούσα διπλωματική εργασία επικεντρώνεται σε ένα από τα πλέον κρίσιμα και δυσεπίλυτα προβλήματα της σύγχρονης αποκεντρωμένης Μηχανικής Μάθησης. Συγκεκριμένα, η εργασία πραγματεύεται την αξιοποίηση Συνθετικών Δεδομένων για την αντιμετώπιση του προβλήματος Ανισορροπίας Κλάσεων σε Περιβάλλοντα Ομοσπονδιακής Μάθησης. Η πειραματική διαδικασία και τα ακόλουθα συμπεράσματα εξάχθηκαν μέσα από την εκτενή συγκριτική αξιολόγηση σε δύο διαφορετικά σύνολα δεδομένων.

Σε πρώτο στάδιο, επιβεβαιώθηκε πειραματικά πως τα κλασικά Ομοσπονδιακά Περιβάλλοντα καταρρέουν σε συνθήκες Ανισορροπίας Κλάσεων. Η απουσία δειγμάτων της μειονοτικής κλάσης στους τοπικούς κόμβους-πελάτες καθιστά το παγκόσμιο μοντέλο ανίκανο να εντοπίσει τις σπάνιες περιπτώσεις ενδιαφέροντος.

Η εφαρμογή του αλγορίθμου υπερδειγματοληψίας SMOTE σε τοπικό επίπεδο απέδειξε ότι δρα ως ένας ικανοποιητικός μηχανισμός εξομάλυνσης στο ιδανικό σενάριο IID

κατανομής των δεδομένων στους τοπικούς κόμβους-πελάτες ή σε συνθήκες ήπιας στατιστικής ετερογένειας. Το βασικό πρόβλημα εγκείται σε συνθήκες ακραίας στατιστικής ετερογένειας, όπου η αδυναμία άντλησης επαρκούς στατιστικής πληροφορίας οδηγεί σε τοπική υπερπροσαρμογή και υποβάθμιση του παγκόσμιου μοντέλου.

Η λύση των παραπάνω προβλημάτων συναντάται στην συνεργατική δια-κομβική υπερ-δειγματοληψία, η οποία αρχιτεκτονική αποτελεί και την κύρια ερευνητική συνεισφορά της εργασίας. Η γραμμική παρεμβολή στον κρυπτογραφημένο χώρο, με αξιοποίηση της Πλήρους Ομομορφικής Κρυπτογράφησης και του σχήματος CKKS, προσφέρει στο σύστημα την απαραίτητη παγκόσμια ποικιλομορφία. Η προτεινόμενη αρχιτεκτονική αποδεικνύεται πολύ υποσχόμενη, διατηρώντας τις μετρικές F1-Score και Average Precision σε υψηλά επίπεδα, επιδεικνύοντας αδιαφορία ως προς τον βαθμό της στατιστικής ετερογένειας και την ίδια την αποκεντρωμένη φύση του συστήματος, διασφαλίζοντας παράλληλα την μαθηματικά εγγυημένη προστασία των αρχικών ευαίσθητων δεδομένων.

5.2 Ανοιχτά Ζητήματα

Παρά την αδιαμφισβήτη βελτίωση της προγνωστικής ικανότητας του παγκόσμιου μοντέλου, η σύζευξη της Ομοσπονδιακής Μάθησης με την Πλήρως Ομομορφική Κρυπτογράφηση εγείρει σημαντικά ζητήματα που παραμένουν ανοιχτά προς διερεύνηση.

Αρχικά, οι πράξεις κρυπτογράφησης, αποκρυπτογράφησης και ιδιαίτερα οι ομομορφικοί πολλαπλασιασμοί στον κρυπτογραφημένο χώρο εισάγουν δραματική αύξηση στον απαιτούμενο χρόνο εκτέλεσης. Παράλληλα, το μέγεθος των κρυπτογραφημένων μηνυμάτων αυξάνει εκθετικά τον όγκο δεδομένων που πρέπει να διακινηθεί στο δίκτυο. Αυτός ο περιορισμός καθιστά την αρχιτεκτονική ιδανική για Cross-Silo σενάρια, που αφορούν μεγάλα ιδρύματα, αλλά πρακτικά απαγορευτική για Cross-Device εφαρμογές, όπου υπάρχουν περιορισμοί εύρους ζώνης. Αν και στα πλαίσια της παρούσας μελέτης το υπολογιστικό κόστος διατηρήθηκε σε εξαιρετικά χαμηλά επίπεδα λόγω της επιτάχυνσης μέσω σύγχρονων μονάδων GPU και της μικρής κλίμακας του Νευρωνικού Δικτύου, η κλιμάκωση του πρωτοκόλλου σε Βαθιά Νευρωνικά Δίκτυα εκατομμυρίων παραμέτρων παραμένει μια ανοιχτή τηλεπικοινωνιακή πρόκληση.

Ταυτόχρονα, λόγω των δομικών περιορισμών του σχήματος CKKS, ο βαθμός παρεμβολής της αρχιτεκτονικής Trans-Client SMOTE περιορίζεται σε ένα διακριτό σύνολο δεκαδικών τιμών. Ενώ με βάση τα πειραματικά αποτελέσματα, η πρακτική αυτή αποδίδει εξαιρετικά αποτελέσματα, η πλήρως συνεχής τυχαία παρεμβολή στον κρυπτογραφημένο χώρο παραμένει ένα δύσκολο μαθηματικό πρόβλημα.

5.3 Μελλοντικές Επεκτάσεις

Με βάση τα ευρήματα και τους περιορισμούς της παρούσας μελέτης, μελλοντικές προσπάθειες μπορούν να επικεντρωθούν σε πληθώρα κατευθύνσεων.

Στην παρούσα εργασία εφαρμόστηκε η βασική έκδοση του αλγόριθμου υπερδειγματοληψίας SMOTE σε Ομοσπονδιακό Περιβάλλον. Εξαιρετικά ενδιαφέρουσα επέκταση θα αποτελούσε ο σχεδιασμός ενός πρωτοκόλλου βασισμένο στον αλγόριθμο **Borderline-SMOTE**, όπου εντοπίζονται και ταξινομούνται ως επικίνδυνα τα μειοψηφικά δείγματα στα όρια απόφασης ή ενός πρωτοκόλλου που είναι αντίστοιχα βασισμένο στον αλγόριθμο **ADASYN**, όπου η παραγωγή συνθετικών δεδομένων προσαρμόζεται στην πυκνότητα. Τα πρωτόκολλα αυτά θα εφαρμόζονται εξολοκλήρου πάνω σε κρυπτογραφημένα δεδομένα, αποφεύγοντας ταυτόχρονα τη δημιουργία θορύβου και εγγυώντας την ασφάλεια των αρχικών δεδομένων.

Προκειμένου να αμβλυνθεί η τηλεπικοινωνιακή επιβάρυνση των κρυπτογραφικών τεχνικών, η αρχιτεκτονική Trans-Client SMOTE μπορεί να συνδυαστεί με τεχνικές **Ασφαλούς Πολυμερούς Υπολογισμού (Secure Multi-Party Computation - SMPC) ή Διαφορικής Ιδιωτικότητας (Differential Privacy - DP)**. Ένα υβριδικό σύστημα θα μπορούσε να εξισορροπήσει τον συμβιβασμό μεταξύ της ασφάλειας και της υπολογιστικής αποδοτικότητας.

Η χρονική καθυστέρηση που προκαλείται από τις πράξεις του σχήματος CKKS εντείνει το πρόβλημα των καθυστερημένων πελατών. Η διερεύνηση ενός **Ασύγχρονου Πρωτοκόλλου Ομοσπονδιακής Μάθησης**, όπου ο κεντρικός διακομιστής δεν αναμένει όλους τους κόμβους-πελάτες προκειμένου να προχωρήσει στην συνάθροιση και στην παραγωγή συνθετικών δειγμάτων, αποτελεί μια πολλά υποσχόμενη αρχιτεκτονική βελτίωση.

Η εξέλιξη του ερευνητικού πεδίου απαιτεί τη διερεύνηση υλοποιήσεων της αρχιτεκτονικής Trans-Client SMOTE σε **εξειδικευμένο υλικό**, το οποίο θα διαθέτει τη δυνατότητα παραλληλοποίησης των πράξεων στο κρυπτογραφημένο χώρο και της μείωσης του χρόνου της κρυπτογραφικής παρεμβολής σε πραγματικό χρόνο.

Bibliography

- [1] R. Khadka, "Machine learning types 2," Sep 2017. [Online]. Available: <https://medium.com/data-science/machine-learning-types-2-c1291d4f04b1>
- [2] "Supervised machine learning," Apr 2026. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/supervised-machine-learning/>
- [3] "What is unsupervised learning," Apr 2026. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/unsupervised-learning/>
- [4] "Reinforcement learning," Apr 2026. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/what-is-reinforcement-learning/>
- [5] "Workflow of machine learning for effective data processing outline diagram," Apr 2026. [Online]. Available: <https://gr.pinterest.com/pin/309974386871392818/>
- [6] "Simplified structure of xgboost," Apr 2026. [Online]. Available: https://www.researchgate.net/figure/Simplified-structure-of-XGBoost_fig5_381857634
- [7] "What is a neural network," Apr 2026. [Online]. Available: <https://www.geeksforgeeks.org/deep-learning/neural-networks-a-beginners-guide/>
- [8] "Generative adversarial network (gan)," Apr 2026. [Online]. Available: <https://www.geeksforgeeks.org/deep-learning/generative-adversarial-network-gan/>
- [9] "Dealing with imbalanced datasets in machine learning: Techniques and best practices," Mar 2023. [Online]. Available: <https://www.blog.trainindata.com/machine-learning-with-imbalanced-data/>
- [10] "10 techniques to solve imbalanced classes in machine learning," Dec 2025. [Online]. Available: <https://www.analyticsvidhya.com/blog/2020/07/10-techniques-to-deal-with-class-imbalance-in-machine-learning/>
- [11] "Smote for imbalanced classification with python," Apr 2025. [Online]. Available: <https://www.analyticsvidhya.com/blog/2020/10/overcoming-class-imbalance-using-smote-techniques/>

- [12] “What is federated learning?” Oct 2019. [Online]. Available: <https://blogs.nvidia.com/blog/what-is-federated-learning/>
- [13] “Cross-device versus cross-silo federated learning,” Feb 2025. [Online]. Available: https://www.researchgate.net/figure/Cross-device-versus-cross-silo-federated-learning_fig3_388615693
- [14] “What is fully homomorphic encryption,” Jan 2024. [Online]. Available: <https://www.linkedin.com/pulse/what-fully-homomorphic-encryption-gregory-boland-wi3ue/>
- [15] IBM Data and AI Team, “Machine learning examples, applications & use cases,” <https://www.ibm.com/think/topics/machine-learning-use-cases>, 2026, á: 14 i 2026.
- [16] A. Bussche, *The EU General Data Protection Regulation (GDPR): A Practical Guide*. Springer, 2017.
- [17] Google Cloud, “What is federated learning?” <https://cloud.google.com/discover/what-is-federated-learning>, 2026, á: 15 i 2026.
- [18] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y. Arcas, “Communication-Efficient Learning of Deep Networks from Decentralized Data,” in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, ser. Proceedings of Machine Learning Research, A. Singh and J. Zhu, Eds., vol. 54. PMLR, 20–22 Apr 2017, pp. 1273–1282. [Online]. Available: <https://proceedings.mlr.press/v54/mcmahan17a.html>
- [19] P. Kairouz and H. B. McMahan, “Advances and open problems in federated learning,” *Foundations and trends in machine learning*, vol. 14, no. 1-2, pp. 1–210, 2021.
- [20] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Transactions on knowledge and data engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [21] L. Wang, S. Xu, X. Wang, and Q. Zhu, “Addressing class imbalance in federated learning,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 11, pp. 10 165–10 173, May 2021. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/17219>
- [22] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “Smote: synthetic minority over-sampling technique,” *Journal of artificial intelligence research*, vol. 16, pp. 321–357, 2002.

- [23] L. Zhu, Z. Liu, and S. Han, "Deep leakage from gradients," in *Advances in Neural Information Processing Systems*, H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, Eds., vol. 32. Curran Associates, Inc., 2019. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2019/file/60a6c4002cc7b29142def8871531281a-Paper.pdf
- [24] C.-C. Zong and S.-J. Huang, "Federated active learning under extreme non-iid and global class imbalance," *arXiv preprint arXiv:2603.10341*, 2026.
- [25] R. Younis and M. Fisichella, "Fly-smote: Re-balancing the non-iid iot edge devices data in federated learning system," *IEEE Access*, vol. 10, pp. 65 092–65 102, 2022.
- [26] T. Alsolami and M. Ilyas, "Fedsmote-dp: Privacy-aware federated ensemble learning for intrusion detection in iomt networks," *Sensors*, vol. 26, no. 5, p. 1592, 2026.
- [27] Z. K. Taha, J. K. S. Paw, Y. C. Tak, T. S. Kiong, K. Kadirgama, F. Benedict, T. J. Ding, K. Ali, and A. M. Abed, "Advances in federated learning: combining local preprocessing with adaptive uncertainty symmetry to reduce irrelevant features and address imbalanced data," *IEEE Access*, vol. 12, pp. 186 277–186 295, 2024.
- [28] R. Darwish, M. Abdelsalam, S. Khorsandroo, and K. Roy, "Fedp3e: Privacy-preserving prototype exchange for non-iid iot malware detection in cross-silo federated learning," *arXiv preprint arXiv:2507.07258*, 2025.
- [29] J. Wen, X. Li, L. Long, X. Li, and H. Mao, "A privacy-preserving data augmentation approach for credit card fraud detection," 2024.
- [30] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga *et al.*, "Pytorch: An imperative style, high-performance deep learning library," *Advances in neural information processing systems*, vol. 32, 2019.
- [31] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg *et al.*, "Scikit-learn: Machine learning in python," *the Journal of machine Learning research*, vol. 12, pp. 2825–2830, 2011.
- [32] G. Lemaître, F. Nogueira, and C. K. Aridas, "Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning," *Journal of machine learning research*, vol. 18, no. 17, pp. 1–5, 2017.

- [33] A. Benaissa, B. Retiat, B. Cebere, and A. E. Belfedhal, "Tenseal: A library for encrypted tensor operations using homomorphic encryption. arxiv 2021," *arXiv preprint arXiv:2104.03152*, 2021.
- [34] T. M. Mitchell, *Machine learning*. MacGraw-Hill, 1997.
- [35] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [36] C. M. Bishop and N. M. Nasrabadi, *Pattern recognition and machine learning*. Springer, 2006, vol. 4, no. 4.
- [37] R. S. Sutton, A. G. Barto *et al.*, *Reinforcement learning: An introduction*. MIT press Cambridge, 1998, vol. 1, no. 1.
- [38] S. B. Kotsiantis, I. Zaharakis, P. Pintelas *et al.*, "Supervised machine learning: A review of classification techniques," *Emerging artificial intelligence applications in computer engineering*, vol. 160, no. 1, pp. 3–24, 2007.
- [39] D. W. Hosmer Jr, S. Lemeshow, and R. X. Sturdivant, *Applied logistic regression*. John Wiley & Sons, 2013.
- [40] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, 2016, pp. 785–794.
- [41] W. S. McCulloch and W. Pitts, "A logical calculus of the ideas immanent in nervous activity," *The bulletin of mathematical biophysics*, vol. 5, no. 4, pp. 115–133, 1943.
- [42] F. Rosenblatt, "The perceptron: a probabilistic model for information storage and organization in the brain." *Psychological review*, vol. 65, no. 6, p. 386, 1958.
- [43] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *nature*, vol. 323, no. 6088, pp. 533–536, 1986.
- [44] G. Cybenko, "Approximation by superpositions of a sigmoidal function," *Mathematics of control, signals and systems*, vol. 2, no. 4, pp. 303–314, 1989.
- [45] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial nets," *Advances in neural information processing systems*, vol. 27, 2014.
- [46] N. Japkowicz and S. Stephen, "The class imbalance problem: A systematic study," *Intelligent data analysis*, vol. 6, no. 5, pp. 429–449, 2002.

- [47] V. García, J. S. Sánchez, and R. A. Mollineda, “On the effectiveness of pre-processing methods when dealing with different levels of class imbalance,” *Knowledge-Based Systems*, vol. 25, no. 1, pp. 13–21, 2012.
- [48] H. He, Y. Bai, E. A. Garcia, and S. Li, “Adasyn: Adaptive synthetic sampling approach for imbalanced learning,” in *2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence)*. Ieee, 2008, pp. 1322–1328.
- [49] H. Han, W.-Y. Wang, and B.-H. Mao, “Borderline-smote: a new over-sampling method in imbalanced data sets learning,” in *International conference on intelligent computing*. Springer, 2005, pp. 878–887.
- [50] U. Fiore, A. De Santis, F. Perla, P. Zanetti, and F. Palmieri, “Using generative adversarial networks for improving classification effectiveness in credit card fraud detection,” *Information Sciences*, vol. 479, pp. 448–455, 2019.
- [51] Q. Yang, Y. Liu, T. Chen, and Y. Tong, “Federated machine learning: Concept and applications,” *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 10, no. 2, pp. 1–19, 2019.
- [52] Y. Zhao, M. Li, L. Lai, N. Suda, D. Civin, and V. Chandra, “Federated learning with non-iid data,” *arXiv preprint arXiv:1806.00582*, 2018.
- [53] R. L. Rivest, A. Shamir, and L. Adleman, “A method for obtaining digital signatures and public-key cryptosystems,” *Communications of the ACM*, vol. 21, no. 2, pp. 120–126, 1978.
- [54] C. Gentry, “Fully homomorphic encryption using ideal lattices,” in *Proceedings of the forty-first annual ACM symposium on Theory of computing*, 2009, pp. 169–178.
- [55] A. Acar, H. Aksu, A. S. Uluagac, and M. Conti, “A survey on homomorphic encryption schemes: Theory and implementation,” *ACM Computing Surveys (Csur)*, vol. 51, no. 4, pp. 1–35, 2018.
- [56] J. H. Cheon, A. Kim, M. Kim, and Y. Song, “Homomorphic encryption for arithmetic of approximate numbers,” in *International conference on the theory and application of cryptology and information security*. Springer, 2017, pp. 409–437.
- [57] D. M. Powers, “Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation,” *arXiv preprint arXiv:2010.16061*, 2020.

- [58] T. Fawcett, "An introduction to roc analysis," *Pattern recognition letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [59] J. Davis and M. Goadrich, "The relationship between precision-recall and roc curves," in *Proceedings of the 23rd international conference on Machine learning*, 2006, pp. 233–240.
- [60] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets," *PloS one*, vol. 10, no. 3, p. e0118432, 2015.
- [61] I. Goodfellow, "Deep learning," 2016.
- [62] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [63] T.-M. H. Hsu, H. Qi, and M. Brown, "Measuring the effects of non-identical data distribution for federated visual classification," *arXiv preprint arXiv:1909.06335*, 2019.